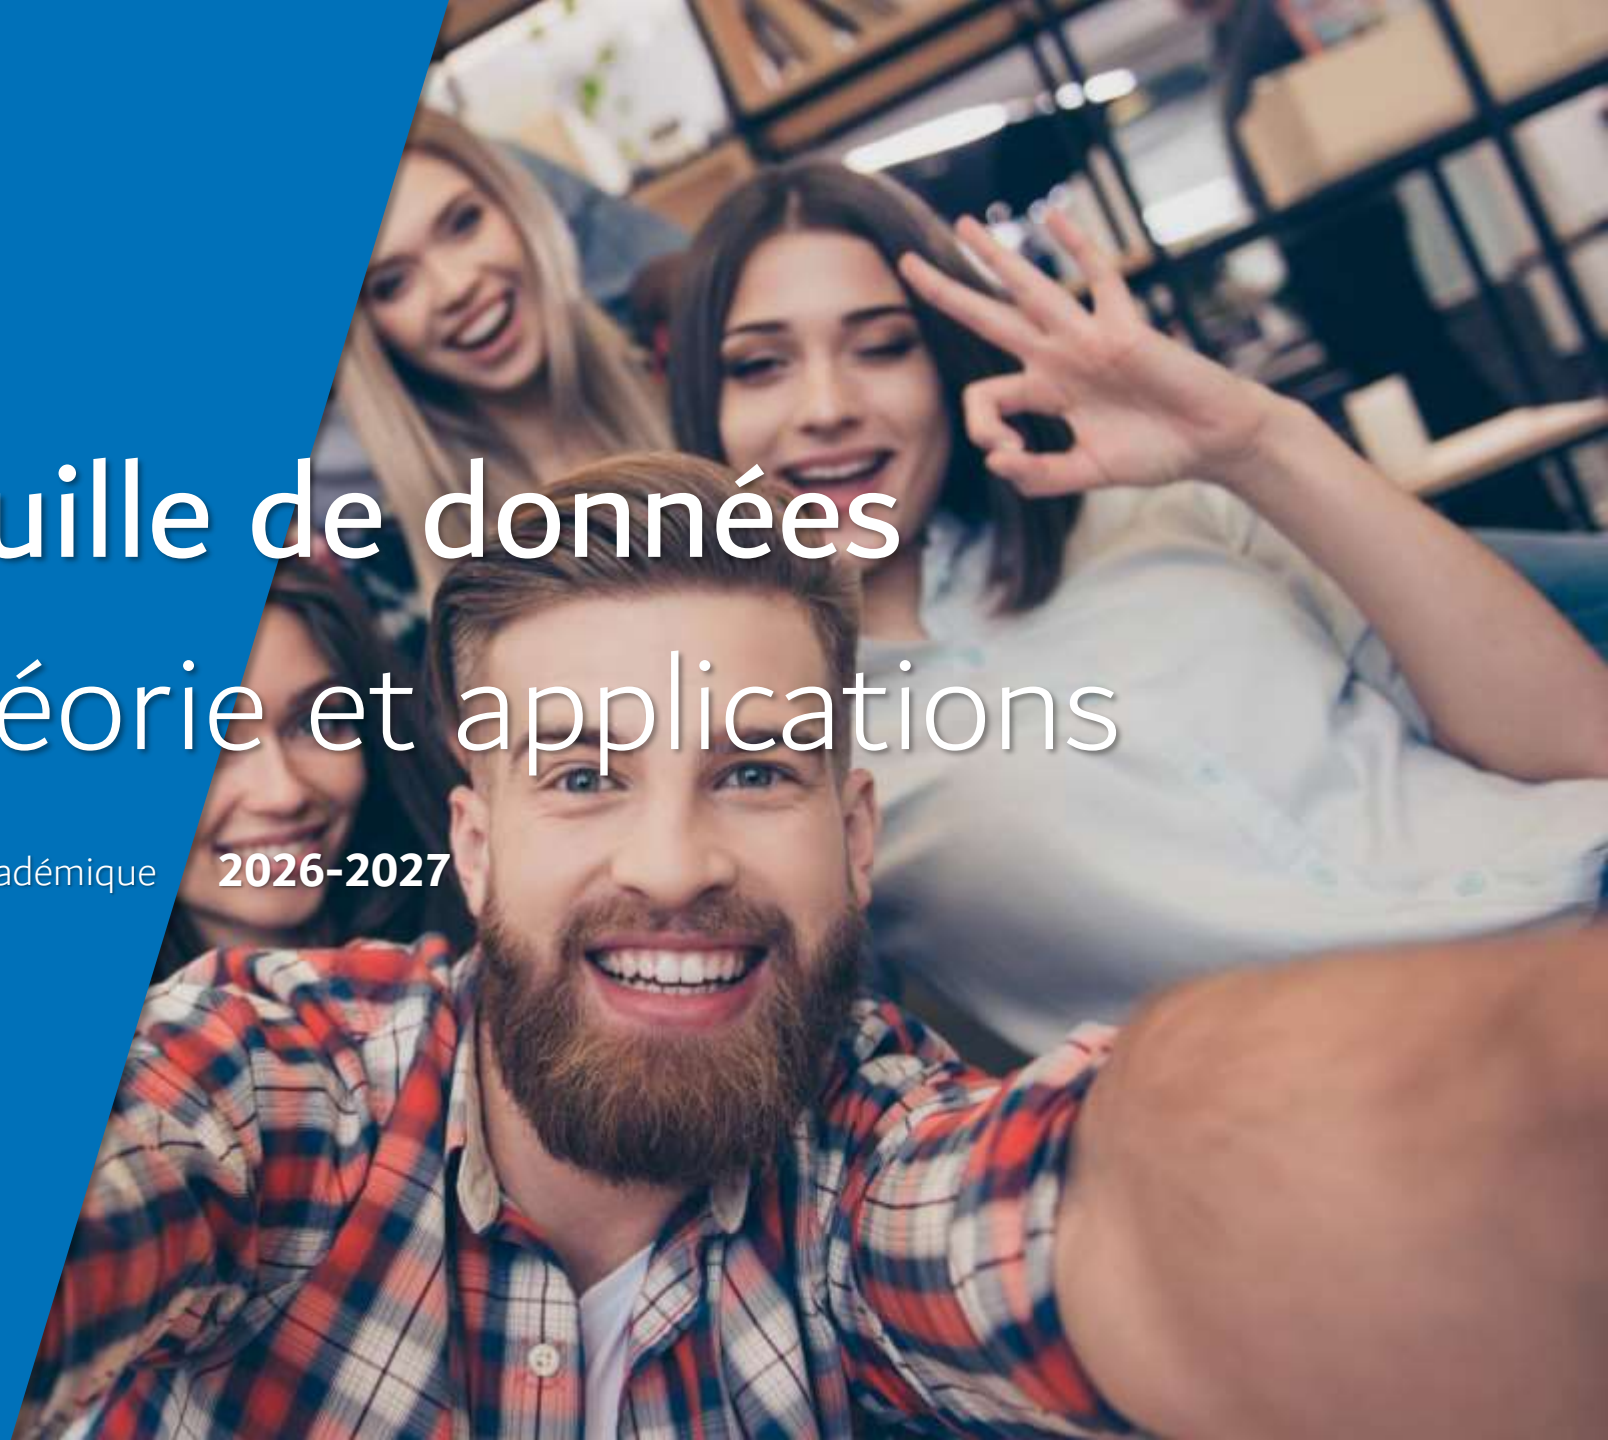
HAUTE ÉCOLE DE NAMUR-LIÈGE-LUXEMBOURG

UNIVERSITÉ DE NAMUR

Fouille de données

Théorie et applications

Année académique **2026-2027**



Présentation générale - UE

1. Théorie et **applications** (volume global – 45h)
2. Laboratoires (en groupes et présentation à la classe – 15h)

Calendrier provisoire

1. Présentation générale – 17/09
2. Régression logistique – 23/09 – 2h
3. Maximum de vraisemblance & Généralisation à n dimensions – 30/09
4. Matrice de confusion – 21/10
5. Courbe ROC et AUC – 13/11
6. Sélection de dimension discriminante – 05/11 – 6h ☺
7. Généralisation à un autre domaine fonctionnel (1) – 12/11
8. Généralisation à un autre domaine fonctionnel (2) – 19/11
9. Dilemme biais-variance & Généralisation à un autre domaine fonctionnel (3) - 26/11
10. Apprentissage non supervisé - 11/12
11. Apprentissage par renforcement - 18/12

Présentation générale

Théorie

1. Introduction et rapide historique
2. Concepts clés
3. Méthodologies générales
4. Techniques spécifiques
5. Etudes de cas
6. Questions d'actualités:

    10-15 minutes par semaine par un membre du groupe... y compris moi pour les premières semaines

Présentation générale

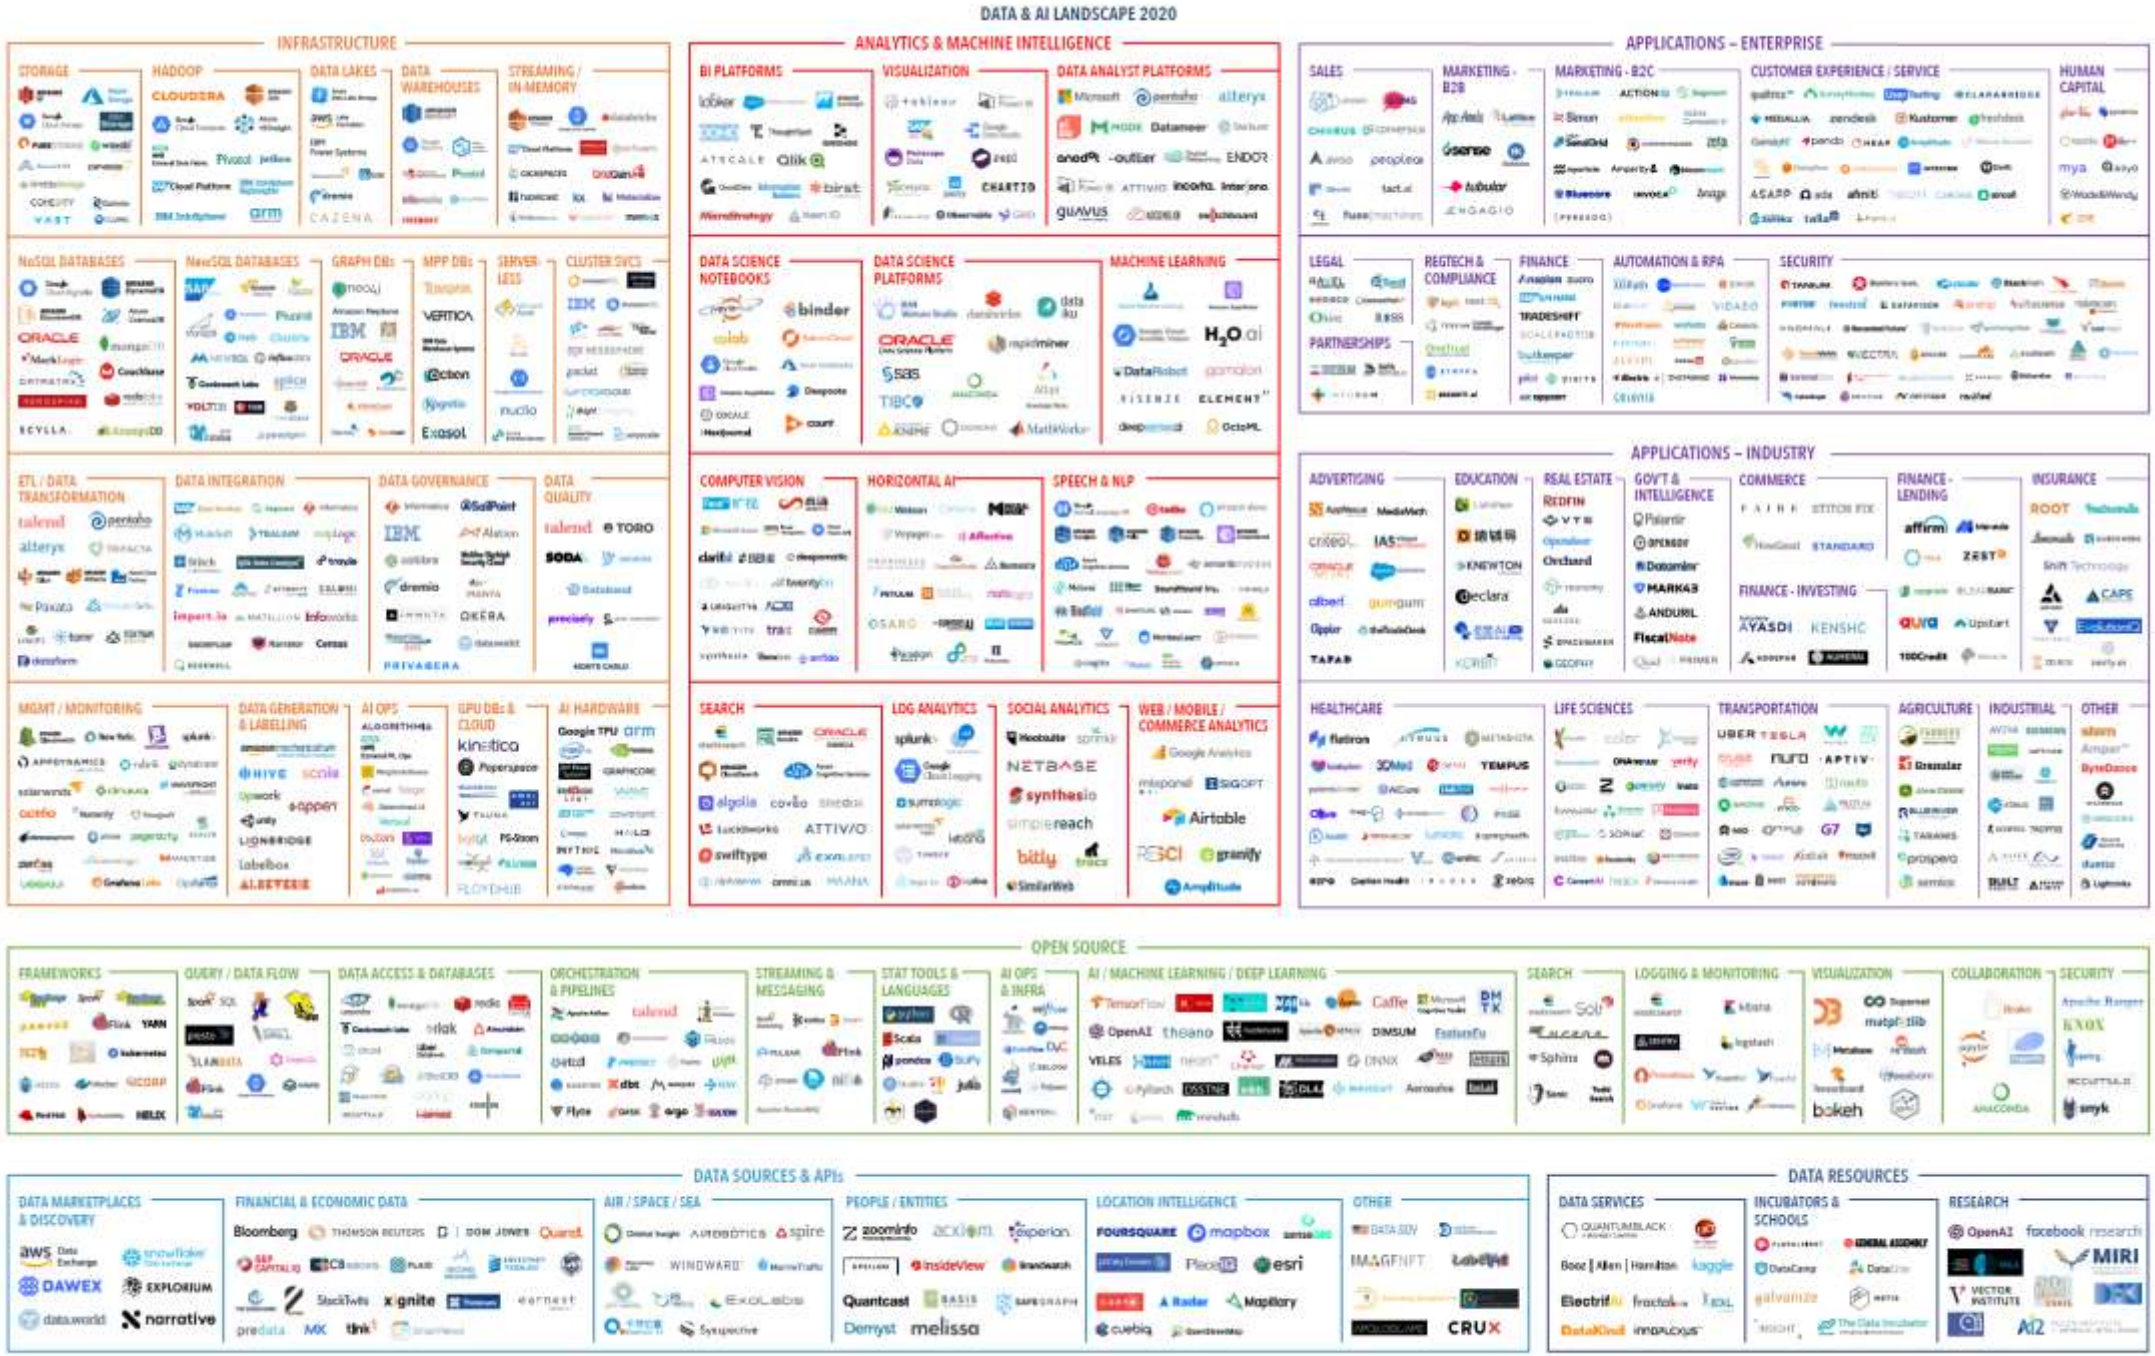
Applications

1. Régression logistique
2. Courbe ROC
3. Régression multiple et construction de modèle
4. Feature Selection – Méthode LASSO

Présentation générale

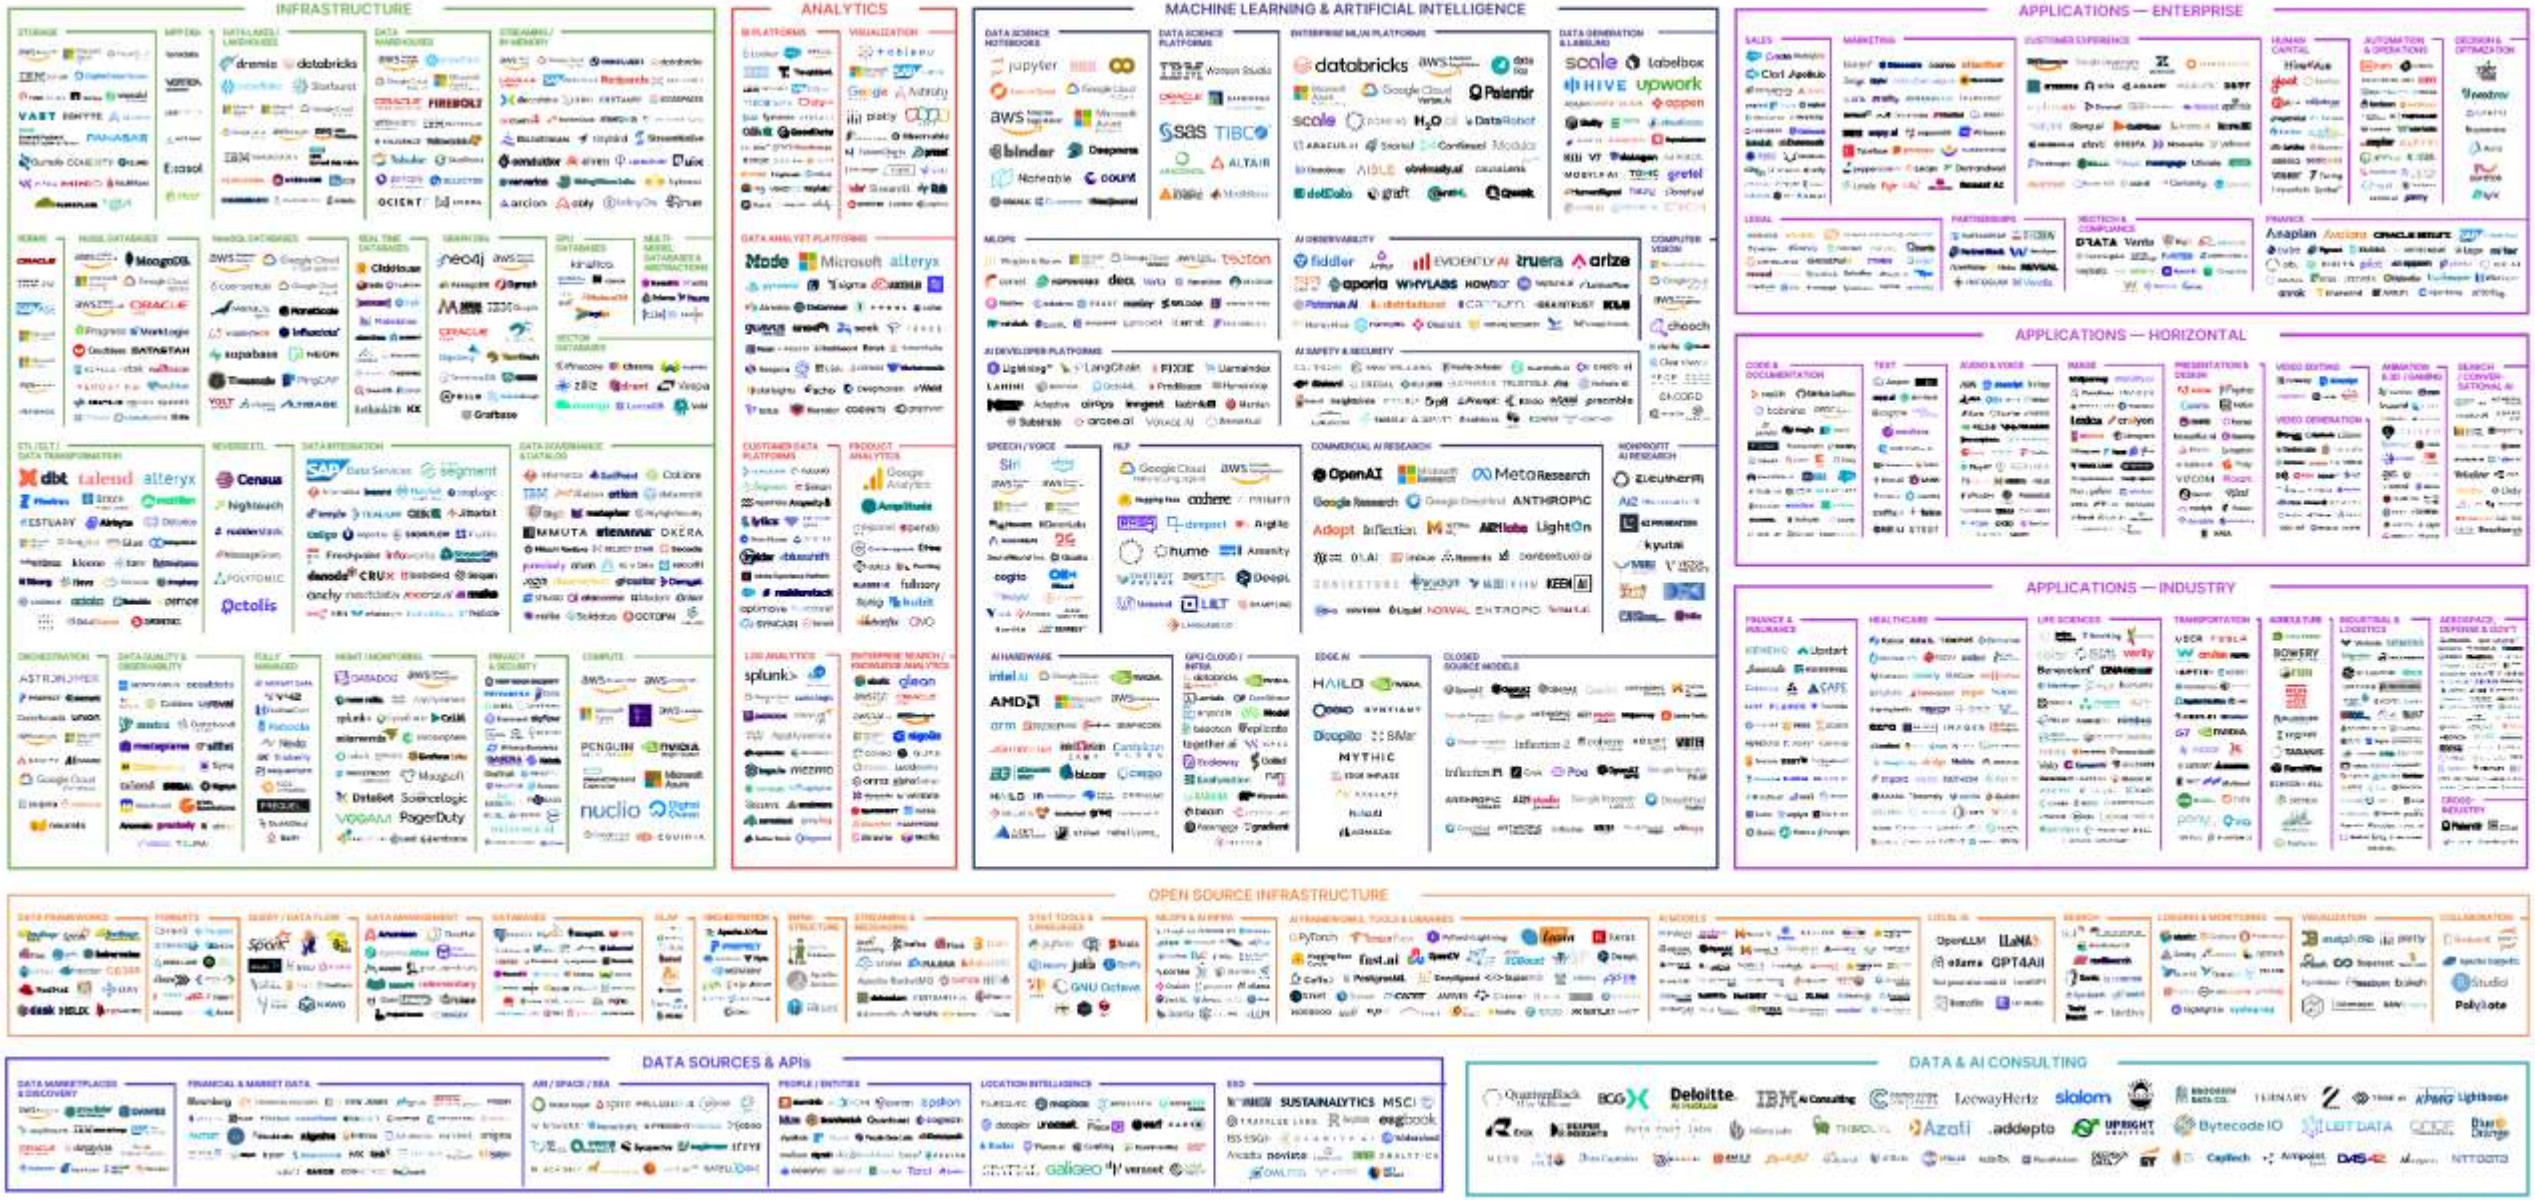
Laboratoires (en groupes + présentation - 15h)

1. Méthodes de réductions de dimensions – PCA
2. Estimation bayésienne et réseaux bayésiens
3. Arbre de décision et random forest
4. Clustering
5. (a) Réseau neuronal + (b) Deep Learning
6. Outils GIS et fouilles de données spatiales
7. Text Mining
8. Topic Modelling
9. LLM (Large Language Model) et GPT-x (General Pre-Trained Transformers)
10. Process Mining - Log Mining
11. Graph Analytics
12. RPA (Robot Process Automation)



© Matt Turck (@mattturck) & FirstMark (@firstmarkcap)

THE 2024 MAD (MACHINE LEARNING, ARTIFICIAL INTELLIGENCE & DATA) LANDSCAPE



Face à cela…

Pratiquement, il faut un outil de fouille de données !

- N'espérez pas trop d'un cours *ex cathedra* !!!
- Je ne serai 'que' médiateur, éclaireur, organisateur, facilitateur, ressource mais PAS le (dépositaire|référent) du savoir !!!
- Cette méthode est vouée à l'échec car il y a trop à apprendre ☺

- Même s'il est immense, le domaine de la fouille de données et son utilisation au sein de l'entreprise se résument souvent à une partie d'un cadre plus large, l'informatique décisionnelle (*Business Intelligence*, BI)

Ne JAMAIS perdre de vue que le Data Mining

- (n')est (qu')un **outil** et pas une boîte magique



- ne trouve pas automatiquement des solutions sans se faire **"guider" un minimum**

Ne JAMAIS perdre de vue que dans le Data Mining

- pour être certain d'avoir des résultats plausibles, il faut maîtriser la connaissance de ses données ;



- **l'enjeu majeur**: trouver des modèles robustes et éviter le "surapprentissage" , le "surajustement" : trouver des modèles très efficaces dans un contexte donné (l'environnement d'apprentissage) mais également capables de généraliser leurs bons résultats dans un autre contexte (l'environnement de test)).

Data Mining

Références (2)

- Livres :
  - Exploration de données – Méthodes et modèles du *data mining* Daniel T. Larose (2012) Vuibert
  - Apprentissage artificiel – Concepts et algorithmes A. Cornuéjols (2010) Eyrolles
  - Apprentissage statistique G. Dreyfus (2008) Eyrolles
  - Réseaux de neurones – Méthodologie et applications G. Dreyfus (2002) Eyrolles
  - Réseaux bayésiens P. Naïm (2008) Eyrolles

- Sites Web :
  - Supports de cours en Data Science – Machine Learning – Statistique, Ricco Rakotomalala – Université Lumière Lyon 2
  - scikit-learn – Machine Learning in Python

Présentation générale

Applications

1. Régression logistique
2. Courbe ROC
3. Régression multiple et construction de modèle
4. Feature Selection – Méthode LASSO

Rappels

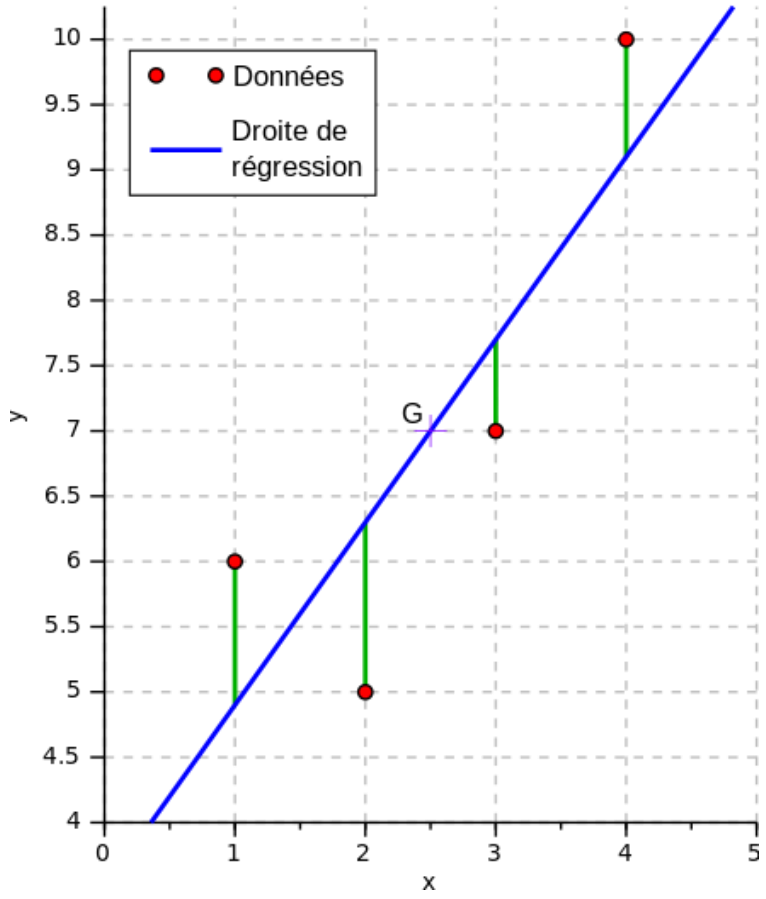
Régression linéaire (1)

- Fonction de sortie potentiellement sur [- ∞,+∞]
- Valeurs des paramètres optimaux justifiées par une analyse à moindre carré sur l'erreur cumulée

  C'est d'ailleurs la diminution (régression) de cette erreur cumulée sur le modèle linéaire idéal qui justifie le nom de la méthode!
- Résultats analytiques

Rappels

Régression linéaire (2)



- La droite de régression passe par G, le centre de gravité du nuage de points.

- L'équation de la droite de régression est

$$y = ax + b$$

où

$$a = cov(x, y)/var(x)\text{^}2$$

et

$$b = \bar{y} - a\bar{x}$$

Régression logistique

N'est pas une régression linéaire ☺ parce que…

- Fonction de sortie limitée à [0.0,1.0]
  - En forme de S très allongé
  - Peut être interprétée comme une probabilité
- Sert plutôt pour de la classification
- La solution de régression optimale n'a pas de forme analytique
  - Ici, on maximisera la vraisemblance du modèle vis-à-vis des données (voir théorie)

Régression logistique

A quoi cela ressemble ?

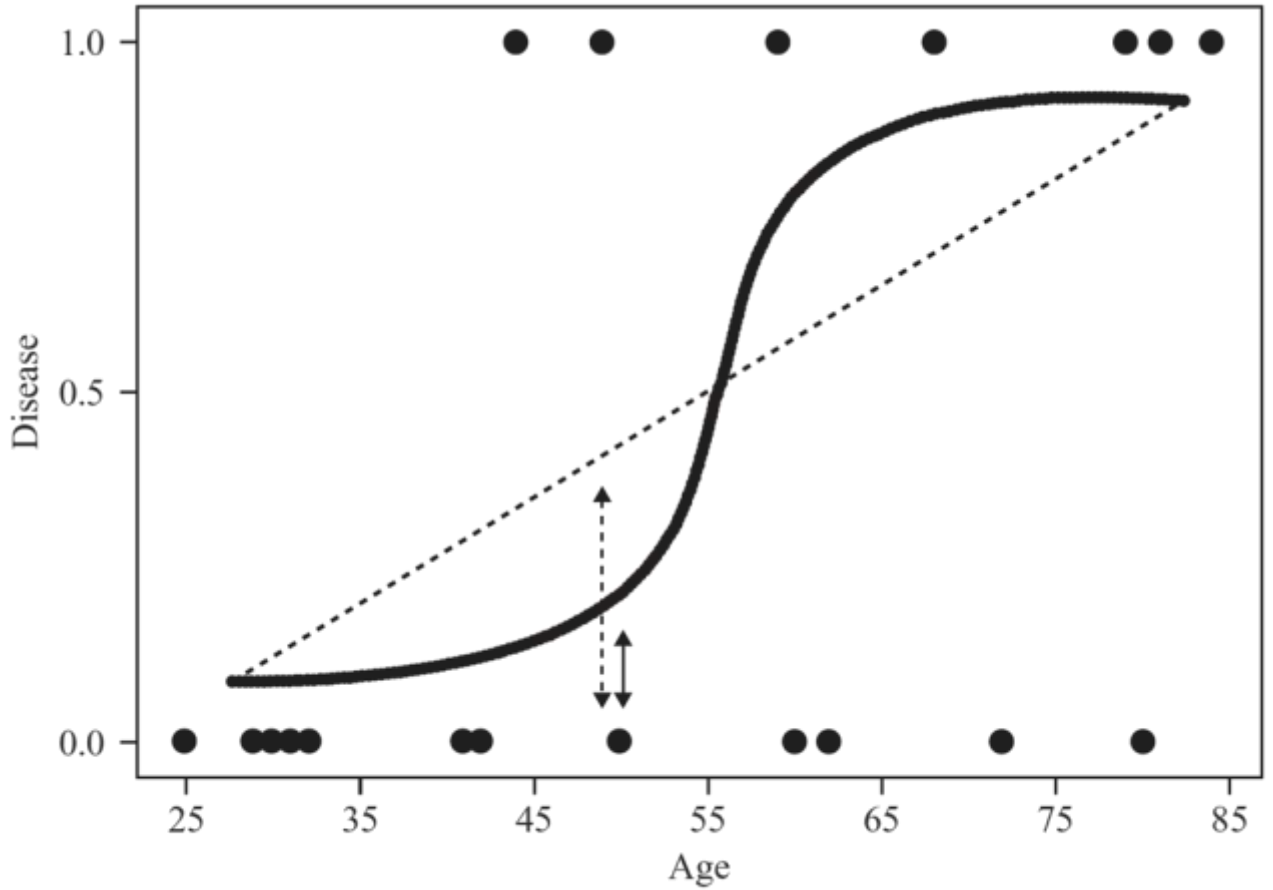


Figure 4.1 Plot of *disease* versus age, with least-squares and logistic regression lines.

Régression logistique

Un peu plus précisément… analytiquement

La courbe sigmoïde sera définie par l'équation:

$$\pi(x) = \frac{1}{1 + e^{-g(x)}}$$

où g(x) est donné par

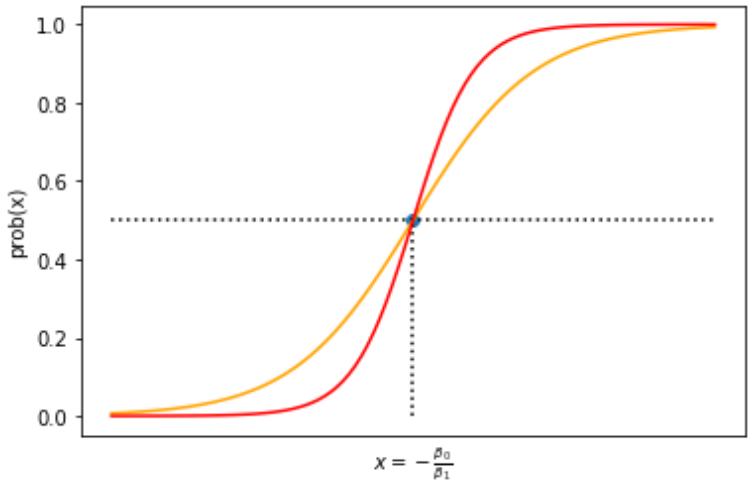
$$g(x) = \beta_0 + \beta_1 x$$

Notez que $\pi(x) \epsilon [0,1] \; \forall x$

et peut donc s'interpréter comme une probabilité!

Régression logistique

Courbe sigmoïde – Quelques particularités



Définition: $\pi(x) = \frac{e^{g(x)}}{1+e^{g(x)}} = \frac{1}{1+e^{-g(x)}}$

Si $g(x) = \beta_0 + \beta_1 x$

Dérivée première: $\frac{d\pi(x)}{dx} = \frac{e^{g(x)}}{\left(1+e^{g(x)}\right)^2}\frac{dg(x)}{dx}$

Dérivée seconde: $\frac{d^2\pi(x)}{dx^2} = \frac{e^{g(x)}}{\left(1+e^{g(x)}\right)^2}\left[-g'' - g'^2\left(1 - \frac{2e^{g(x)}}{1+e^{g(x)}}\right)\right]$

$\pi(x) = \frac{1}{2} \Leftrightarrow g(x)=0$

$\pi(x) = \frac{1}{2} \Leftrightarrow x = -\frac{\beta_0}{\beta_1}$

$\left.\frac{d\pi}{dx}\right|_{\pi=1/2} = \left.\frac{dg}{dx}\right|_{x=?}$

$\left.\frac{d\pi}{dx}\right|_{\pi=1/2} = \beta_1$

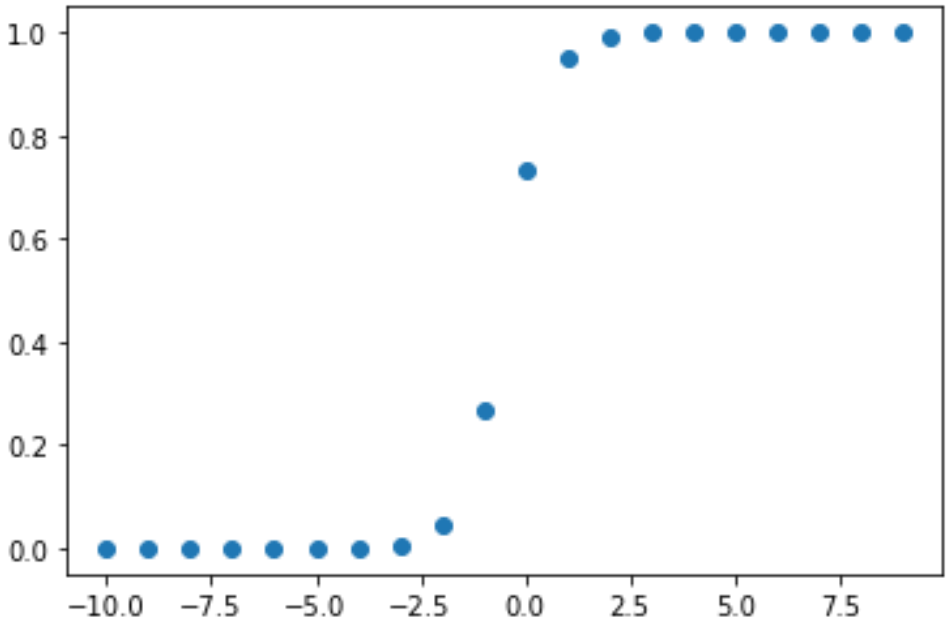
$\left.\frac{d^2\pi(x)}{dx^2}\right|_{\pi=1/2} = -\frac{g''}{4}$

$\left.\frac{d^2\pi(x)}{dx^2}\right|_{\pi=1/2} = 0$

Régression logistique

Exercice 1

- Montrer moi (par une démonstration numérique dans un notebook Jupyter) que les formules présentées dans le slide précédent correspondent bien à une courbe en S, confinée en ordonnée à l'intervalle [0,1].



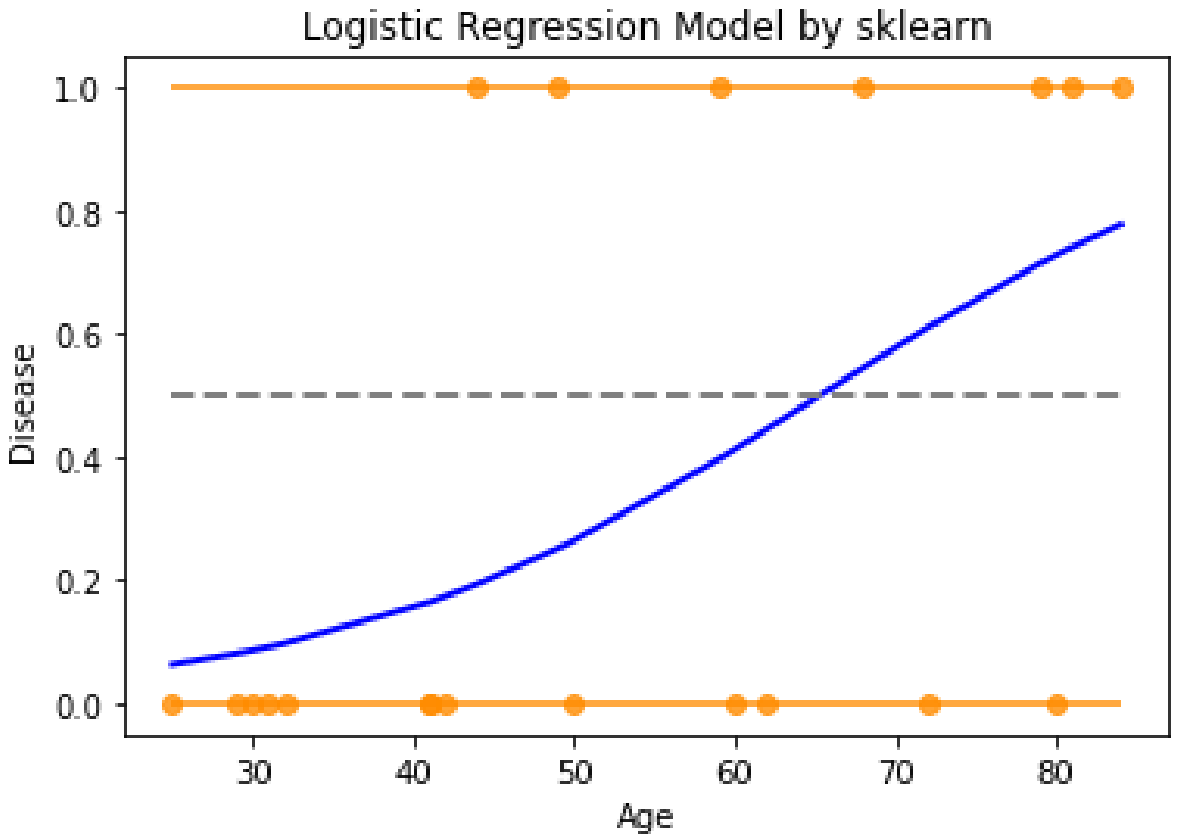
Régression logistique

Unidimensionnelle et continue - Exercice 2

- Référence: Data Mining Methods and Models Daniel Larose (2006) Wiley, Chapter 4, Logistic Regression
- Reproduire dans un notebook Jupyter le nuage de point du graphe présenté dans « Régression logistique – A quoi cela ressemble ? » sur base des données de la p.156 (voir le fichier `disease.txt` sur le portail)
- Utiliser la librairie sklearn pour optimiser un modèle logistique
- Comparer avec les valeurs du modèle annoncées en p.159
- Ajouter la courbe optimale au nuage de point

Régression logistique

Unidimensionelle continue - Exercice 2 – Proposition de solution



Régression logistique

Unidimensionnelle et continue - Exercice 2 suite

- Une fois le modèle mis au point, il peut servir aussi à interpoler et à avoir des probabilités d'être malade pour tous les âges, y compris fractionnaires…
- Ainsi, quelle est la probabilité d'être malade à 50 ans ?
- A 72 ans ?
- Ou de determiner des âges où la probabilité de maladie est de x.
- Ainsi, quel est l'âge où la probabilité est de 0.5 ? Idem pour 0.25? Idem pour 0.75?
- Au niveau des coefficients:
  - beta1 donne directement la pente de la courbe en S au point d'inflexion,
  - beta0 paramétrise (en combinaison avec beta1) le point d'inflexion, à quelle place sur l'axe x, le point d'inflexion se trouve. Ainsi, si beta0 augmente en valeur absolue, le point d'inflexion s'éloignera du zero sur l'axe des x.

Concepts clés

Optimisation de modèle: maximum de vraisemblance (1)

- Le maximum de vraisemblance est un concept clé dans la recherche de modèles non-linéaires optimaux… au sens des probabilités.
- Souvenez-vous de vos cours de statistiques descriptives avec l'optimisation de modèle de régression linéaire et la minimisation de l'erreur (minimum de la somme des carrés des écarts).
- Comme déjà évoqué dans les exercices, ici, dans le cours de fouille de données, nous avons abordé le modèle logistique qui essaie de donner une probabilité d'avoir un positif… c'est une courbe en S.
- Puisque c'est une probabilité, qu'en est-il de la probabilité qu'un échantillon aléatoire de même taille puisse suivre exactement la même répartition entre les deux classes? Et comment cette probabilité peut-elle variée en fonction des paramètres de ce modèle de probabilité?
- C'est là le cœur même de la question!!!

Concepts clés

Optimisation de modèle: maximum de vraisemblance (2)

Dans le cas d'un modèle de classification binaire, l'output du modèle pour un point x_i, sera la probabilité que ce point soit un positif ou $p(x_i)$. De la même façon, nous pourrons déduire la probabilité que ce point soit un négatif par $1 - p(x_i)$. Si toutes ces observations sont indépendantes, la probabilité que notre ensemble de faits $\{x_i\}_i$ soit compatible avec le modèle est donné par sa vraisemblance :

$$vraisemblance\ du\ modèle = \prod_i \left(p(x_i)\right)^{pos(i)} \left(1 - p(x_i)\right)^{neg(i)}$$

où $pos(i)$ vaut 1 si le point i est positif et 0 sinon alors que $neg(i)$ vaut 1 si le point i est négatif et 0 sinon.

Les fonctions *pos(i)* et *neg(i)* sont donc complémentaires l'une de l'autre, autrement dit :

$$pos(i) + neg(i) = 1 \ \forall i$$

avec $pos(i) = 1$ si le point i est positif et 0 sinon.

Concepts clés

Optimisation de modèle: maximum de vraisemblance (3)

Quand nous parlons d'un modèle, nous parlons en général d'une famille de modèle, paramétrisée par $\{\alpha_j\}$. Il s'agira donc ici de trouver, dans toute cette famille, le modèle qui maximisera sa vraisemblance par rapport à l'échantillon qui nous sert de base d'apprentissage, d'optimiser ce modèle - c'est-à-dire l'ensemble des paramètres tel que $\{\alpha_j\}$:

$$\max_{\{\alpha_j\}} \prod_i \left(p_{\{\alpha_j\}}(x_i)\right)^{pos(i)} \left(1 - p_{\{\alpha_j\}}(x_i)\right)^{neg(i)}$$

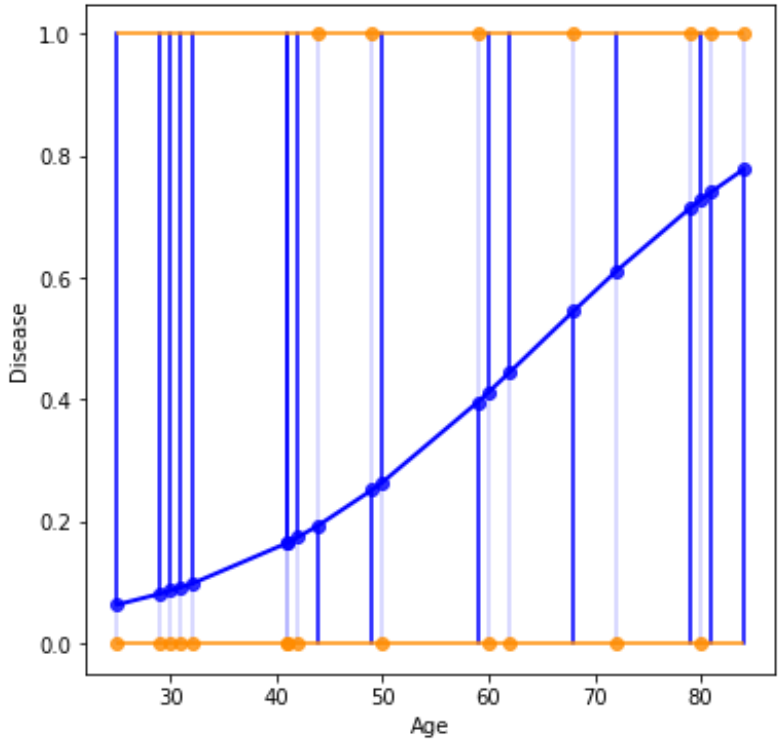
Généralement, on passe au logarithme pour transformer le produit en somme (plus facile à manipuler) pour finalement obtenir le problème suivant :

$$\max_{\{\alpha_j\}} \sum_i \left(pos(i) ln\left(p_{\{\alpha_j\}}(x_i)\right) + neg(i) ln\left(1 - p_{\{\alpha_j\}}(x_i)\right)\right)$$

Concepts clés

Optimisation de modèle: Maximum de vraisemblance (4) - Calcul concret

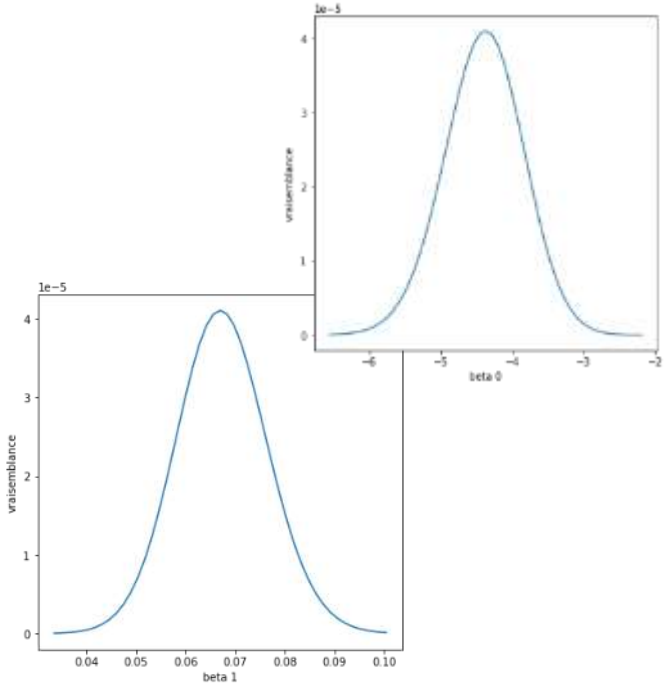
Voir exercice 3 pour une mise en œuvre explicite de l'algo de calcul présenté dans les slides précédents

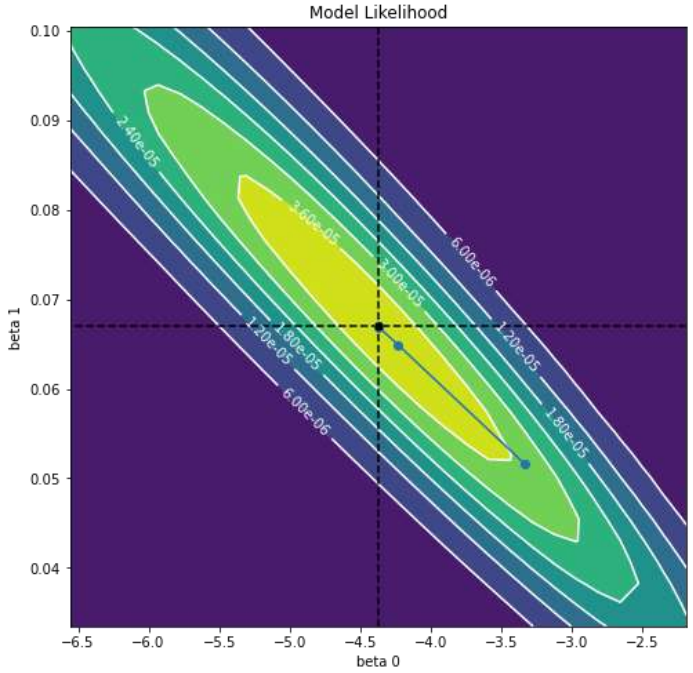


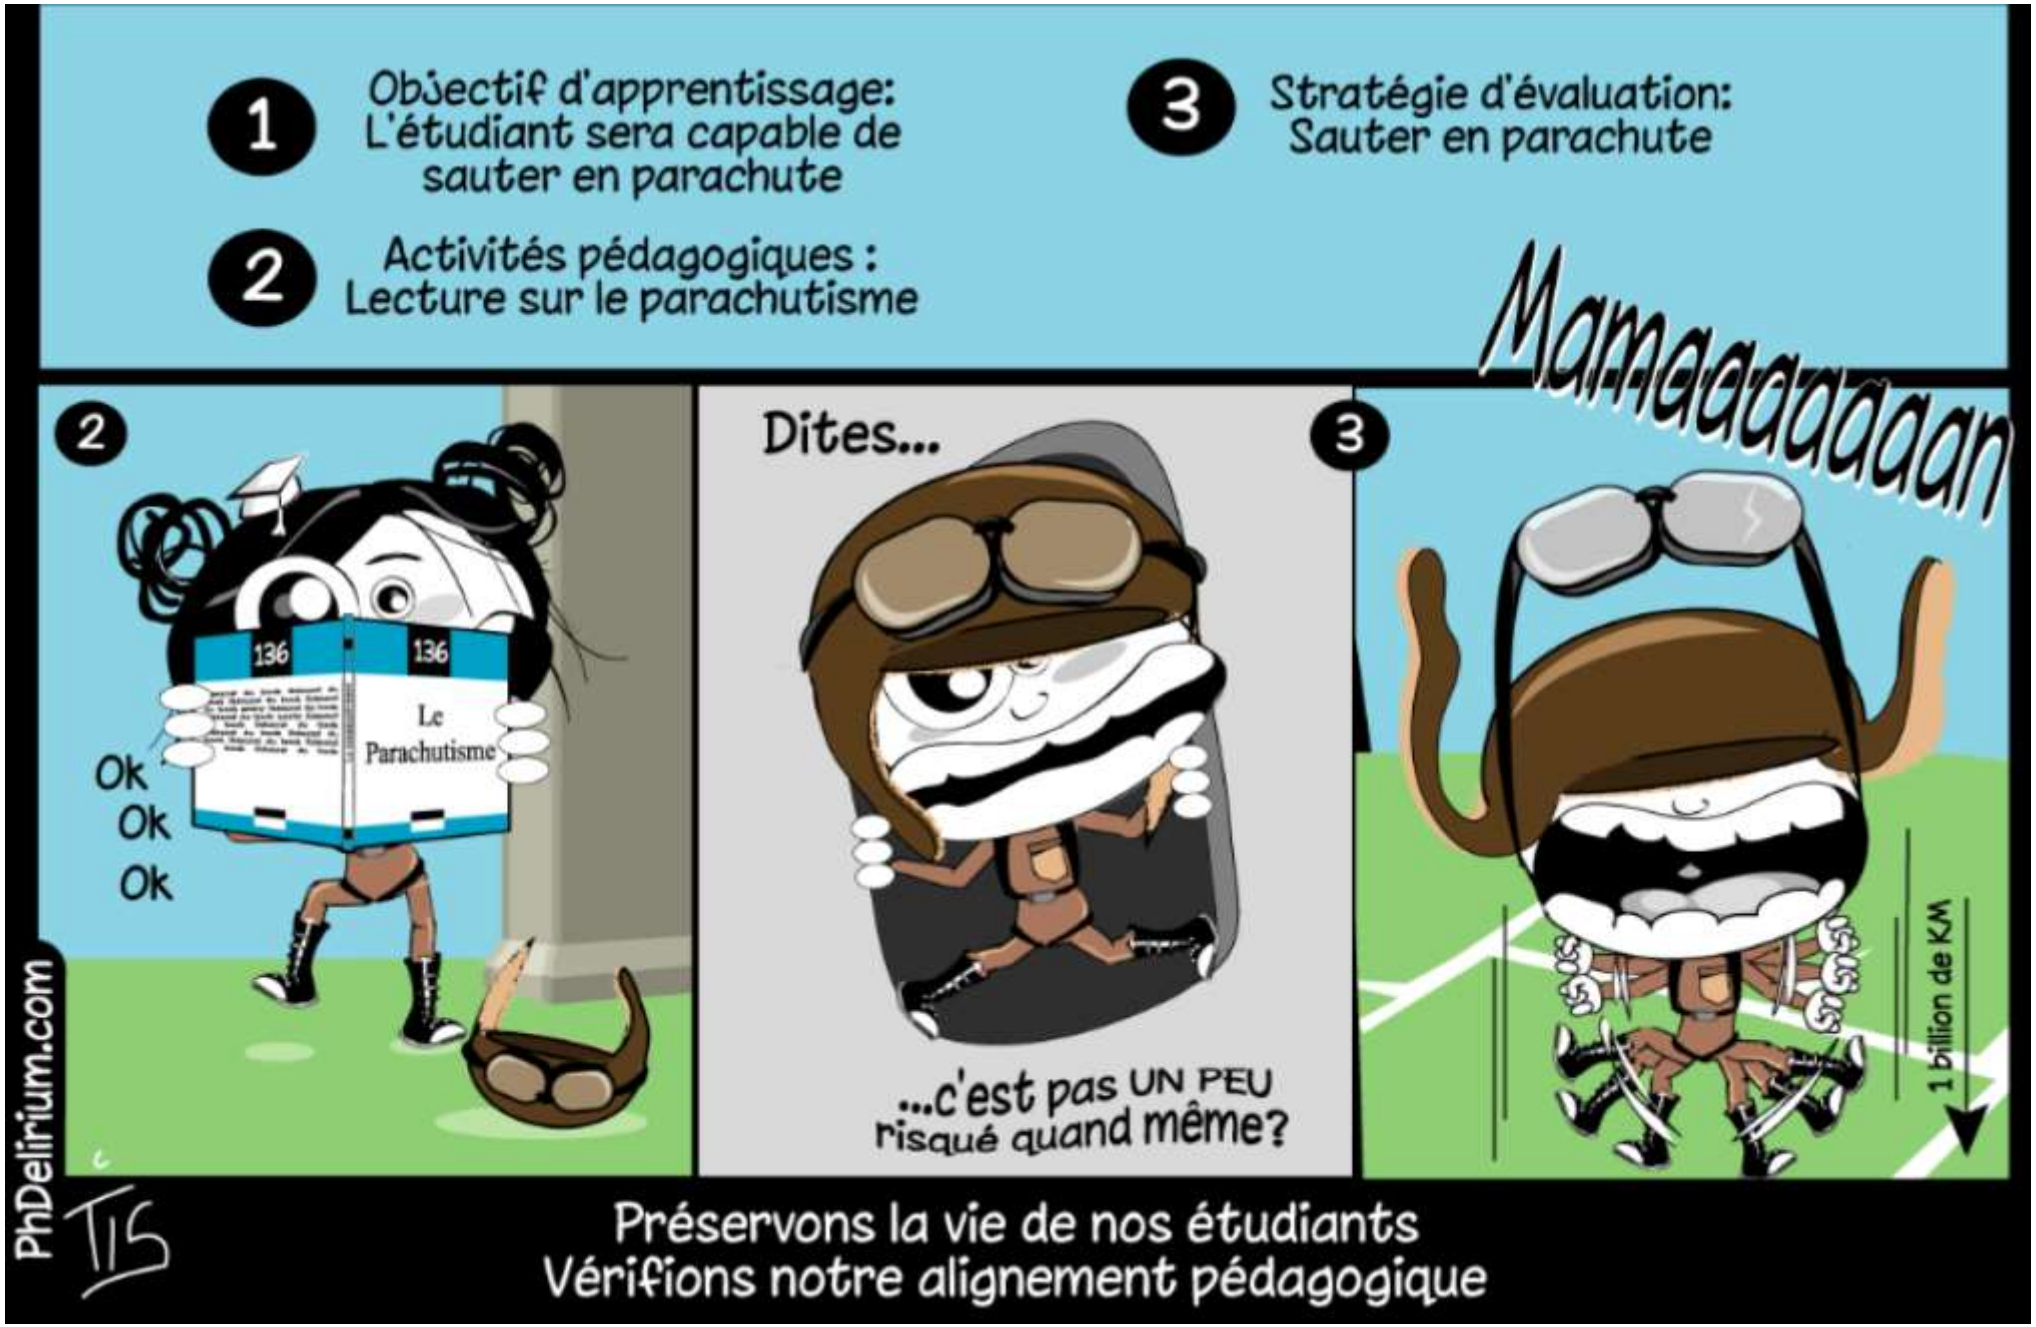
Régression logistique

Unidimensionnelle continue - Exercice 3 – Maximum de vraisemblance

- En repartant de la définition de la courbe logistique, montrer que les valeurs de paramètres obtenues dans l'exercice 2 correspondent bien au modèle de probabilité le plus probable compatible avec les données.






1
Objectif d'apprentissage:
L'étudiant sera capable de sauter en parachute
2
Activités pédagogiques :
Lecture sur le parachutisme
3
Stratégie d'évaluation:
Sauter en parachute
2
136
136
Le Parachutisme
Ok
Ok
Ok
Dites...
...c'est pas UN PEU risqué quand même?
3
Mamaaaaaaan
1 billion de KM
PhDelirium.com
TIS
Préservons la vie de nos étudiants
Vérifions notre alignement pédagogique

Régression logistique

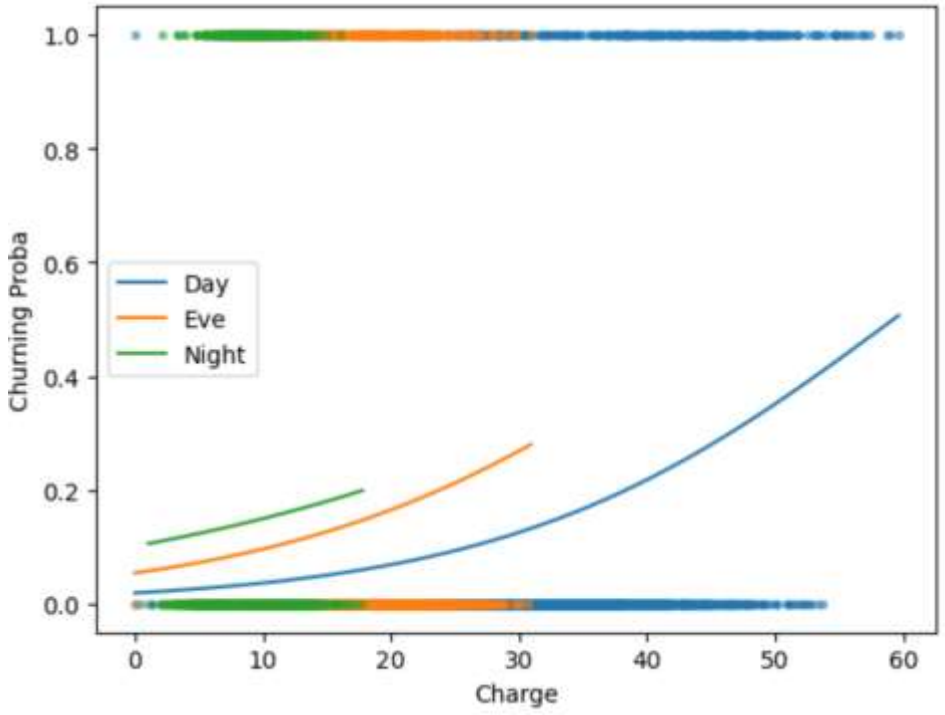
Unidimensionnelle minimale - Exercice 4.1

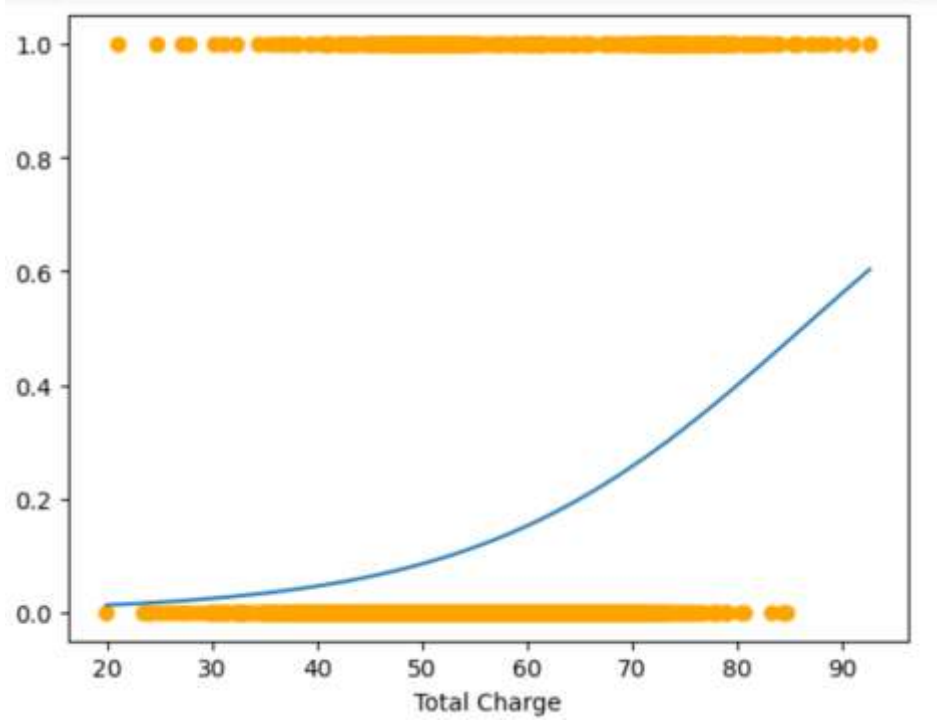
- Référence: Data Mining Methods and Models Daniel Larose (2006) Wiley, Chapter 4, Logistic Regression
- Partant des données de changement d'opérateur téléphonique (churn.txt sur le portail), utiliser la librairie sklearn pour optimiser un modèle logistique (au sens du maximum de vraisemblance) basé, dans un premier temps, sur la seule modalité du nombre d'appel au service clientèle
- Visualiser la probabilité de départ du client déduite de ce modèle en fonction du nombre croissant d'appel au service clientèle.
- Que pouvez-vous déduire ?
- Le modèle obtenu vous semble-t-il vraisemblable ?

Régression logistique

Unidimensionnelle minimale - Exercice 4.2 (suite et fin)

- Refaites la même chose mais cette fois en considérant successivement les montants de facture correspondant aux appels de jours, de soirée et de nuit et finalement le montant total (une modalité à la fois, PAS tout en même temps, j'insiste...)





Rappel: Régression logistique

Slide 18 adapté à n dimensions

La courbe sigmoïde sera définie par l'équation :

$$\pi(x) = \frac{1}{1 + e^{-g(x)}}$$

où $x = [x_1, x_2, \dots, x_n]$ et g(x) est donné par

$$g(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \dots + \beta_n x_n$$

Notez que $\pi(x) \epsilon [0,1] \; \forall x$

et peut donc toujours s'interpréter comme une probabilité !

Régression logistique

Estimation des variations de probabilité

Exercice 4.3 :

- Estimez la moyenne de la facture totale sur tous les clients.
- Quelle sera la probabilité de churning pour un client payant exactement ce montant moyen ?
- Comparez à la proportion de clients partant à la concurrence calculée sur l'ensemble de la population.
- Quelle serait votre conclusion ?
- Quelle sera la probabilité de churning pour un client payant 10% de plus ?
- Cette tendance vous semble-t-elle normale ?
- Idem pour un client payant 2 x plus

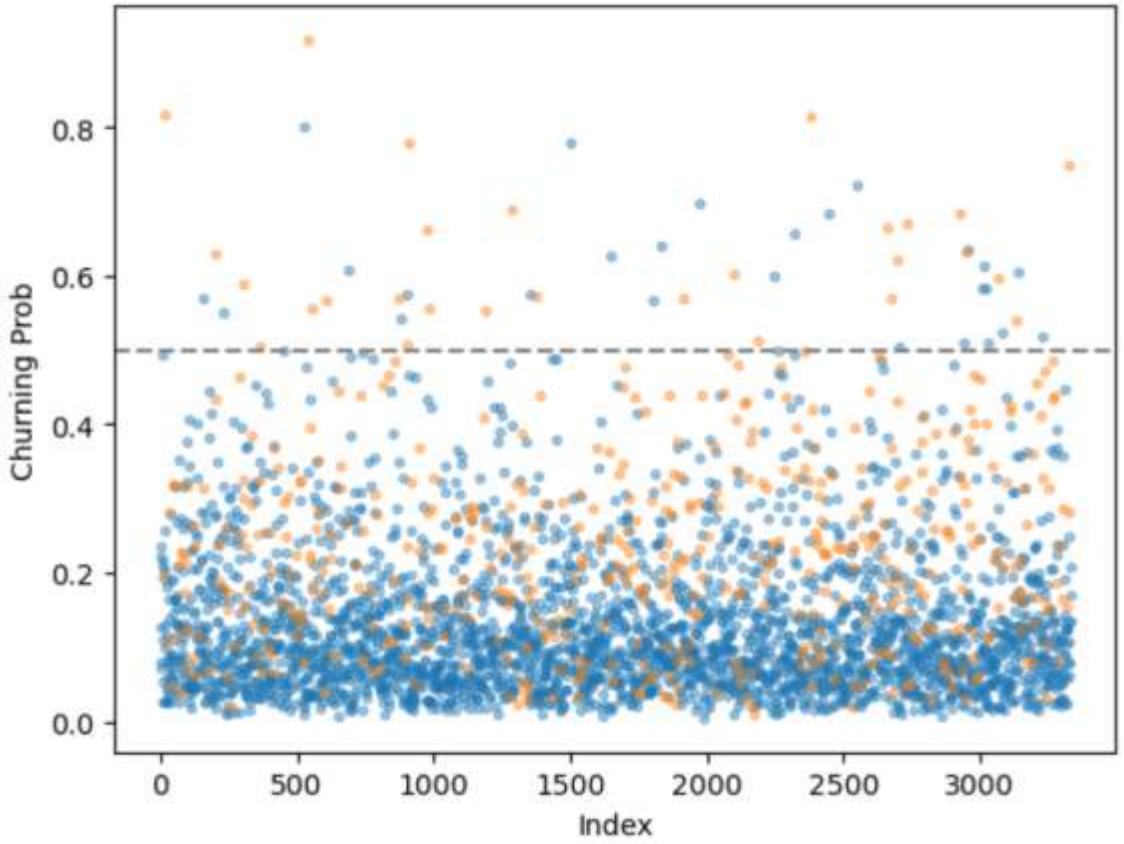
Régression logistique

Exercice 5

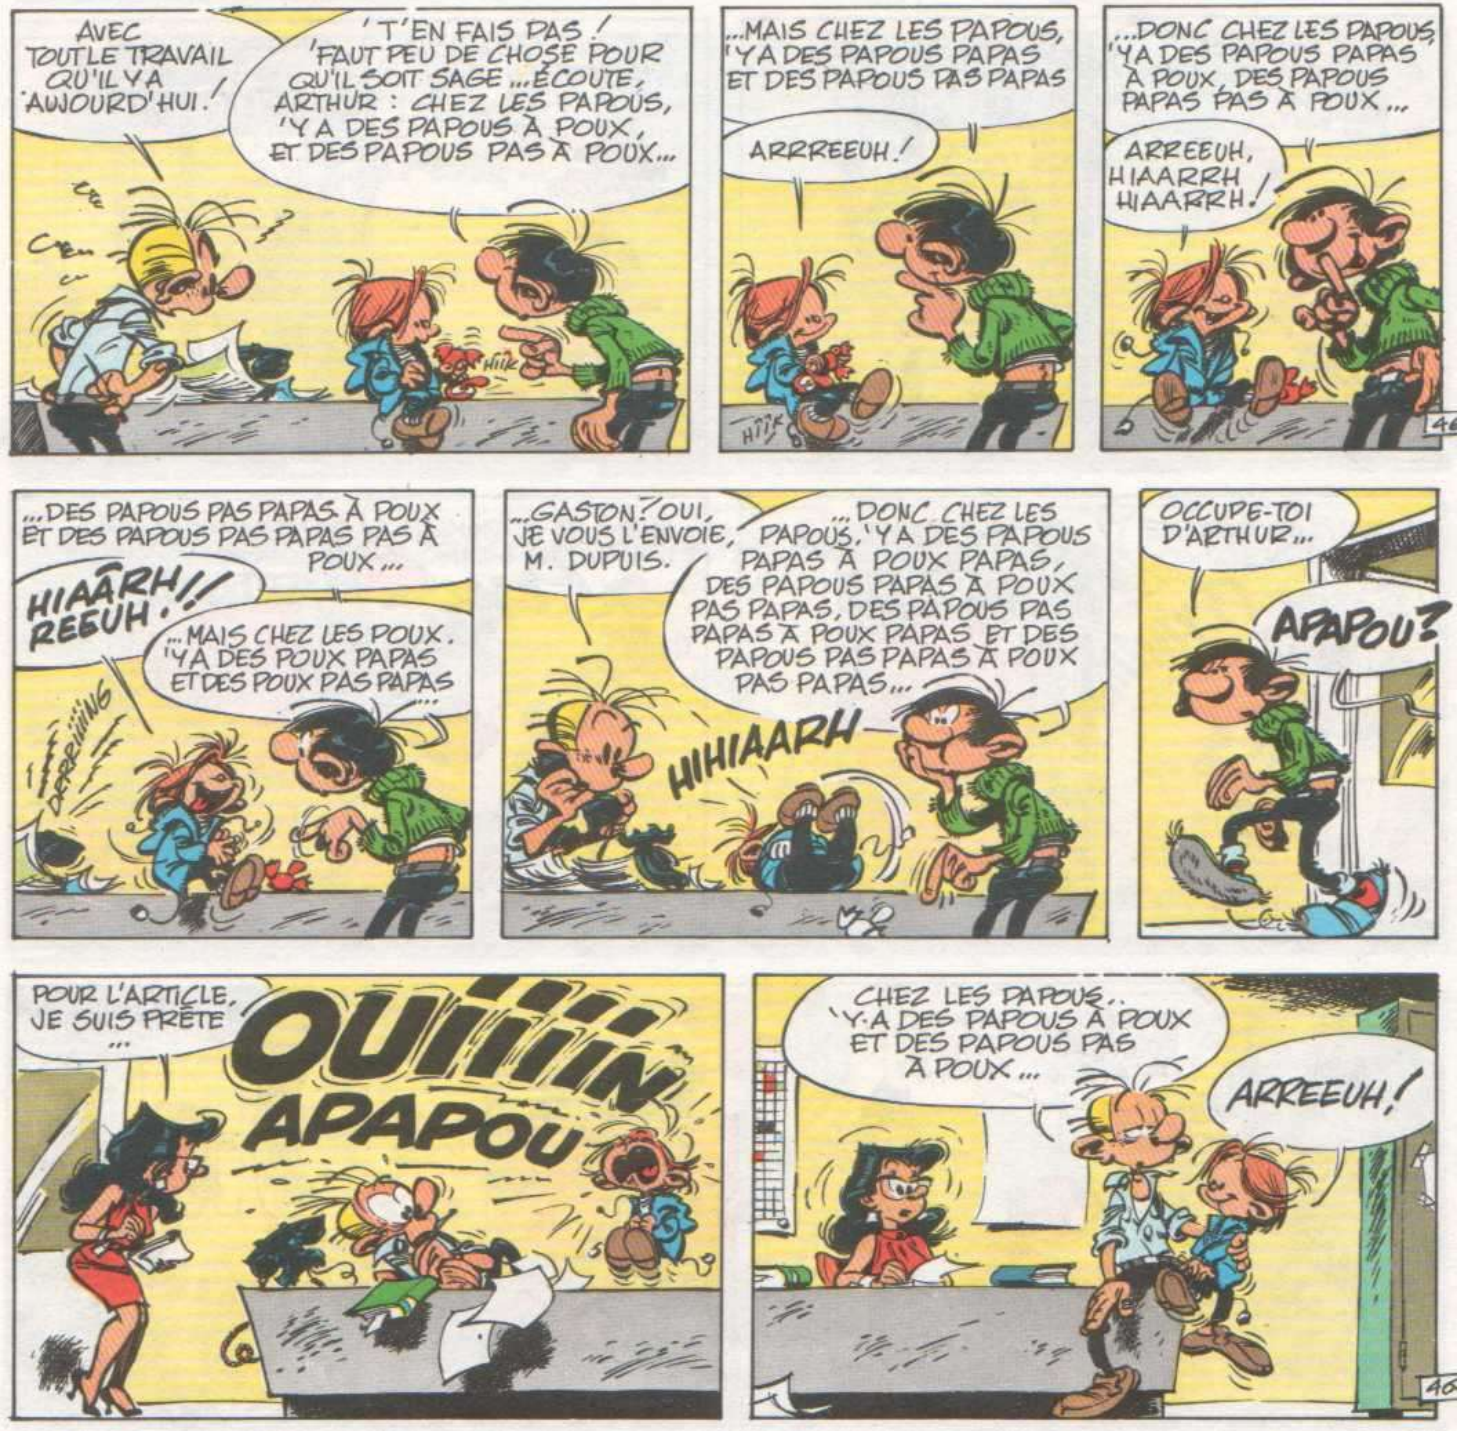
- Même énoncé que l'Exercice 4 mais en considérant l'ensemble des dimensions suivantes: Day Charge, Eve Charge, Night Charge et CustServ Calls
- Représenter l'ensemble des probabilités produites par le modèle en nuage de point
- Appliquons un threshold T de 0.5
- Décidons que tous les clients ayant une probabilité supérieure à T comme prédits comme partant alors qu'à l'inverse, tous les clients ayant une probabilité inférieure à T seront prédits comme restants
- Calculer alors le nombre de **vrais positifs, vrais négatifs, faux positifs et faux négatifs.**
- Que pouvez-vous en conclure ?

Régression logistique

Exercice 5



TP:28 FP:26
FN:455 TN:2824


AVEC TOUT LE TRAVAIL QU'IL Y A AUJOURD'HUI.
T'EN FAIS PAS ! FAUT PEU DE CHOSE POUR QU'IL SOIT SAGE ... ÉCOUTE, ARTHUR : CHEZ LES PAPOUS, Y A DES PAPOUS À POUX, ET DES PAPOUS PAS À POUX...
...MAIS CHEZ LES PAPOUS, Y A DES PAPOUS PAPAS ET DES PAPOUS PAS PAPAS
ARRREEUH !
...DONC CHEZ LES PAPOUS, Y A DES PAPOUS PAPAS À POUX, DES PAPOUS PAPAS PAS À POUX...
ARREEUH, HIAARRH HIAARRH !
...DES PAPOUS PAS PAPAS À POUX ET DES PAPOUS PAS PAPAS PAS À POUX...
HIAARH !! REEUH !
...MAIS CHEZ LES POUX. Y A DES POUX PAPAS ET DES POUX PAS PAPAS...
...GASTON ? OUI, JE VOUS L'ENVOIE, M. DUPUIS.
...DONC CHEZ LES PAPOUS, Y A DES PAPOUS PAPAS À POUX PAPAS, DES PAPOUS PAPAS À POUX PAS PAPAS, DES PAPOUS PAS PAPAS À POUX PAPAS ET DES PAPOUS PAS PAPAS À POUX PAS PAPAS...
HIHIAARH
OCCUPE-TOI D'ARTHUR...
APAPOU ?
POUR L'ARTICLE, JE SUIS PRÊTE...
OUIIIN APAPOU
CHEZ LES PAPOUS.. Y A DES PAPOUS À POUX ET DES PAPOUS PAS À POUX...
ARREEUH !

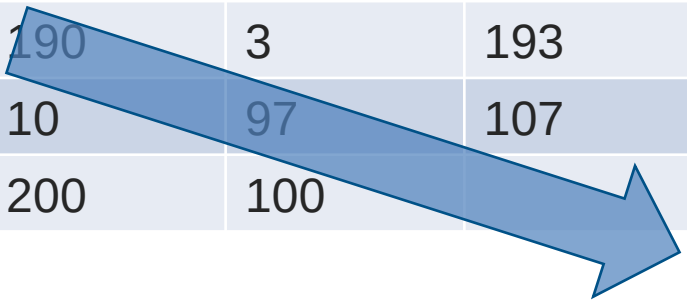
Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Exemple type: détecteur de spam

Prenons un détecteur de spam dont les résultats de classification sur un échantillon de 300 courriers électroniques (200 courriels normaux et 100 pourriels) sont résumés dans le tableau ci-dessous:

		Classe réelle		
		Normal	**Pourriel**	**Totaux**
Classe estimée	**Normal**	190	3	193
	Pourriel	10	97	107
	Totaux	200	100	



Bon classificateur si la diagonale domine!

Fouille de données – Théorie – Concepts clés

Classificateurs binaires – Matrice de confusion

		Classe réelle	
		Positive	**Négative**
Classe estimée	**Positive**	Vrai Positif **VP**	Faux Positif **FP**
	Négative	Faux Négatif **FN**	Vrai négatif **VN**

Deux qualificateurs (parmi bien d'autres):

- **Sensibilité** (ou **Rappel**): probabilité que l'estimateur soit positif sur la classe des positifs:

$$\textbf{\textit{Sensibilité}}: \frac{VP}{VP + FN}$$

- **Spécificité** (ou **Sélectivité**): probabilité d'un test négatif sur la classe négative:

$$\textbf{\textit{Spécificité}}: \frac{VN}{FP + VN}$$

Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Pour notre exemple de spam, on aura les valeurs suivantes:

		Classe réelle	
		Normal	**Pourriel**
Classe estimée	**Normal**	190	3
	Pourriel	10	97
		Sensibilité: 95%	**Spécificité:** 97%

Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Pour l'exercice 5, on aura les valeurs suivantes:

		Classe réelle	
		Partant	**Restant**
Classe estimée	**Partant**	28	26
	Restant	455	2824
		Sensibilité: 0,06 ou 6%	**Spécificité:** 0,99 ou 99%

Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Plus le test est sensible, moins il produira de faux (résultats) négatifs

Plus il est spécifique, moins il produira de faux (résultats) positifs

Gardons la même famille de modèle mais varions le seuil, la valeur de T dans l'intervalle [0,1]:

- T=0… tout le monde est positifs… on ne rate rien mais du coup on a beaucoup de faux positifs => le test n'est pas du tout spécifique
- T=1… tout le monde est négatifs… et donc beaucoup de faux négatifs => le test n'est pas sensible
- T=0.5… bof bof. Dans ces conditions, test très peu sensible mais bien spécifique
- T optimal ?

Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Le ‘bon’ compromis entre sensibilité et spécificité n’est pas toujours simple à optimiser…

Surtout dans des domaines très sensibles ☺ comme la santé.

Ainsi, lisez les deux références, reprises sur Moodle:

Tests sérologiques : les coulisses d'une validation controversée à 7 millions (enquête)

Thierry Denoël

Le Vif 16 juin 2020

Coronavirus: un million de tests sérologiques commandés par la Belgique ne sont pas fiables

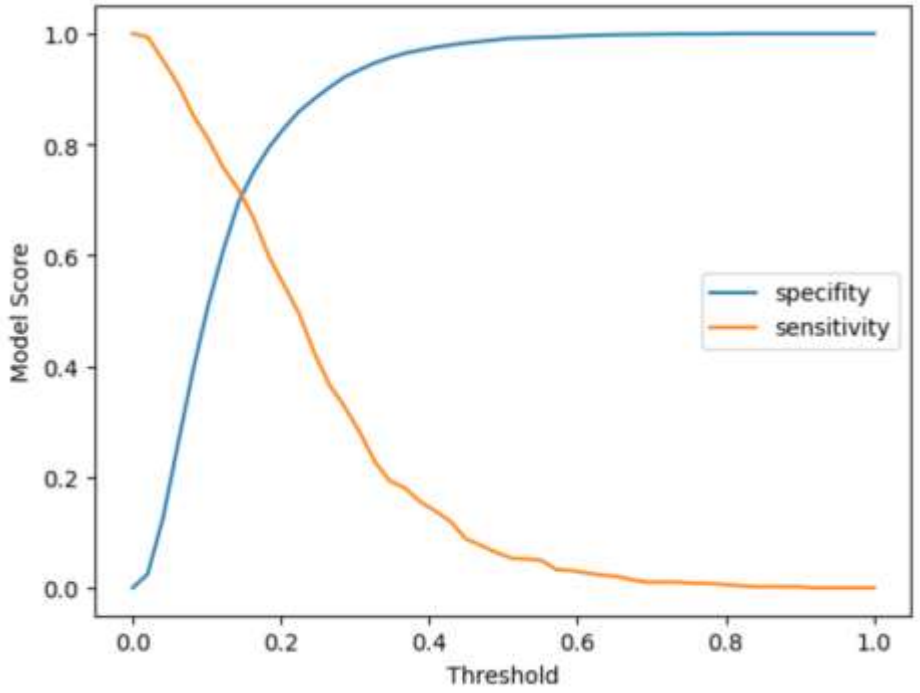
Thierry Denoël

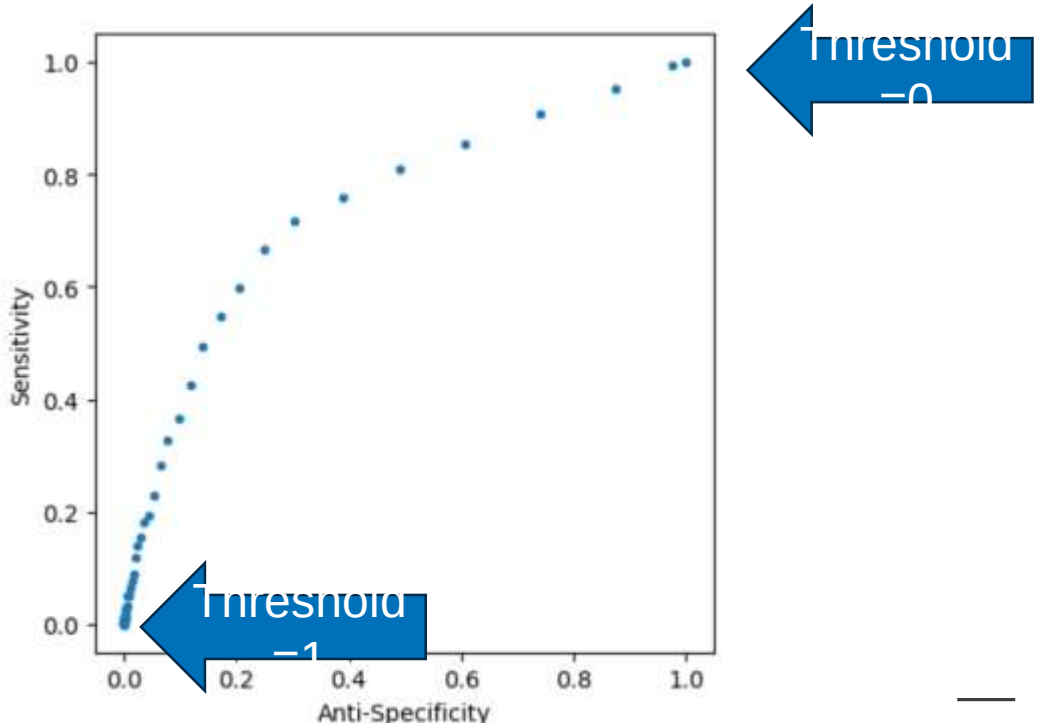
Le Vif 19 août 2020

Fouille de données – Théorie – Concepts clés

Classificateurs binaires

Pour l'exercice 6, modifier le seuil de l'exercice précédent et reporter les valeurs de la sensibilité et de la spécificité dans un même graphe





Fouille de données – Théorie – Concepts clés

Qualification de famille de modèle (1)

- Nous avons des modèles continus optimaux donnant une valeur scalaire en fonction de tous les paramètres d'input (toutes les modalités) avec une contrainte forte: plus cette valeur est élevée plus la probabilité d'être positif est haute (évident si la valeur en question est **la** probabilité d'être positif mais ceci fonctionne aussi pour beaucoup d'autres fonctions, non strictement limitées à l'intervalle [0,1]).

- En fonction d'un seuil pris sur l'image du domaine de cette fonction, on aura un modèle de classification binaire que l'on peut évaluer, en pensant à la population totale.

- Exemple concret: un modèle logistique optimisé sur base du critère de maximum de vraisemblance + un seuil sur [0;1] = modèle de classification binaire

Fouille de données – Théorie – Concepts clés

Qualification de famille de modèle (2)

- Que peut-on dire sur la famille complète des modèles binaires obtenus en ne modifiant que le seuil de discrimination sur l'intégralité du spectre des possibles (l'image du domaine)?

  - Si on place le seuil au maximum possible: toute la population sera classée comme négative => pas grande utilité ☺
  - Si on place le seuil au minimum: toute la population sera classée comme positive => on ne loupe rien ☺ mais on n'a aucune discrimination

- On voit donc que l'utilité du modèle binaire évoluera en fonction du seuil qui le définira… analysons cela d'un peu plus près

Régression logistique

Caractérisation de la réponse d'un modèle en fonction du seuil

Exercice 7

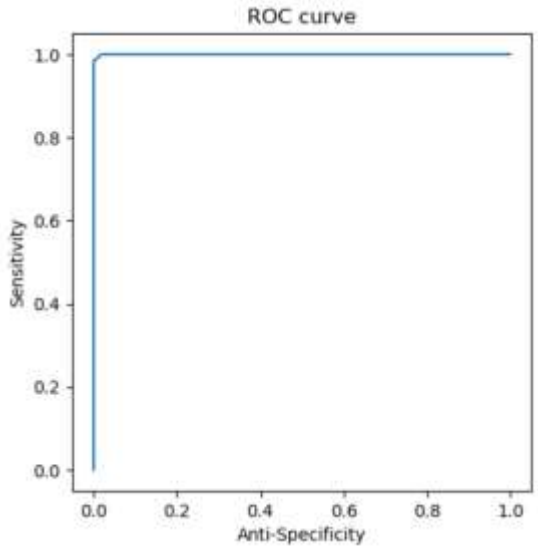
Partant de l'exercice 4:

- Transformer les deux dimensions catégorielles binaires (dimensions booléennes) VMail Plan et Int'l Plan en dimensions entières
- Ajouter ces deux dimensions transformées au modèle
- Représenter la valeur du modèle optimum pour l'ensemble des clients, ventilé suivant leur type.
- Construire la matrice de confusion de ce modèle pour un seuil de 0.5 sur la valeur du modèle.
- Comment évolue cette matrice de confusion si on choisit un autre seuil?
- Faite une représentation de l'évolution de la sensibilité en fonction de l'anti-spécificité (complément à 1 de la spécificité) pour un seuil évoluant sur l'intervalle [0,1].
- Que faudrait-il pour que le modèle soit considéré comme "parfait"?

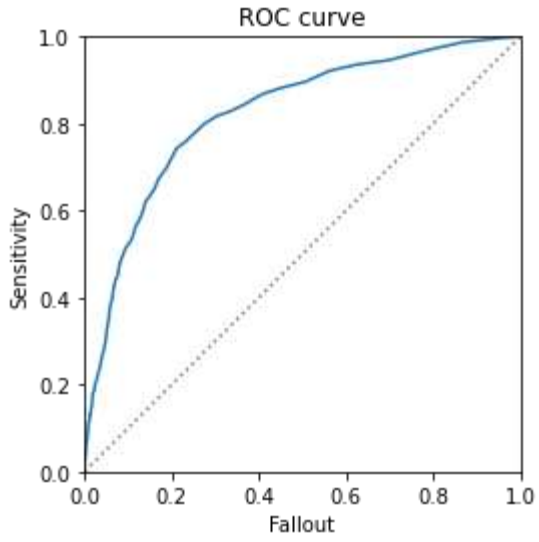
Régression logistique

Caractérisation de la réponse d'un modèle en fonction du seuil

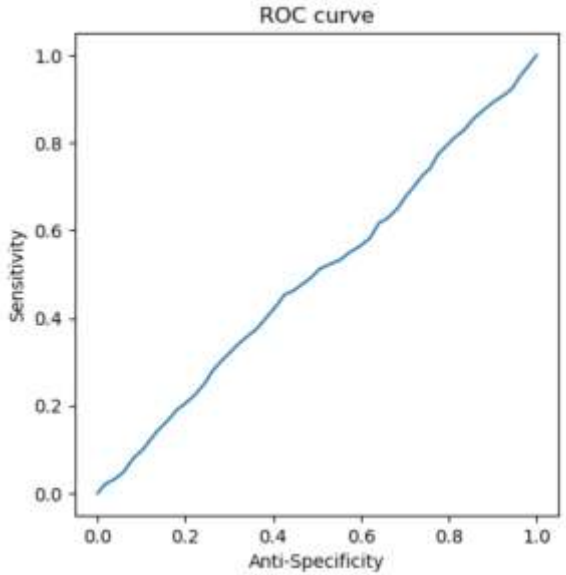
Exercice 7



Modèle parfait:
AUC = 1.000



Modèle logistique optimal:
AUC = 0.817



Le plus mauvais des modèles: AUC = 0.497

Régression logistique

AUC inférieur à 0.5

Nous avons vu dans le slide précédent, que le pur hasard (pas vraiment un modèle très malin donc ☺) nous donne une AUC de 0.5.

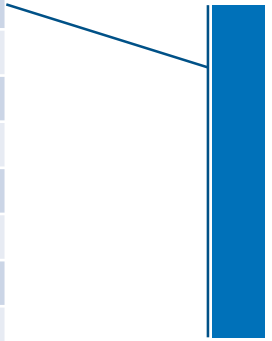
Cela veut dire que c'est plutôt l'éloignement de cette valeur de 0.5 qui nous donne la qualité d'un modèle.

Ainsi, un modèle logistique avec AUC de 0.3 peut être vu, en inversant les conclusions (les positifs deviennent des négatifs et réciproquement) comme un modèle d'AUC égale à 0.7, ce qui n'est pas si mal.

Par contre, un modèle logistique d'AUC de 0.49 reste assez mauvais puisque, en inversant les outputs, nous n'aurons qu'une AUC de 0.51 bien trop proche du pur hasard!!!

Construction de la courbe ROC – Modèle typique

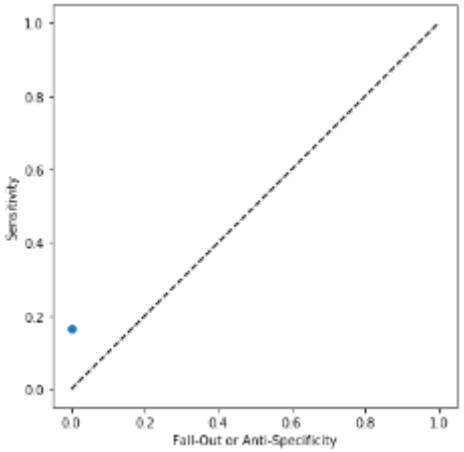
Individu	Score (modèle)	Classe (réalité)
1	1.00	+
2	0.97	+
3	0.91	+
4	0.86	-
5	0.85	-
6	0.74	+
7	0.72	-
8	0.68	-
9	0.63	-
10	0.57	+
11	0.51	-
12	0.46	+
13	0.43	-
14	0.37	-
15	0.31	-
16	0.29	-
17	0.22	-
18	0.19	-
19	0.17	-
20	0.04	-



Seuil: 1.00

		Réalité		
		+	-	Total
Modèle	+	1	0	1
	-	5	14	19
	Total	6	14	20

TPR = 1/6 = 0.16
FPR = 0/14 = 0.00



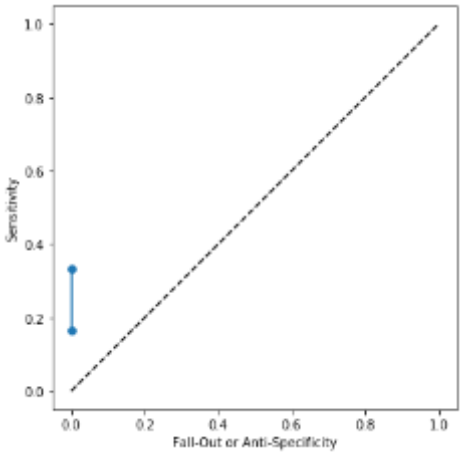
Construction de la courbe ROC – Modèle typique

Individu	Score (modèle)	Classe (réalité)
1	1.00	+
2	0.97	+
3	0.91	+
4	0.86	-
5	0.85	-
6	0.74	+
7	0.72	-
8	0.68	-
9	0.63	-
10	0.57	+
11	0.51	-
12	0.46	+
13	0.43	-
14	0.37	-
15	0.31	-
16	0.29	-
17	0.22	-
18	0.19	-
19	0.17	-
20	0.04	-

Seuil: 0.97

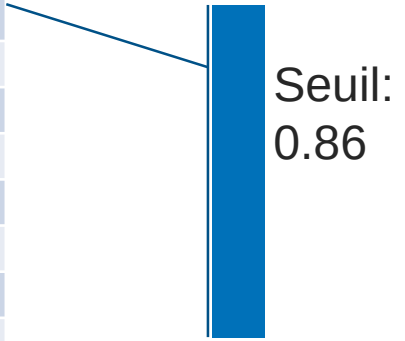
		Réalité		
		+	-	Total
Modèle	+	2	0	2
	-	4	14	18
	Total	6	14	20

TPR = 2/6 = 0.33
FPR = 0/14 = 0.00



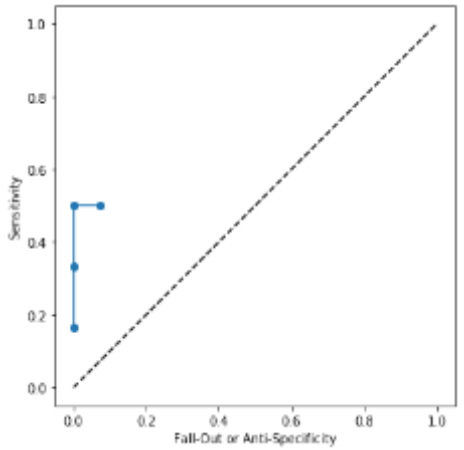
Construction de la courbe ROC – Modèle typique

Individu	Score (modèle)	Classe (réalité)
1	1.00	+
2	0.97	+
3	0.91	+
4	0.86	-
5	0.85	-
6	0.74	+
7	0.72	-
8	0.68	-
9	0.63	-
10	0.57	+
11	0.51	-
12	0.46	+
13	0.43	-
14	0.37	-
15	0.31	-
16	0.29	-
17	0.22	-
18	0.19	-
19	0.17	-
20	0.04	-



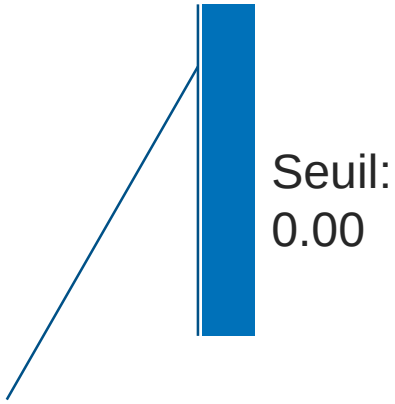
		Réalité		
		+	-	Total
Modèle	+	3	1	4
	-	3	13	16
	Total	6	14	20

TPR = 3/6 = 0.50
FPR = 1/14 = 0.07

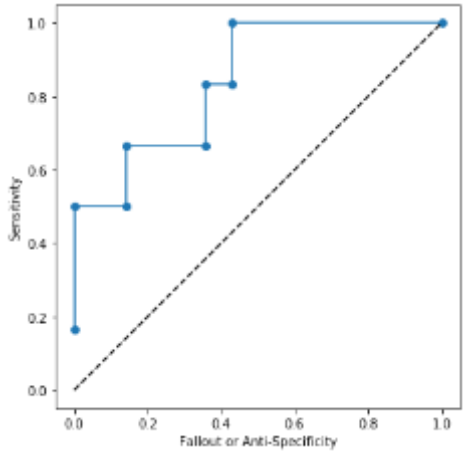


Construction de la courbe ROC – Modèle typique

Individu	Score (modèle)	Classe (réalité)
1	1.00	+
2	0.97	+
3	0.91	+
4	0.86	-
5	0.85	-
6	0.74	+
7	0.72	-
8	0.68	-
9	0.63	-
10	0.57	+
11	0.51	-
12	0.46	+
13	0.43	-
14	0.37	-
15	0.31	-
16	0.29	-
17	0.22	-
18	0.19	-
19	0.17	-
20	0.04	-



Seuil: 0.00



		Réalité		
		+	-	Total
Modèle	+	6	14	20
	-	0	0	0
	Total	6	14	20

Tracé optimal = output de sklearn

TPR = 6/6 = 1.00
FPR = 14/14 = 1.00

Construction de la courbe ROC – Calcul de l'AUC

Individu	Score (modèle)	Classe (réalité)	#- devant un +
1	1.00	+	0
2	0.97	+	0
3	0.91	+	0
4	0.86	-	0
5	0.85	-	0
6	0.74	+	2
7	0.72	-	0
8	0.68	-	0
9	0.63	-	0
10	0.57	+	5
11	0.51	-	0
12	0.46	+	6
13	0.43	-	0
14	0.37	-	0
15	0.31	-	0
16	0.29	-	0
17	0.22	-	0
18	0.17	-	0
19	0.19	-	0
20	0.04	-	0

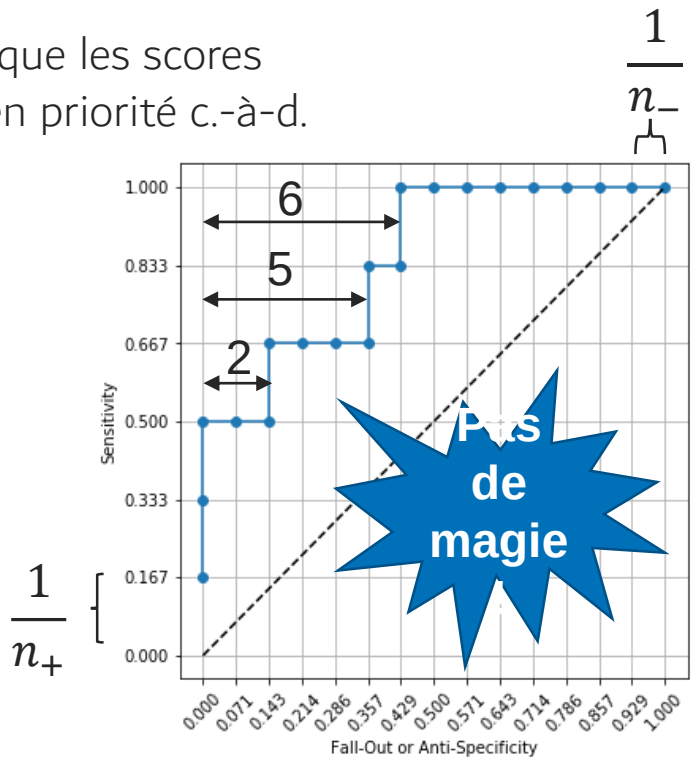
Principe:

- Trier les individus selon un score décroissant.
- Pour chaque « + », compter le nombre de « - » qui le précède.
- Dans notre contexte, on souhaite que les scores élevés soient attribués aux « + » en priorité c.-à-d. les « + » sont précédés de « - ».

$$swaps = 0 + 0 + 0 + 2 + 5 + 6 = 13$$

$$AUC = 1 - \frac{swaps}{n_+ n_-}$$

$$= 1 - \frac{13}{6*14} = 0.8452$$



Fouille de données – Théorie – Concepts clés

Classificateurs binaires – Liste des principales caractéristiques

		True condition				
	Total population	Condition positive	Condition negative	Prevalence = $\frac{\Sigma \text{ Condition positive}}{\Sigma \text{ Total population}}$	Accuracy (ACC) = $\frac{\Sigma \text{ True positive} + \Sigma \text{ True negative}}{\Sigma \text{ Total population}}$	
Predicted condition	Predicted condition positive	**True positive**, Power	**False positive**, Type I error	Positive predictive value (PPV), Precision = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Predicted condition positive}}$	
	Predicted condition negative	**False negative**, Type II error	**True negative**	False omission rate (FOR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Predicted condition negative}}$	
		True positive rate (TPR), Recall, Sensitivity, probability of detection = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR−}}$	**F_1 score** = $\frac{2}{\frac{1}{\text{Recall}} + \frac{1}{\text{Precision}}}$
		False negative rate (FNR), Miss rate = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Condition negative}}$	Negative likelihood ratio (LR−) = $\frac{\text{FNR}}{\text{TNR}}$		

Ne soyons pas confus ☺

Source: https://en.wikipedia.org/wiki/Confusion_matrix

Courbe ROC – Seuil optimal

Caractérisation de la réponse d'un modèle en fonction du seuil

Exercice 8

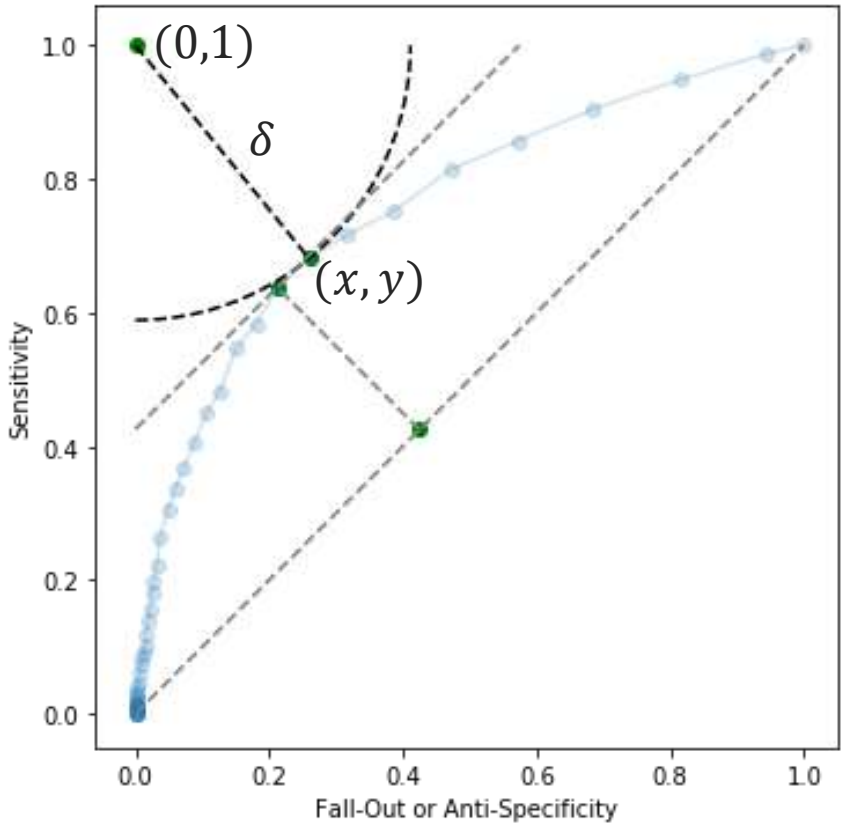
Partant de l'exercice 7:

- Pour la famille de modèle logisitique optimal, caluler l'anti-spécificité et la sensibilité pour un ensemble de thresholds, T, équipartis sur l'intervalle [0,1]
- Pour chaque valeur de T, déterminer la distance au point représentant un modèle parfait situé en (0,1) (coin supérieur gauche).
- Trouver le threshold optimum correspondant au point de la courbe ROC la plus proche de modèle parfait.
- Faite de même en considérant la distance à la diagonale et ici, en maximisant cette distance.
- Trouvez-vous le même threshold optimal ? Commentez ?

Courbe ROC – Seuil optimal

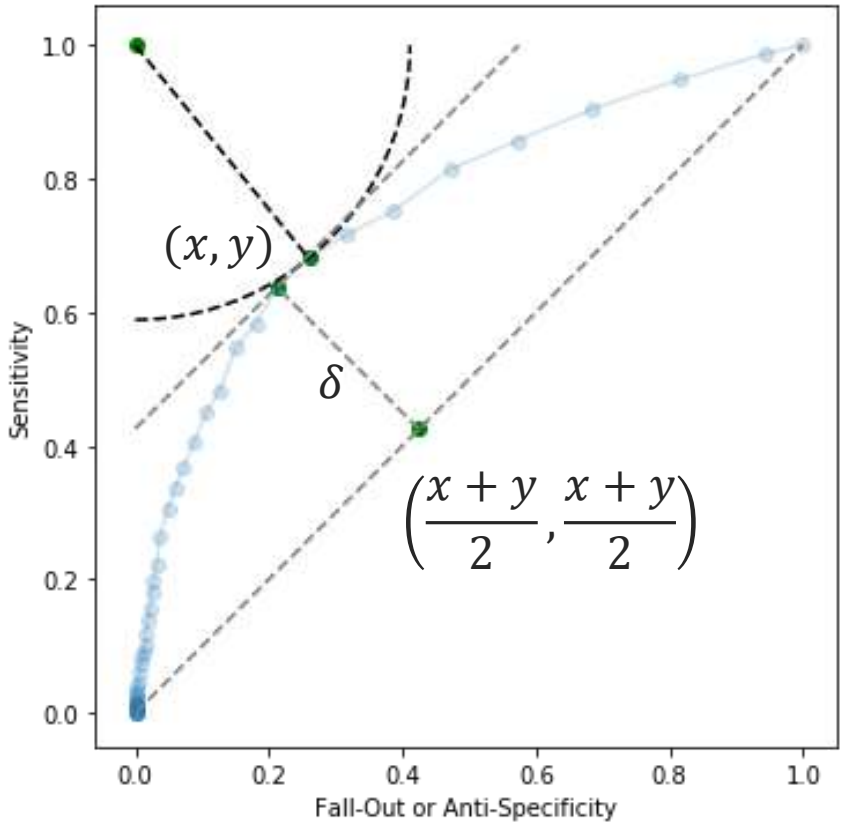
1. Associé au point de la courbe ROC le plus près du modèle parfait [0,1]

$$\delta = \sqrt{x^2 + (y-1)^2}$$



Courbe ROC – Seuil optimal

2. Associé au point de la courbe ROC le plus éloigné du modèle hasardeux 'parfait'



$$\delta = \frac{\sqrt{2}}{2}|x - y|$$

Feature Selection – Principe d'Occam (1)

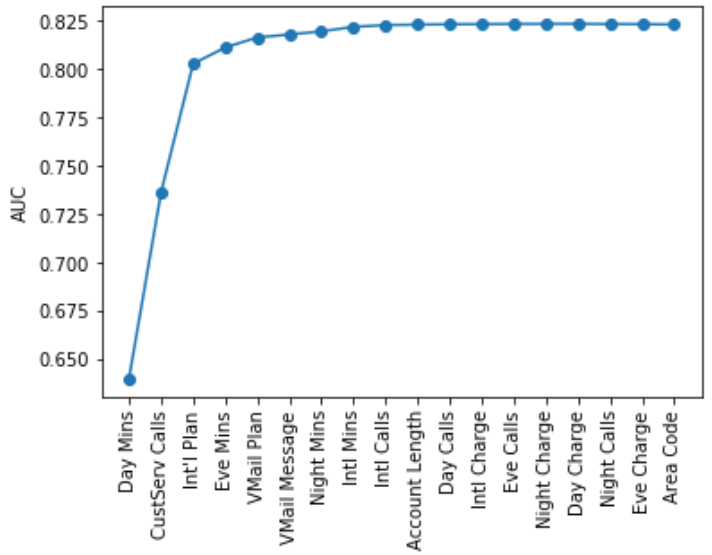
Exercice 9

- Repartant de l'ensemble des dimensions utilisées dans l'exercice 7, il s'agira ici de s'efforcer de construire une suite de famille de modèle, de plus en plus efficaces, de plus en plus discriminatoires, ayant des AUCs croissants.
- On partira d'un ensemble vide et on ajoutera la dimension qui augmente le plus l'AUC. Puis partant de ce modèle à une dimensions on ajoutera la dimension qui augmente le plus l'AUC et ainsi de suite.
- Il s'agira de représenter le graphe de l'AUC en fonction des dimensions successivement ajoutées au modèle logistique.

Feature Selection – Principe d'Occam (2)

Exercice 9 (suite)

- Principe du rasoir d'Occam (ou Ockam): pourquoi faire compliqué lorsque quelque chose de simple marche déjà pas si mal?



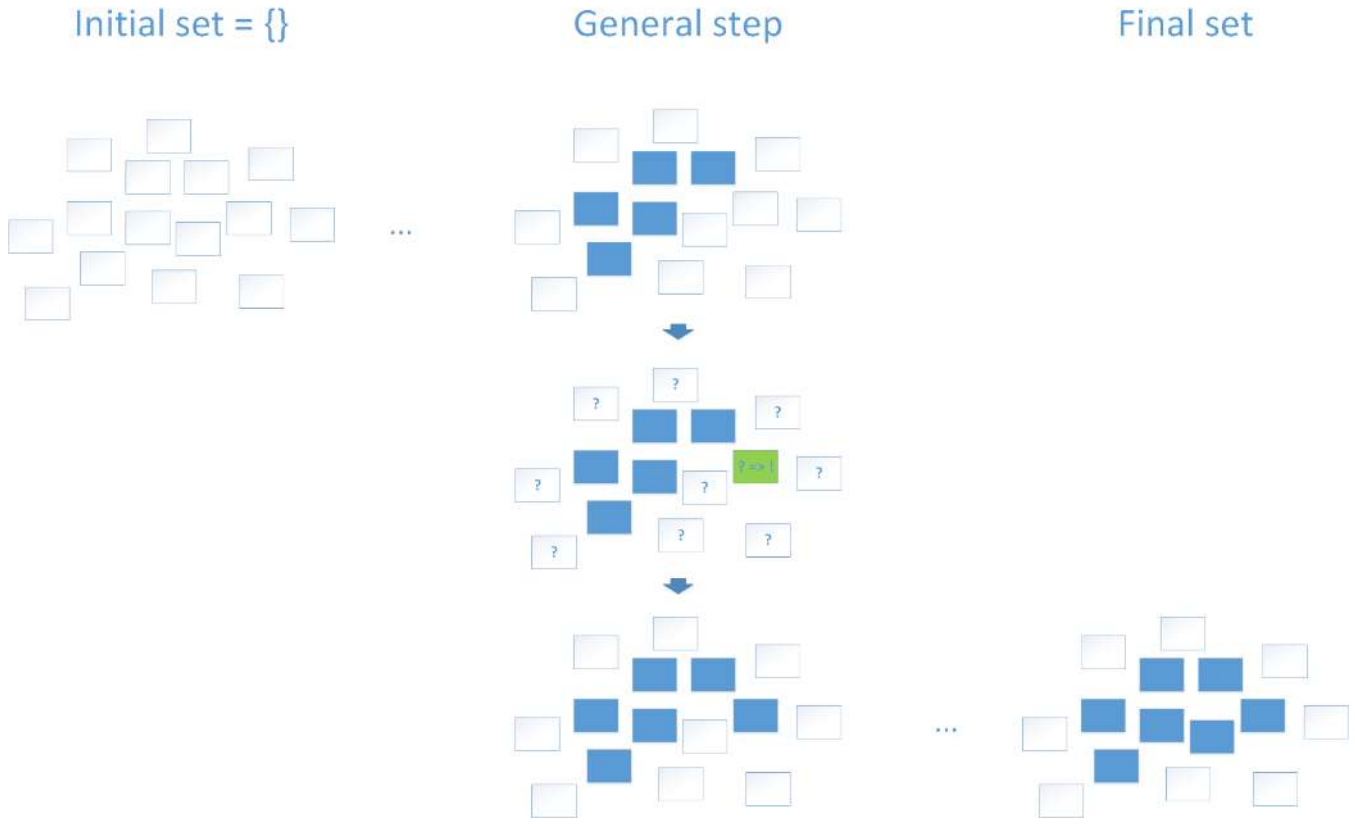
99% de l'AUC sont obtenus avec seulement 5 variables

- KISS: Keep It Simple, Stupid… if it's working ☺

Feature Selection

Par accumulation (Forward)

- **Etape générale:**
  - Explorer tous les ensembles contenant l'ensemble de référence actuel + 1 dimension
  - Calculer les scores (par exemple, l'AUC) et trouver la dimension qui augmente le plus le score de l'ensemble de référence
  - Ajouter cette dimension à l'ensemble de référence
- **Etape initiale:** l'ensemble de référence est vide
- **Sortie** lorsque toutes les dimensions disponibles ont été intégrées à l'ensemble de référence ou lorsque le score ne peut que décroître

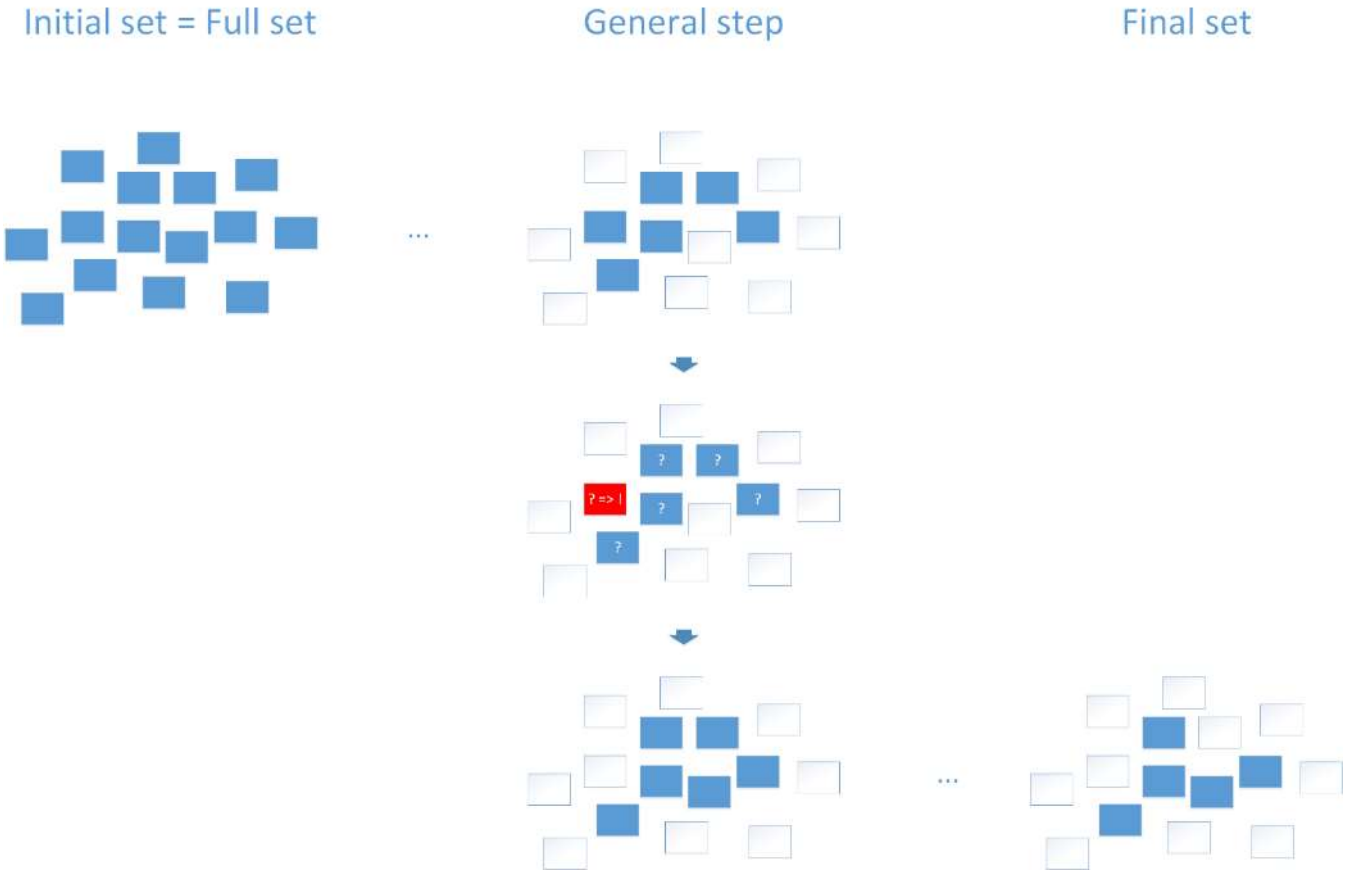


Feature Selection

Par diminution (Backward)

- Noter qu'il est tout à fait possible d'envisager l'algorithme opposé qui partirait de l'ensemble de toutes les dimensions et qui, petit à petit, retrancherait de l'ensemble des dimensions sélectionnées celle qui diminuerait le moins le score d'AUC (dans un premier temps, augmenterait le plus le score d'AUC) jusqu'à une éventuelle stabilisation voire une diminution si on continue à retirer des dimensions.

- **Attention**: rien ne dit que l'ensemble optimal pour cet algorithme sera équivalent au résultat de l'algorithme précédent!!!



Exercice récapitulatif sur les modèles de classification

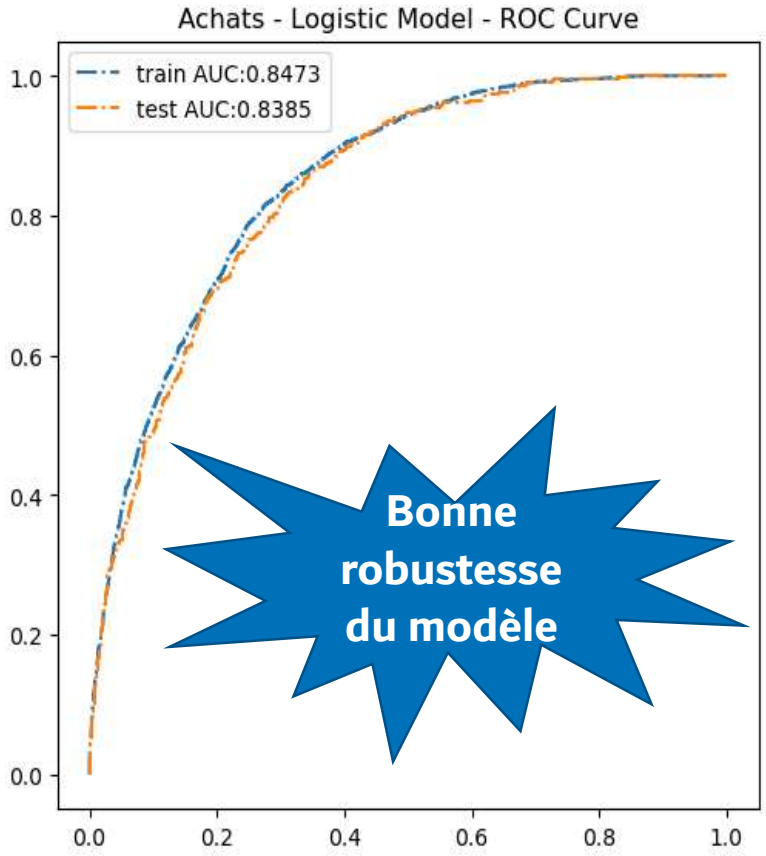
Examen janvier 2018 (1)

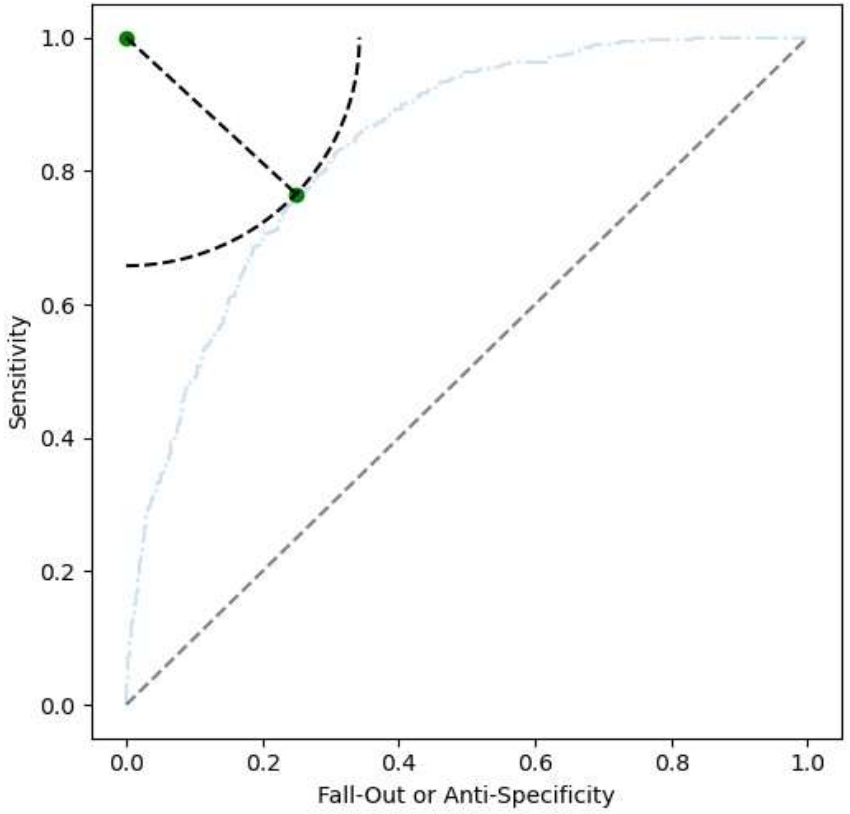
Contexte général : il s'agira d'utiliser au mieux les résultats d'une promotion récente d'une chaîne de magasins d'articles de mode pour déterminer les critères optimaux prédisant les chances de « forcer » une visite dans un de ses magasins physiques par une promotion similaire. (voir Larose p265 § Direct Mail Marketing Response Problem)

- Données: fichier Achat.csv sur Moodle
- Meta-Données: fichier AchatMeta.xls sur Moodle
- Mettez au point d'un modèle logistique de classification sur base du maximum de vraisemblance (80% apprentissage)
- Construisez la courbe ROC sur 20% test
- Déterminez le seuil optimal à utiliser pour être le plus proche d'un modèle parfait (Anti-spécificité:0, Sensibilité:1)
- Positionnez ce modèle optimal sur la courbe ROC

Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (2)





Optimal threshold : 0.1836
Optimal sensitivity: 0,7997
Optimal fallout: 0.2716

Matrice de confusion
au seuil optimal:

TP:483 FP:781
FN:121 TN:2094
P:604 N:2875

Accuracy: 0,7407

Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (3) – Bilan de la campagne – Larose p269

Imaginons un coût d'envoi de promotion de 4 euros pour une moyenne d'achat de 30 euros si le client se déplace dans le magasin suite à la promotion.

Quel bilan de promotion obtient-on si on envoie la promotion à tout le monde ?

- On envoie à tout le monde: coût de la promotion: 4 euros * (tot=3479) = 13916 euros
- On devrait récupérer: 30 euros * (P=604) = 18120 euros
- Bilan positif de: 18120-13916 = 4204 euros

Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (4) – Bilan de la campagne

Que se passe-t-il si on n'envoie la promotion qu'aux clients au-dessus du seuil optimal ?

A priori, on va envoyer moins de promotion (on va gagner sur de ce côté) mais on risque aussi de perdre des gens qui seraient venus mais qu'on n'a pas contactés (FP).

Par catégorie et par client, on aura un bilan:

- TP: (30 – 4)
- FP: -4
- FN: -30
- TN: 0

Au seuil optimal, T=0.1836, on aura donc:

- TP: 483*(30-4)
- FP: 781*(-4)
- FN: 121*(-30)
- TN: 2094*0

soit un bilan de 5804 euros bien meilleur que le précédent tout en envoyant beaucoup moins de folders (483+781)=1264 au lieu de 3479!!!

Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (5)

- Lisez la définition de la table coût/bénéfice (voir Larose p267 § Building the Cost/Benefit Table => p269)
- Que peut-on conclure?

Ne peut-on faire mieux encore?

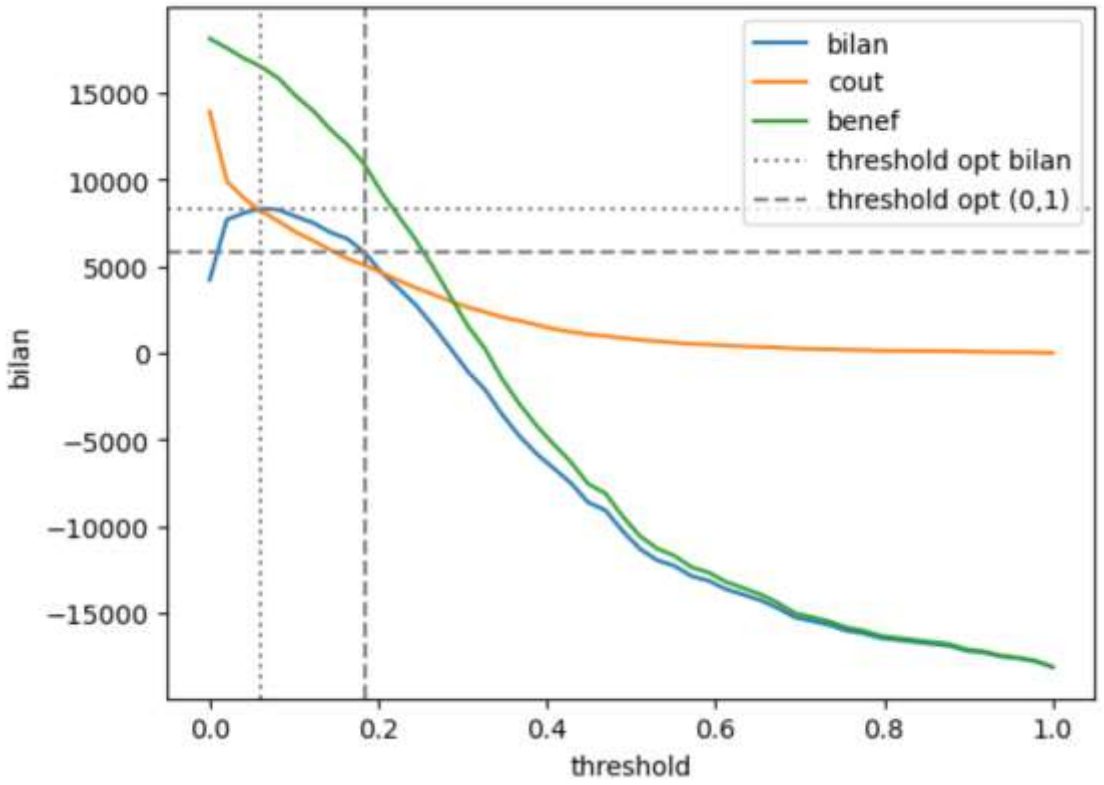
En calculant systématiquement

le bilan de la campagne en fonction

du threshold, on peut trouver un

optimum à 0,061 et un bilan de 8324 euros

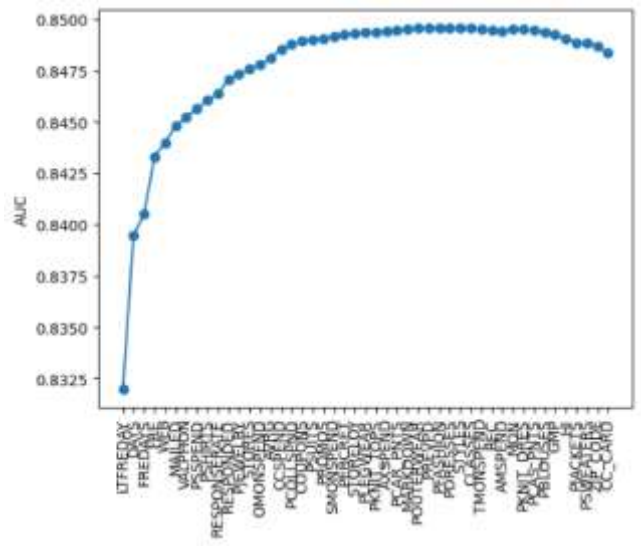
pour 2044 envois.

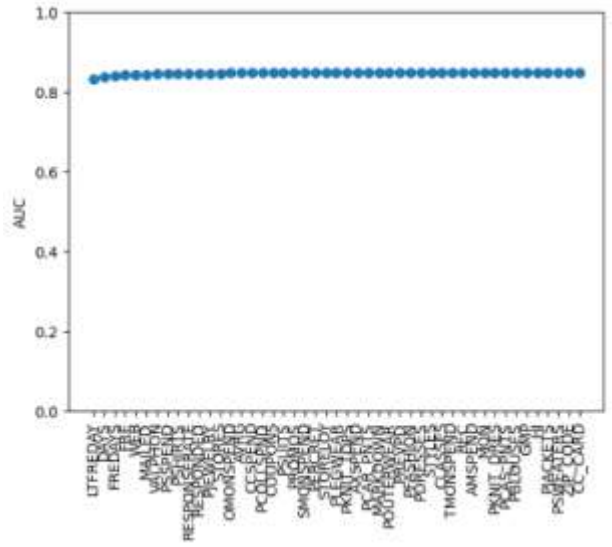


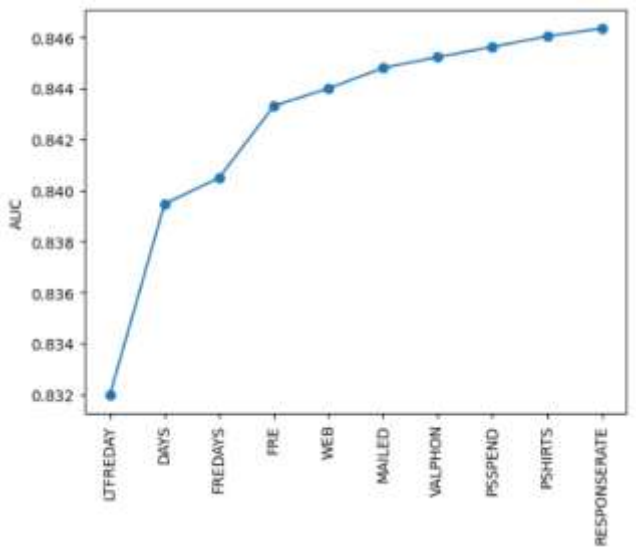
Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (6)

- Toutes les dimensions se valent-elles? (Feature sélection)
- Quelle est l'évolution de l'AUC en fonction de l'ajout de dimension?







Exercice récapitulatif sur les modèles de classification

Examen janvier 2018 (7)

- Story telling sur les 6 features les plus discriminantes
- Le signe des coefficients de la régression logistique pour ces 6 features vous parait-il correct et pourquoi ?
- Pouvez-vous essayer d'améliorer votre modèle en utilisant d'autres techniques vues au cours ?

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (1)

Dans un article relativement récent « Machine learning based prediction of COVID-19 diagnosis based on symptoms », l'équipe de recherche se propose de mesurer la fiabilité d'une simple grille de symptômes cliniques par rapport à l'approche de test biologique classique complet (couteuse en ressource, surtout en cas de crise) pour déterminer si un patient est réellement porteur du COVID-19.

Référence : https://www.nature.com/articles/s41746-020-00372-6

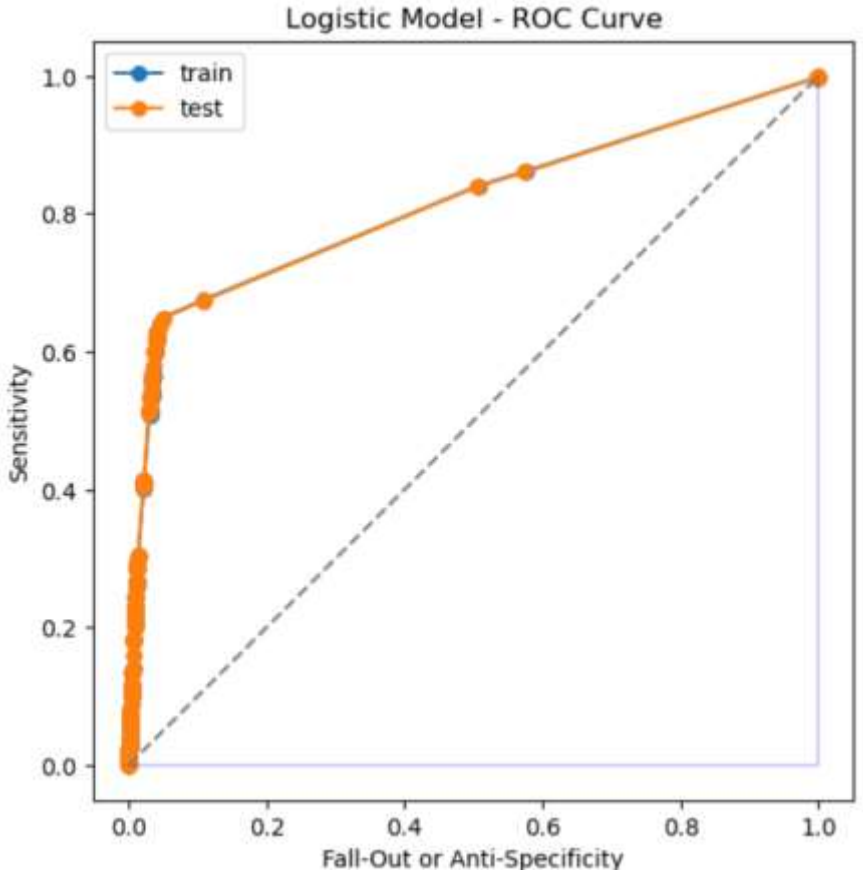
Il s'agira ici d'adapter le début du questionnaire de janvier 2018 à cette nouvelle problématique.

On éliminira tous les enregistrements comprenant au moins une valeur nan (sinon problème numérique dans les traitements suivants).

Pour la dimension 'test_indication' qui contient trois valeurs ('Other', 'Contact with confirmed', 'Abroad'), on utilisera sklearn.preprocessing.OneHotEncoder() pour encoder cette dimension sur trois colonnes distinctes et on ne gardera que les deuxième et troisième colonnes (la première s'en déduisant puisqu'elles sont complémentaires).

Exercice récapitulatif sur les modèles de classification

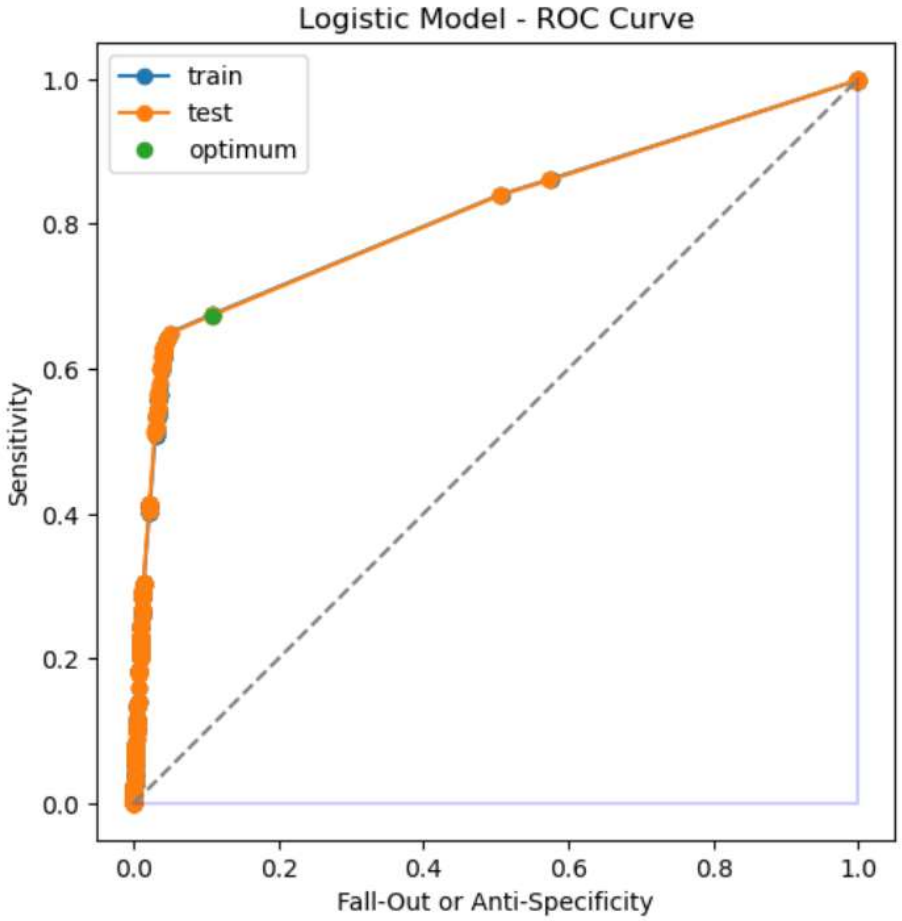
Examen janvier 2022 (2)



- AUC(train): 0.8145
- AUC(test): 0.8141
- On constate une bonne robustesse du modèle car le score d'AUC ne se tasse presque pas lorsque l'on passe du training set au test set
- On remarque malgré tout une courbe ROC d'allure peut habituelle, assez anguleuse.
- Ceci est dû au fait que toutes les valeurs des colonnes sont catégorielles, aucune n'est flottante continue.

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (3)



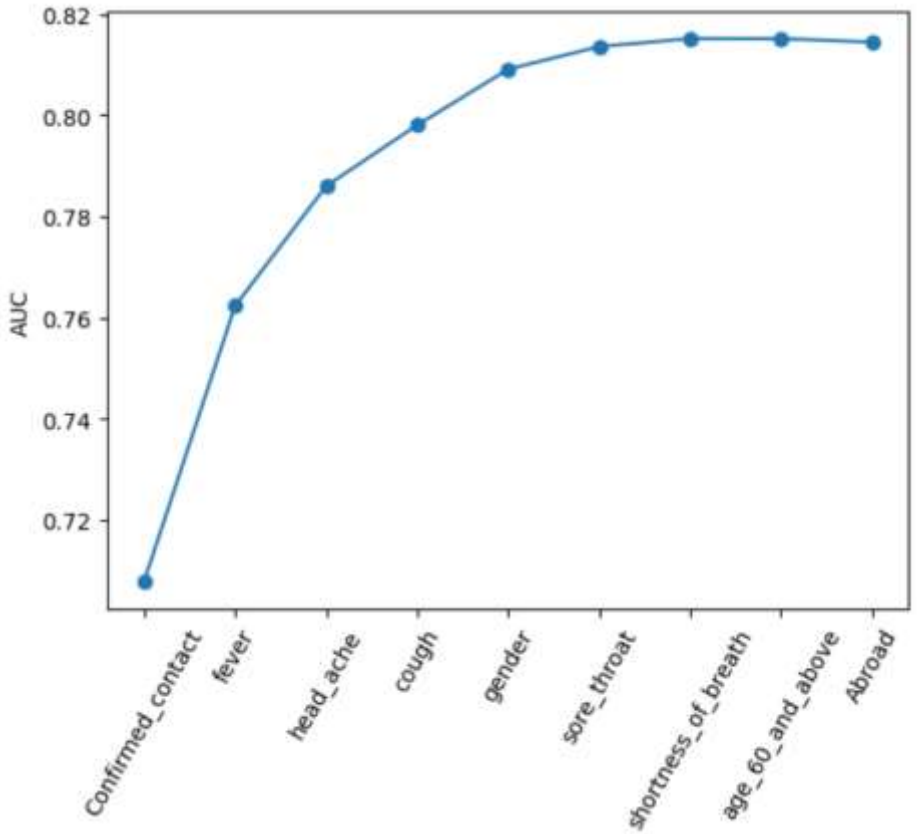
- Modèle optimal (le plus proche de (0,1)) correspond à un threshold de 0.0564 et aux scores suivants:
  - Sentitivity: 0.674
  - Fall-Out: 0.109
  - Specificity: 0.891
  - Accuracy: 0.870

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (4)

- Si on fait de la feature sélection, on obtient le graphe ci-contre.

- On voit que les cinq dimensions portant le plus d'information (les dimensions les plus discriminantes) sont:
  - Le fait d'avoir été en contact avec un cas positif
  - La fièvre
  - Les maux de tête
  - La toux
  - Le genre



Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (5)

- Ces différents critères sont-ils favorables ou défavorables à la positivité du résultat du test ?
- Pour s'en rendre compte il faut regarder le signe des différents coefficients définissant le modèle logistique (tableau ci-contre).

Coefficient	Dimensions	Valeurs
Beta0	NA	-2.6656
Beta1	Confirmed contact	+0.7005
Beta2	Fever	+0.3158
Beta3	Head ache	+0.2890
Beta4	Cough	+0.1232
Beta5	Gender	+0.1004
Beta6	Sore_throat	+0.1454
Beta7	Shortness of breath	+0.0998
Beta8	Age 60 and above	+0.0441
Beta9	Abroad	-0.0549

Rappel: Régression logistique

Slide 70 adapté à n dimensions

La courbe sigmoïde sera définie par l'équation:

$$\pi(x) = \frac{e^{g(x)}}{1 + e^{g(x)}}$$

où $x = [x_1, x_2, \ldots, x_n]$ et g(x) est donné par

$$g(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \ldots + \beta_n x_n$$

Notez que $\pi(x) \epsilon [0,1] \; \forall x$

et peut donc s'interpréter comme une probabilité!

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (6)

Que signifie la valeur de 1.6785 du coefficient correspond à l'indicateur de présence de fièvre ?

Pour un candidat ayant tous ses indicateurs à zero, on aura une valeur de probabilité d'avoir le covid est de

$$p = \pi(0) = \frac{e^{\beta_0}}{1+e^{\beta_0}}$$

où $\beta_0 = -2.9234$ alors que si l'indicateur de présence de fièvre est à 1, on aura

$$q = \pi(1) = \frac{e^{\beta_0 + \beta_2}}{1 + e^{\beta_0 + \beta_2}}$$

où $\beta_2 = +1.6785$.

On peut calculer alors que p=0.0510 et q=0.2236 ou autrement dit un candidat qui ne tousse pas, qui n'a pas mal à la gorge, qui n'a pas de problème respiratoire, qui n'a pas mal à la tête, qui n'a pas plus de 60 ans, qui est un homme, qui n'est pas "cas contact" et qui ne revient pas de l'étranger mais qui a de la fièvre a q/p=4.38 fois plus de 'chance' d'être porteur du virus Covid

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (7)

Que signifie la valeur de -0.1970 du coefficient correspond à l'indicateur genre?

Pour un candidat ayant tous ses indicateurs à zero, on aura une valeur de probabilité d'avoir le covid est de

$$p = \pi(0) = \frac{e^{\beta_0}}{1+e^{\beta_0}}$$

où $\beta_0 = -2.9234$ alors que si l'indicateur de présence de genere est à 1 (femme), on aura

$$q = \pi(1) = \frac{e^{\beta_0 + \beta_7}}{1 + e^{\beta_0 + \beta_7}}$$

où $\beta_7 = -0.1970$.

On peut calculer alors que p=0.0510 et q=0.0423 ou autrement dit un candidat qui n'a pas de fièvre, qui ne tousse pas, qui n'a pas mal à la gorge, qui n'a pas de problème respiratoire, qui n'a pas mal à la tête, qui n'a pas plus de 60 ans, qui n'est pas "cas contact" et qui ne revient pas de l'étranger mais qui est une femme a q/p=0.8287 fois moins de 'chance' d'être porteur du

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (8)

Quid d'une matrice de confusion basée sur un modèle basique qui considèrerait que dès qu'on a de la fièvre on est envoyé au test? Ici, on travaillera sur toute la population et pas seulement sur le test set

	Covid	Pas Covid
Fiévreux	Covid et Fiévreux:47799	Pas Covid mais Fiévreux:31733
Pas Fiévreux	Covid mais pas Fiévreux:160927	Pas Covid et pas de Fièvre:1911439

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (9)

Quid d'une matrice de confusion basée sur un modèle basique qui considèrerait que dès qu'on est 'cas contact' on est envoyé au test? Ici, on travaillera sur toute la population et pas seulement sur le test set

	Covid	Pas Covid
Cas contact	Covid et Cas contact:92719	Pas Covid mais Cas contact:55090
Pas cas contact	Covid mais pas Cas contact:116007	Pas Covid et pas Cas contact:1888082

Exercice récapitulatif sur les modèles de classification

Examen janvier 2022 (10)

Quid d'une matrice de confusion basée sur un modèle basique qui considèrerait que dès que son score > threshold optimal:0.056 on est envoyé au test? Ici, on travaillera sur toute la population et pas seulement sur le test set

	Covid	Pas Covid
>T	Covid et >T:140844	Pas Covid mais >T:211357
<T	Covid mais <T:67882	Pas Covid et <T:1731815

Comment pourrait-on comparer efficacement les résultats des trois modèles ?
Que pouvez-vous conclure ?

Exercice récapitulatif sur les modèles de classification

Examen janvier 2020 (1)

Contexte général : il s'agira d'utiliser au mieux les données concernant le profil médical de patients hospitaliers pour prédire leur réadmission endéans les 3 mois qui suivent leur sortie.

Le fichier de données à analyser se trouve sur le portail, module « Méthodes et outils pour le traitement de données – Exercices », répertoire « Ressources », fichier hospitalReadmission.csv.

La description des différentes dimensions catégorielles du problème se trouve dans le fichier IDs_mapping.csv (même localisation).

Exercice récapitulatif sur les modèles de classification

Examen janvier 2020 (2)

- Chargez le fichier de données et sélectionnez les dimensions pertinentes et définissez votre dimension cible. (1 pt)
- Optimisez un modèle logistique multiple sur un sous-ensemble de données pertinentes (75%). (1 pt)
- Commentez le résumé du modèle sur base de la signification statistique des différentes dimensions prédictives. En d'autres mots, la sélection des dimensions prédictives les plus significatives vous semble-t-elle justifiée ? (3 pts)
- Sur base de cette famille optimale de modèles et en utilisant le sous-ensemble des données pertinentes non-utilisé dans l'optimisation (point 3), obtenez la courbe ROC et dessinez-là. Déterminez l'AUC correspondant et le point de la courbe ROC le plus éloigné de la diagonale. Reportez ce point dans le diagramme ROC précédent. A quelle valeur critique ce modèle précis se réfère-t-il ? Construisez la matrice de confusion correspondant à ce modèle et calculée sur l'échantillon d'apprentissage. Quelles sont vos conclusions ? (5 pts)
- Faites de la sélection de dimension par itération et construisez la courbe d'évolution de l'AUC en fonction du nombre croissant de paramètres du modèle. Commentez ce graphe. Quel serait l'ensemble de paramètres optimal ? Pourquoi ? Cette sélection rejoint-t-elle vos conclusions du point 4 ? Dans quelle mesure et pourquoi ? (5 pts)
- Essayez d'améliorer le résultat du modèle de régression logistique obtenu au point 3 en recourant à d'autres techniques abordées au cours des laboratoires et expliquez votre démarche. (3 pts)

Clarté: 2 pts

Dilemme Biais-Variance -1

Principe

- Jusque là, nous avons vu quelques techniques d'optimisation utilisées pour adapter des modèles à des données de façon à pouvoir prédire une classification sur des données non utilisées pour l'apprentissage
- Ici, **adapter des modèles** veut dire:
  - Dans un famille de modèles, choisie a priori, explorer l'ensemble des paramètres du modèle possibles de façon à trouver LE modèle de la famille, optimal au sens d'une métrique donnée (et il y en a beaucoup)
- Dans ce qui suit, nous allons comparer des modèles de plus en plus complexes et voir dans quelle mesure cette complexité, le nombre de paramètre du modèle permet de rendre mieux compte de la réalité des données (mesurer la fidélité des prédictions du modèle sur des données non utilisées dans l'apprentissage)
- Ainsi, on vise à mesurer un pouvoir prédictif du modèle vs sa complexité

Dilemme Biais-Variance - 2

Cas académique... mais assez révélateur

- Référence générale: Référence: Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow 2nd edition Aurélien Géron 2019 p. 128-129
- Ici, on force artificiellement le trait puisque nous allons maîtriser tous les rouages et même fabriquer des données bruitées.
- Ainsi, il s'agira de considérer des données correspondant à un fonction quadratique auxquelles on va ajouter un bruit gaussien d'écart-type donné.
- On en fabriquera un ensemble de taille n, dont les x seront eux aussi aléatoires sur un intervalle donné.
- Voyons cela de plus près.

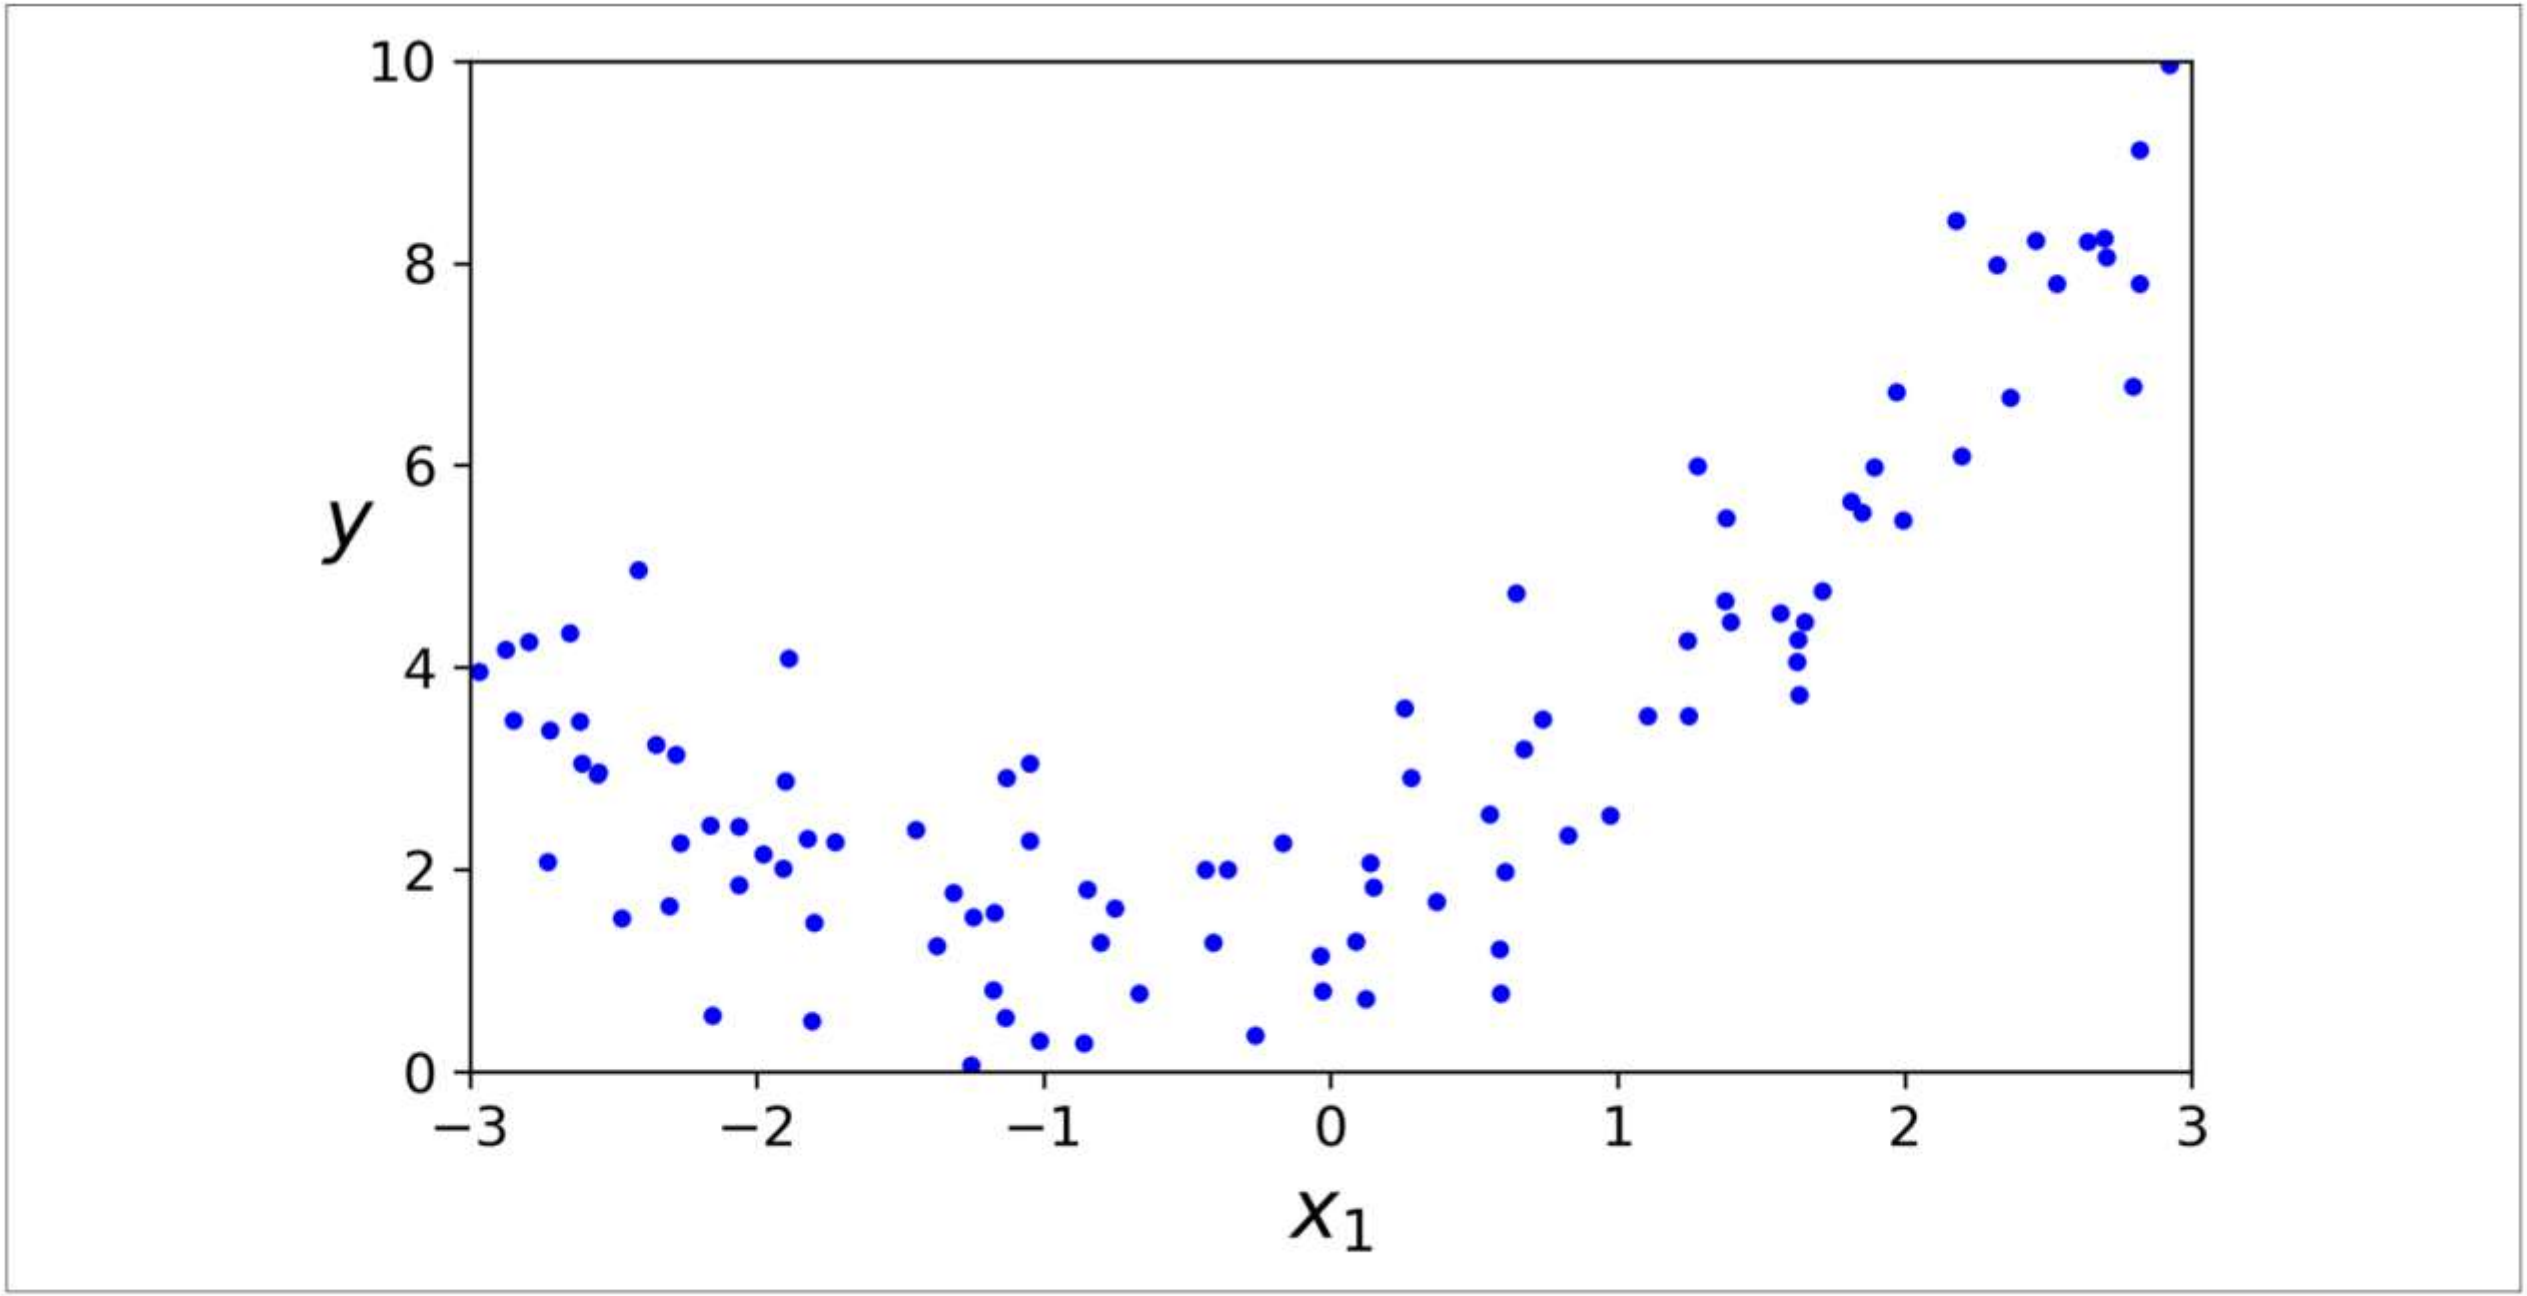


Figure 4-12. Generated nonlinear and noisy dataset

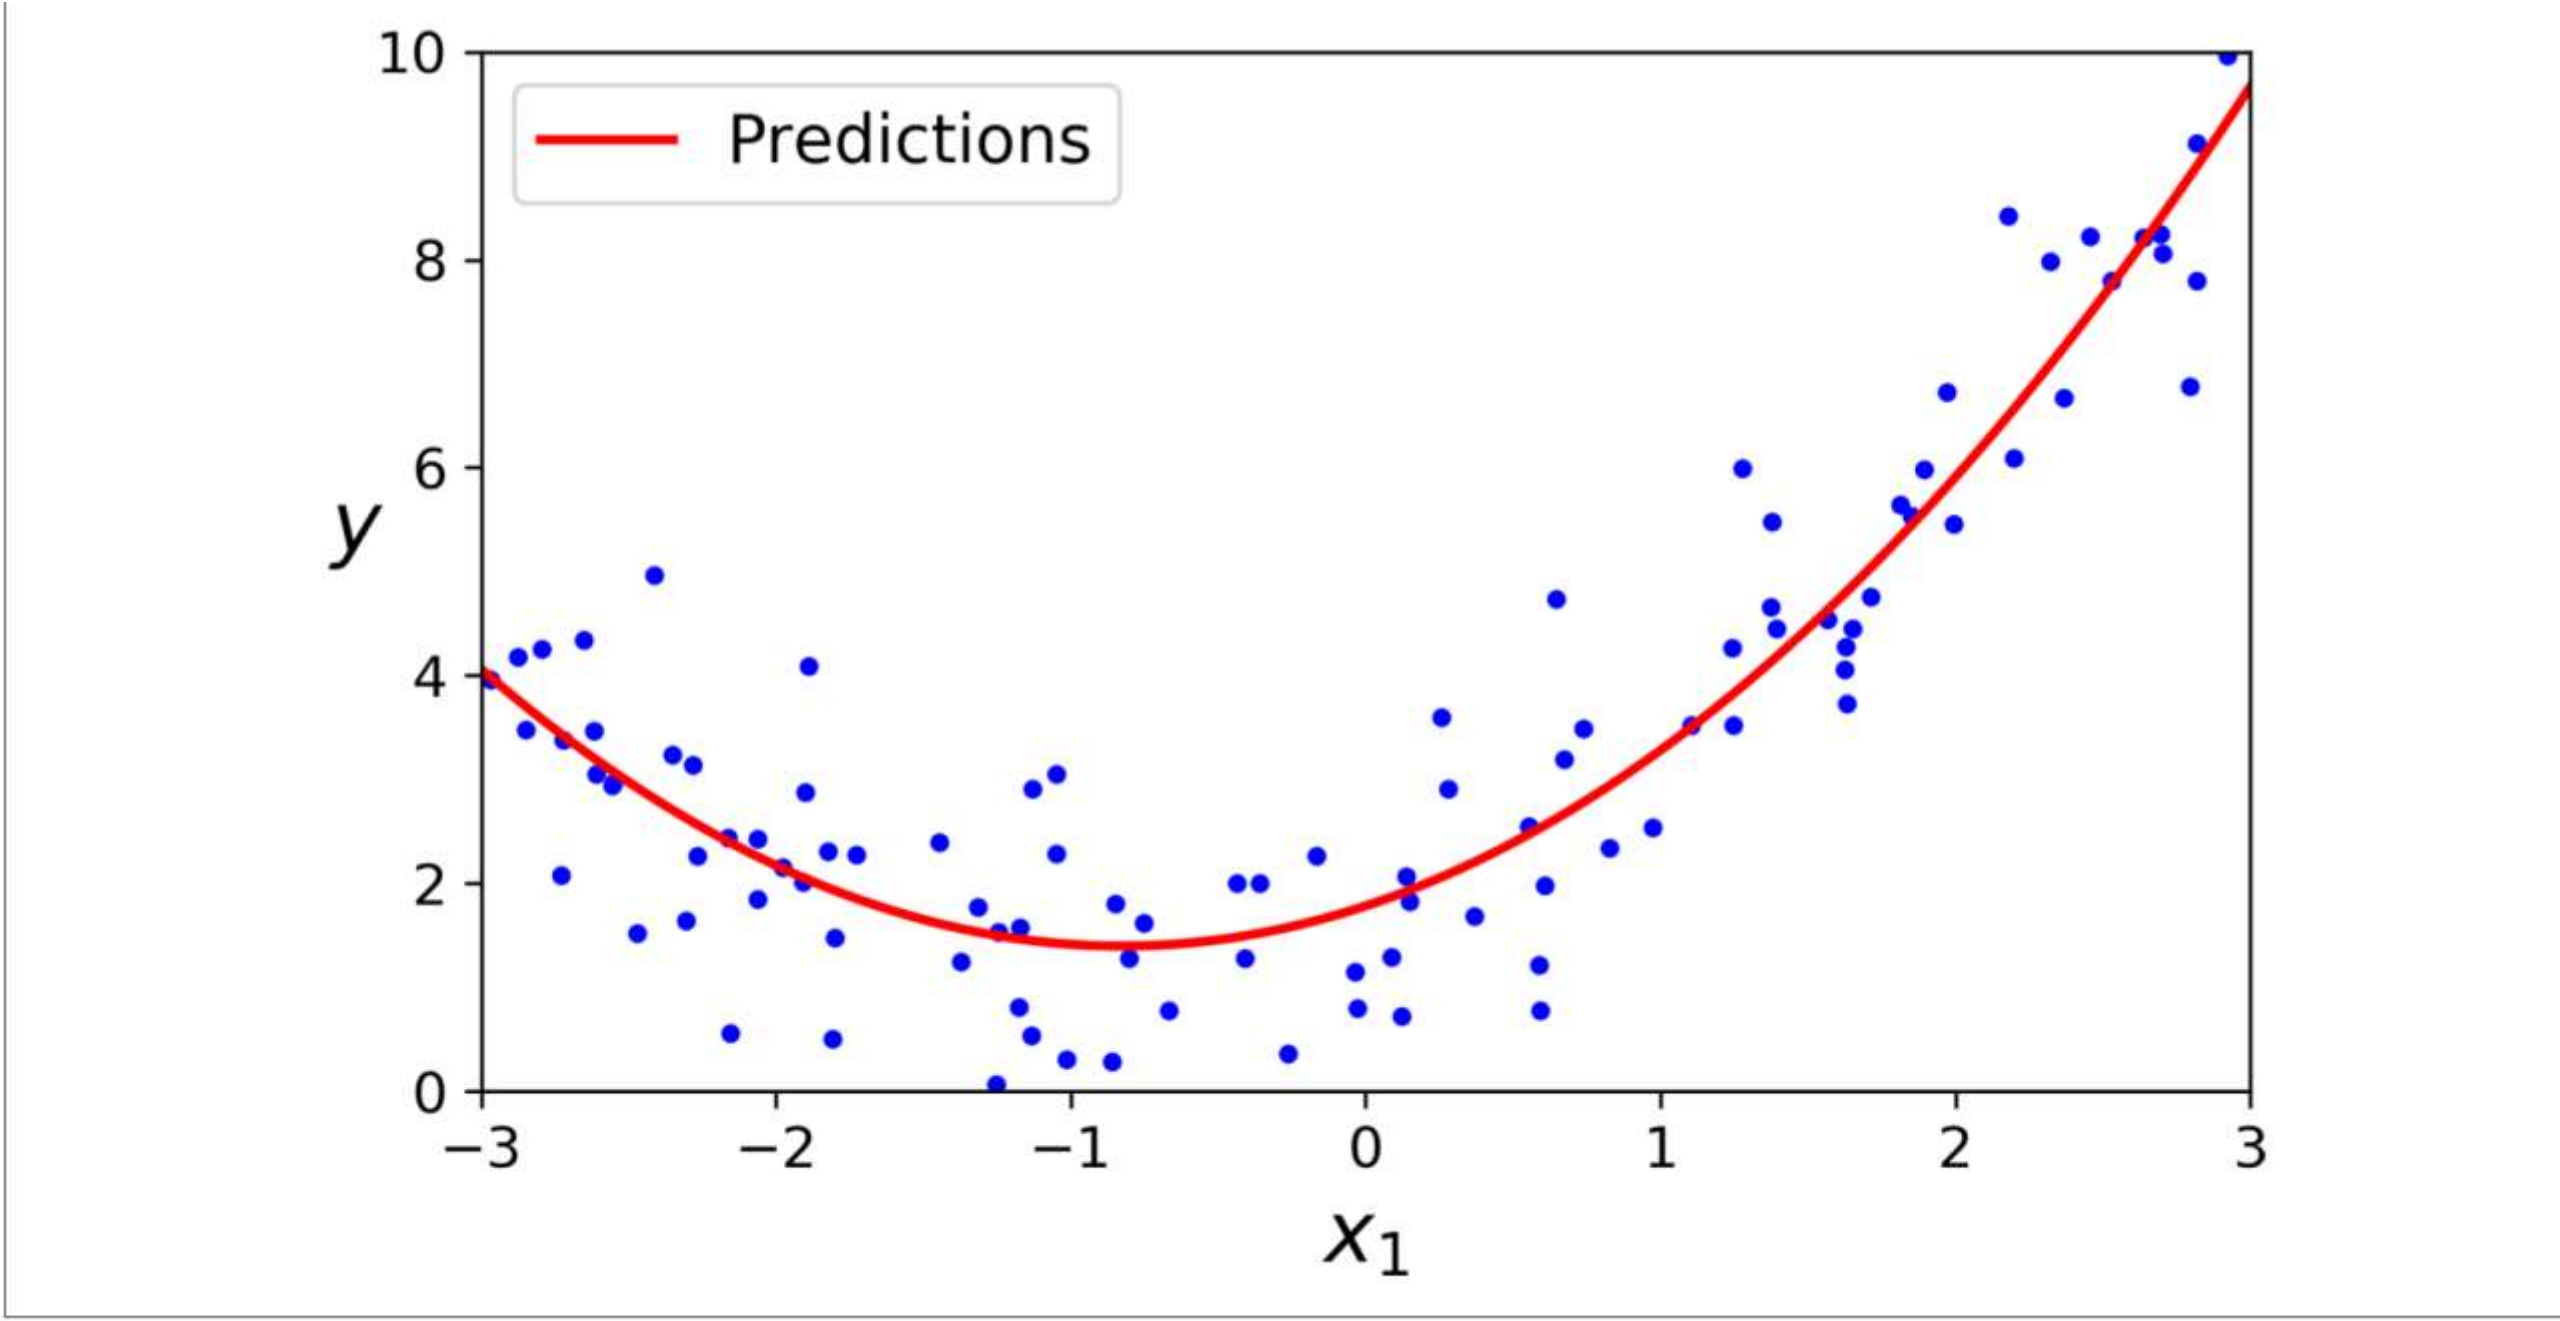
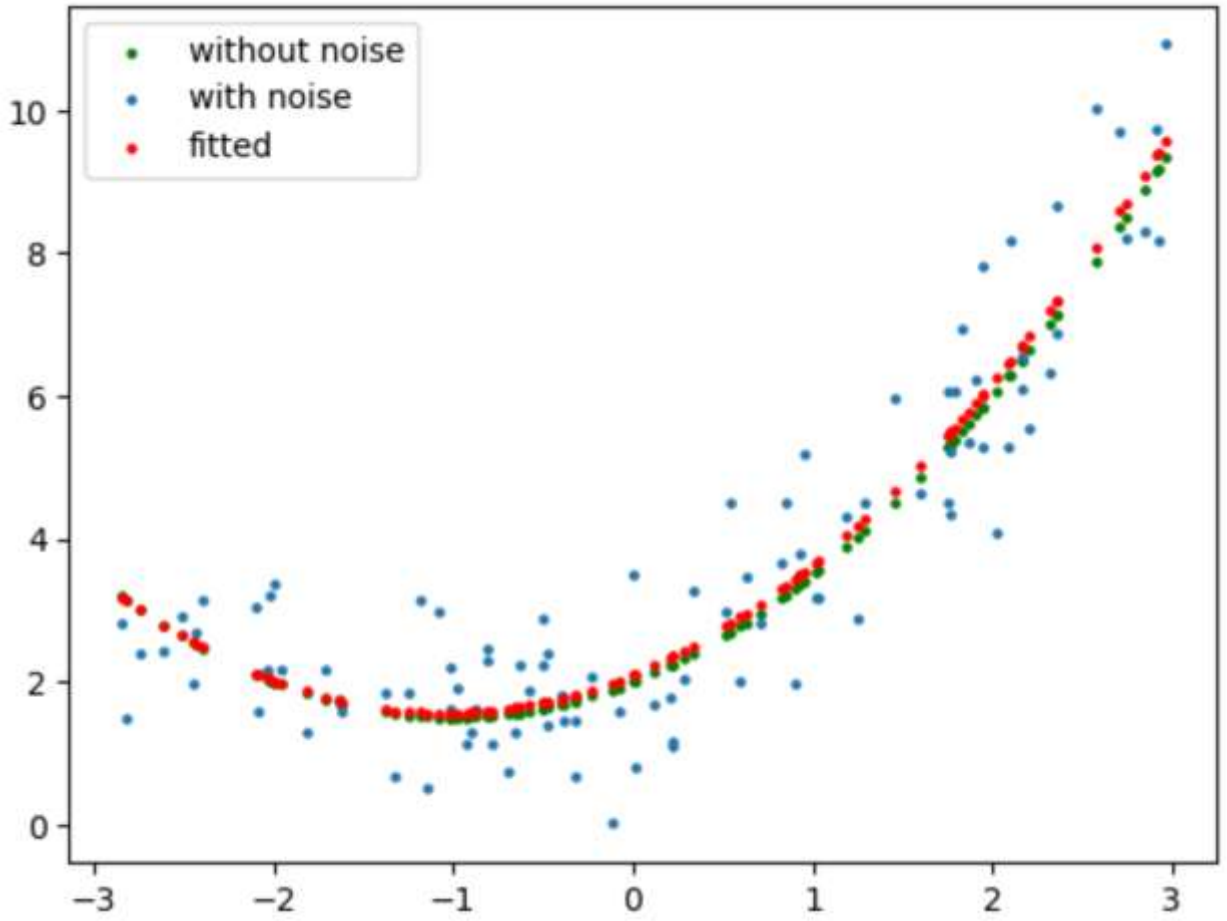


Figure 4-13. Polynomial Regression model predictions

Dilemme Biais-Variance – 3

Ma proposition de solution

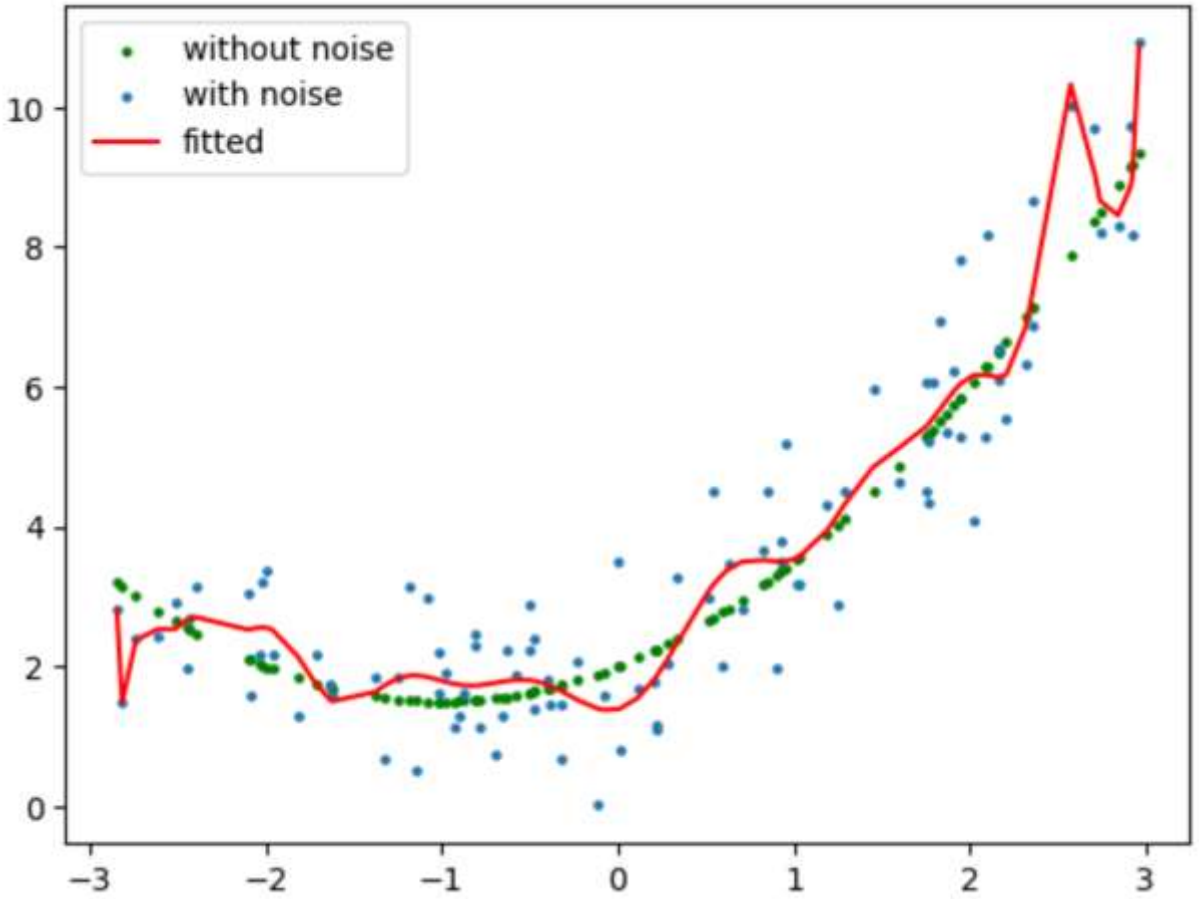



```
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
```

```
Paramètres optimisés:
0.49961065 1.03825675 2.10056356
```

Dilemme Biais-Variance - 4

Augmentation de la complexité du modèle – max degree = 25




```
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
```

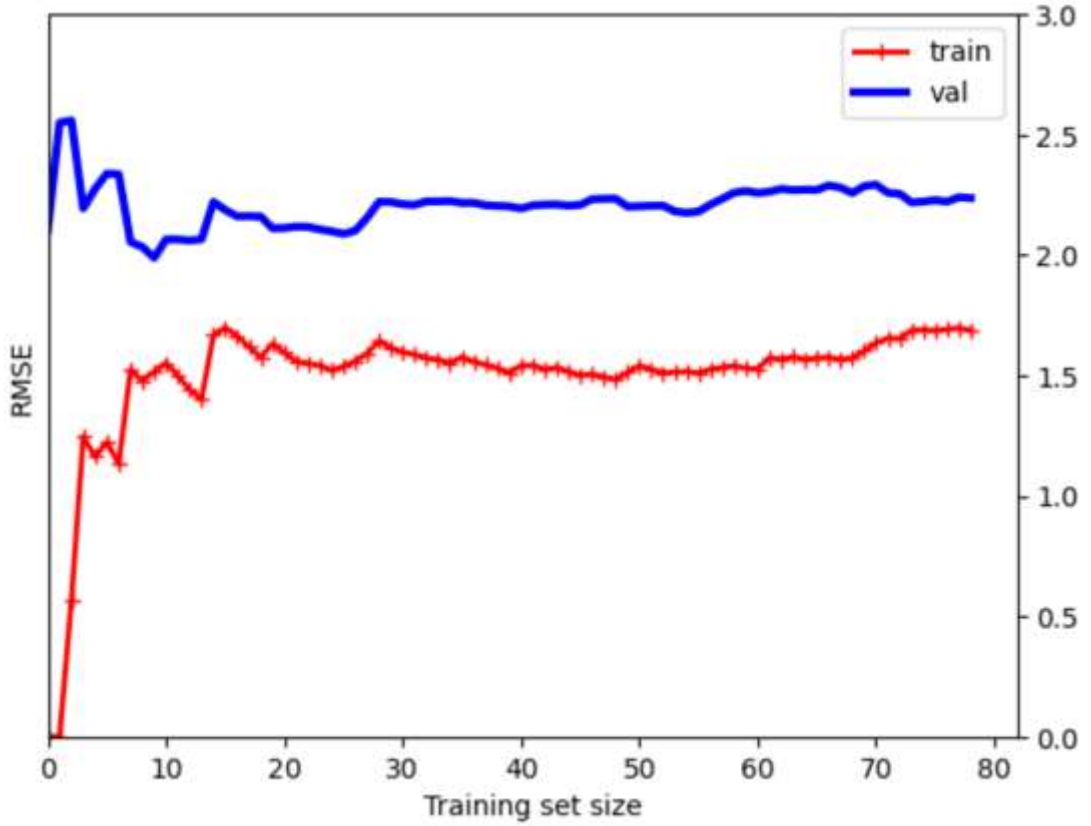
Paramètres optimisés:

(array([1.38663942]),
 array([[5.94652135e-01, 6.72418789e+00,
4.22410908e+00,
        -1.25636551e+01, -7.81612661e+00,
7.55938854e+00,
         2.34531448e+00, 4.60266703e+00,
5.39597003e+00,
        -9.38944111e+00, -6.30197510e+00,
6.13801146e+00,
         3.22913068e+00, -2.23103519e+00, -9.65713
01,
        5.01600223e-01, 1.81450930e-01, -7.142120

Dilemme Biais-Variance – 5

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considéré



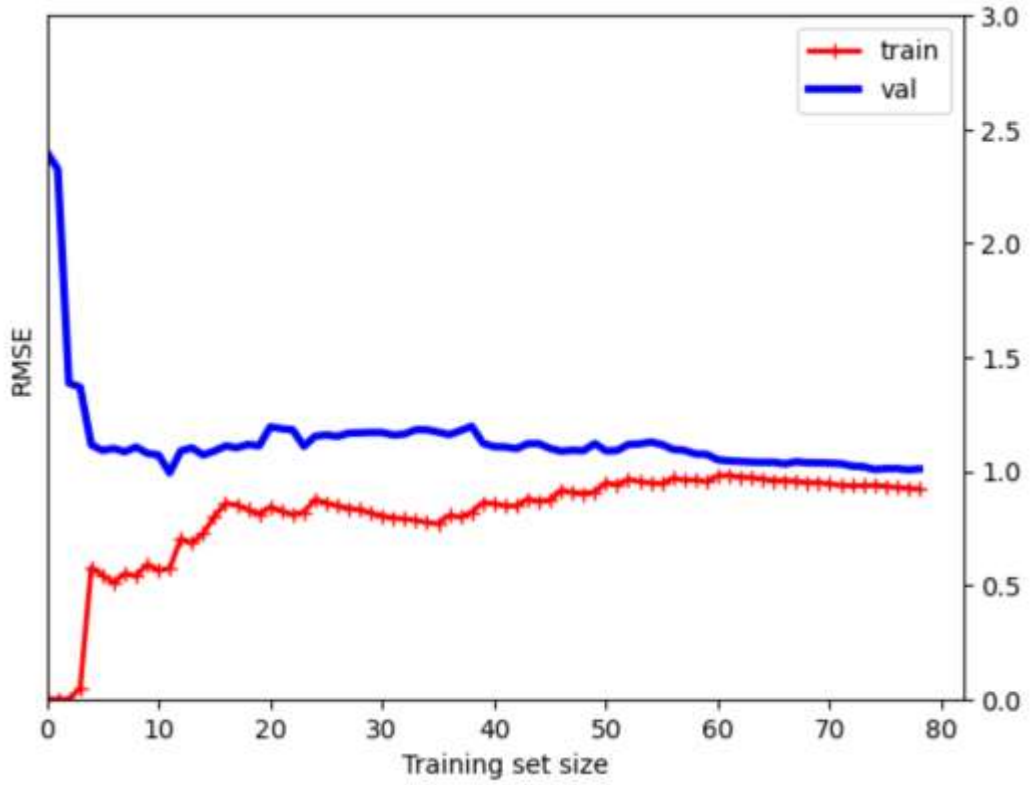
Modèle de degré 1

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance – 5

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considérées



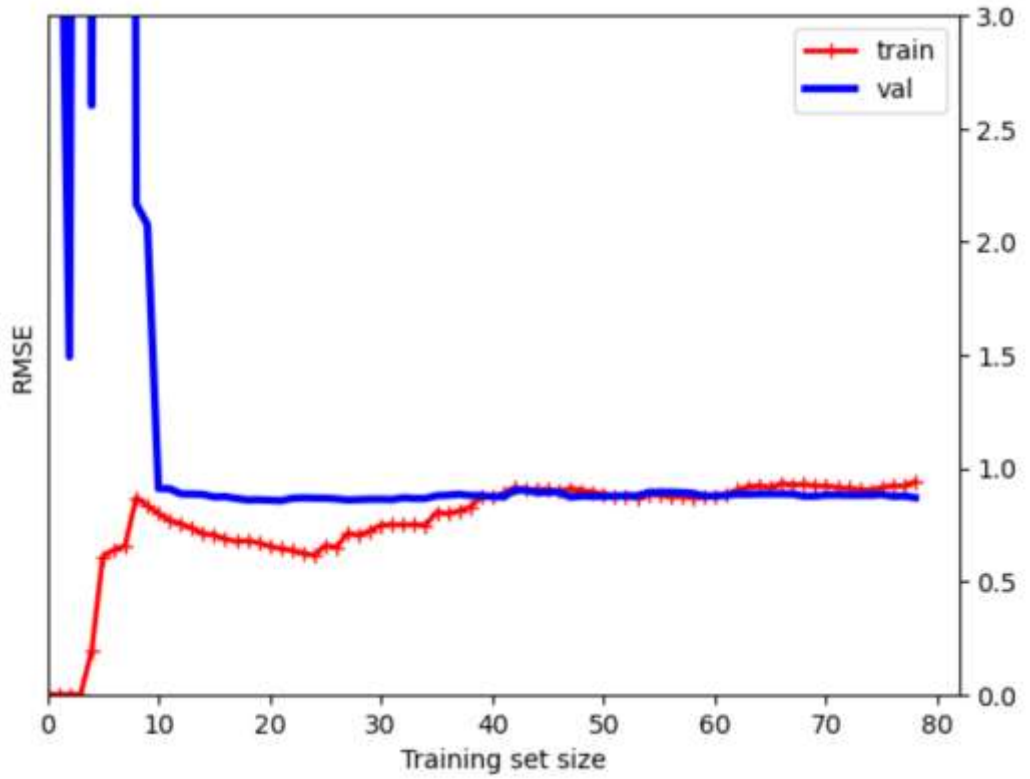
Modèle de degré 2

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance – 6

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considérées



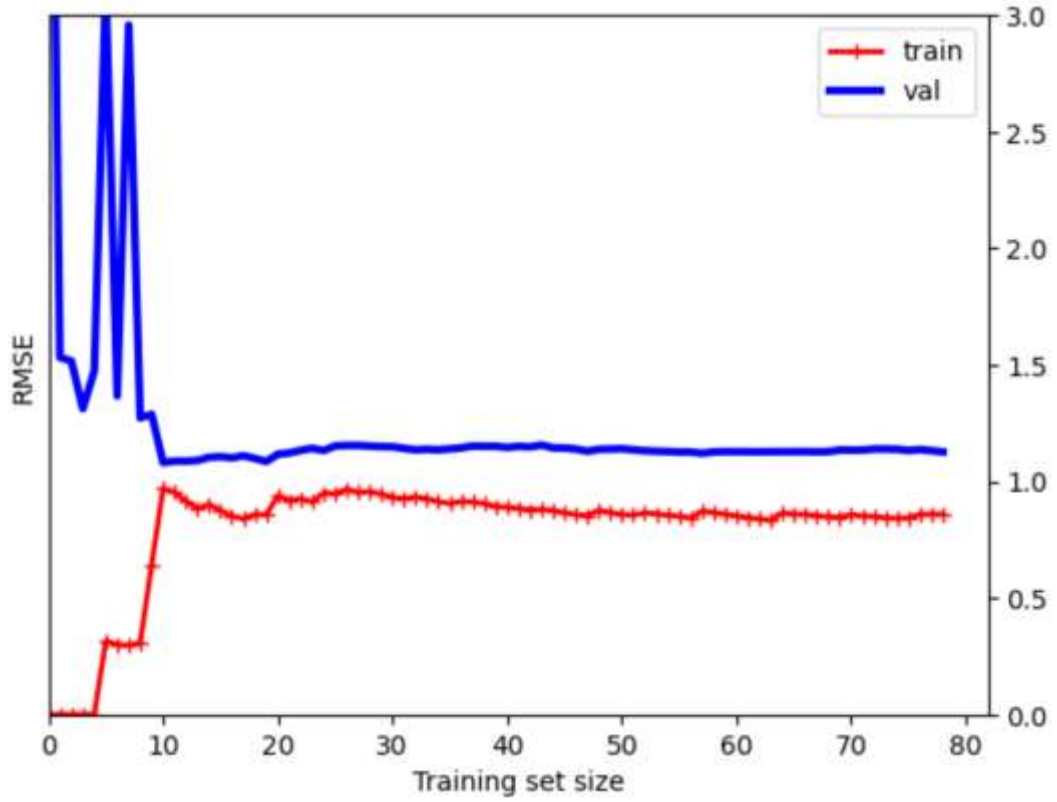
Modèle de degré 3

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance – 7

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considérée



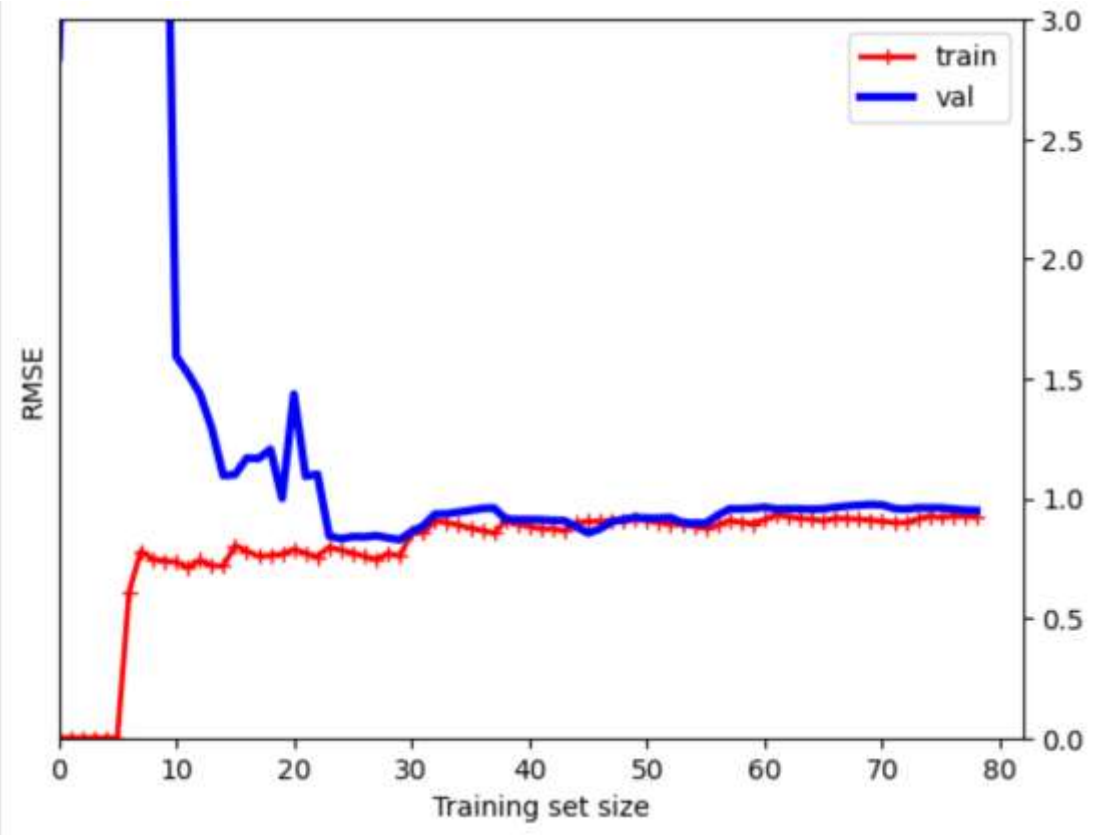
Modèle de degré 4

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance - 8

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considérée



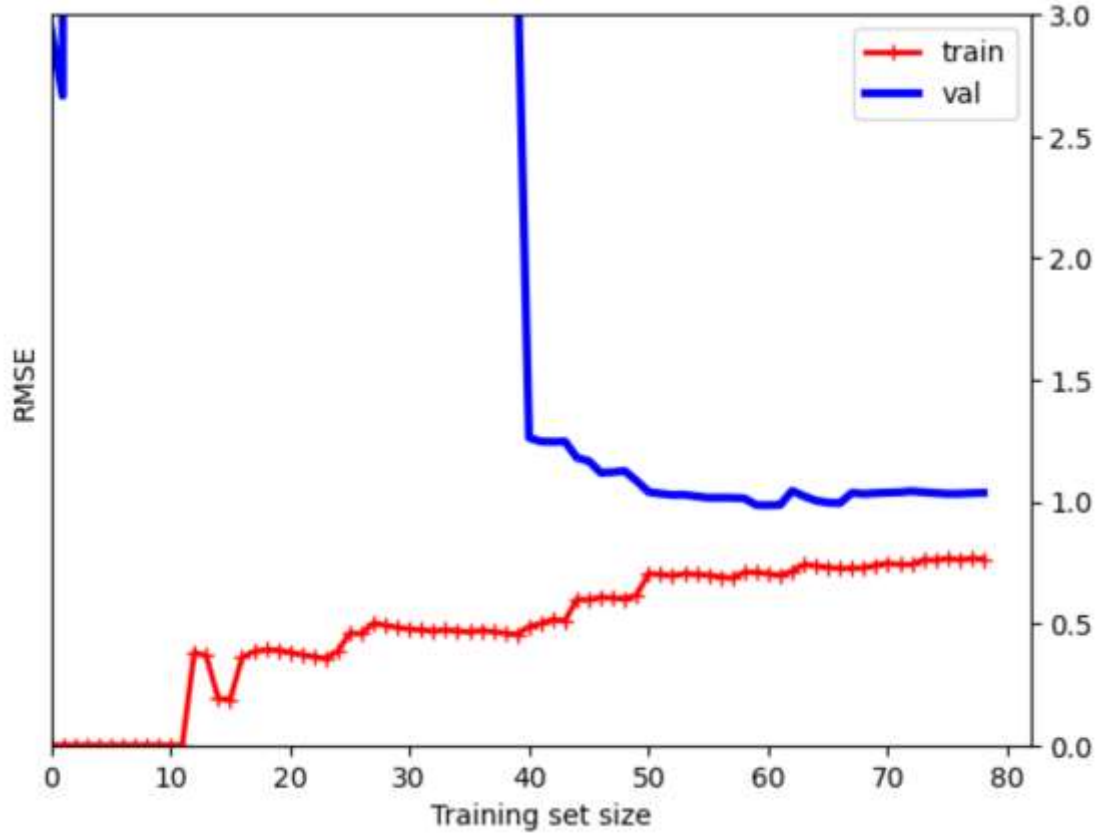
Modèle de degré 5

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance – 9

Comment se rendre compte qu'on finit par modéliser des détails non importants ?

Analyse de l'erreur sur le training set ET sur le validation set en augmentant le nombre de données considé

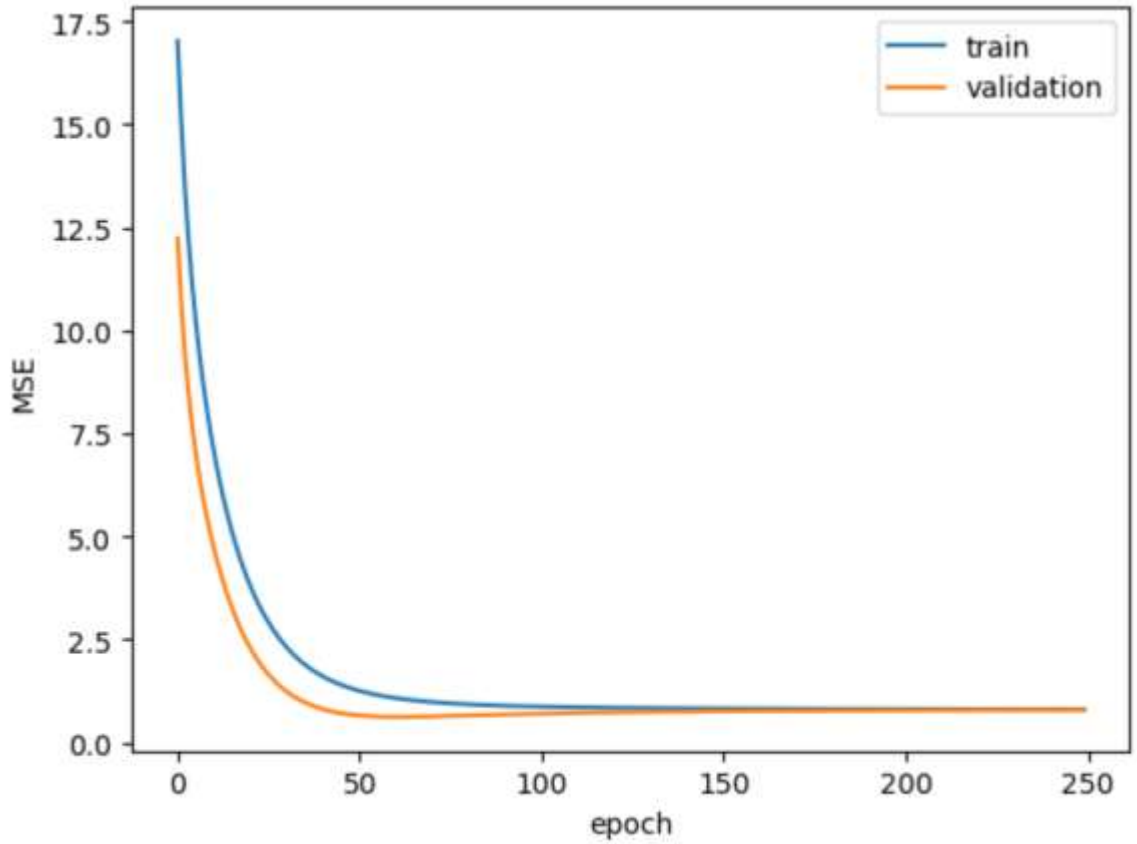


Modèle de degré 5

80/20 pour la proportion entre taille du training set max et taille du validation set

Dilemme Biais-Variance - 10

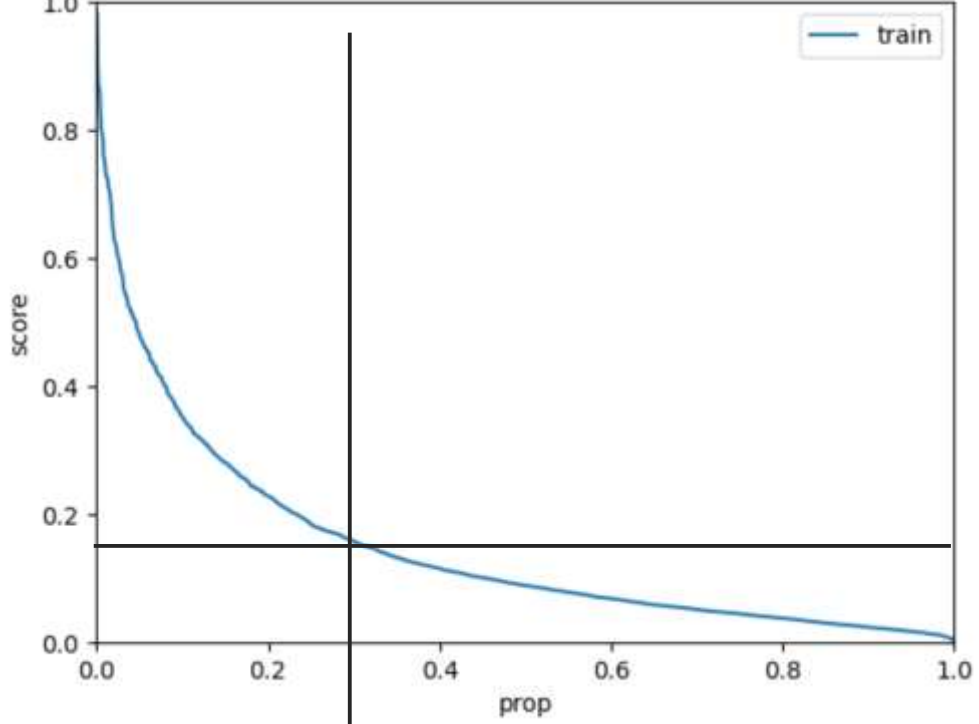
Autre façon de faire: analyser les erreurs au fur et à mesure des relaxations

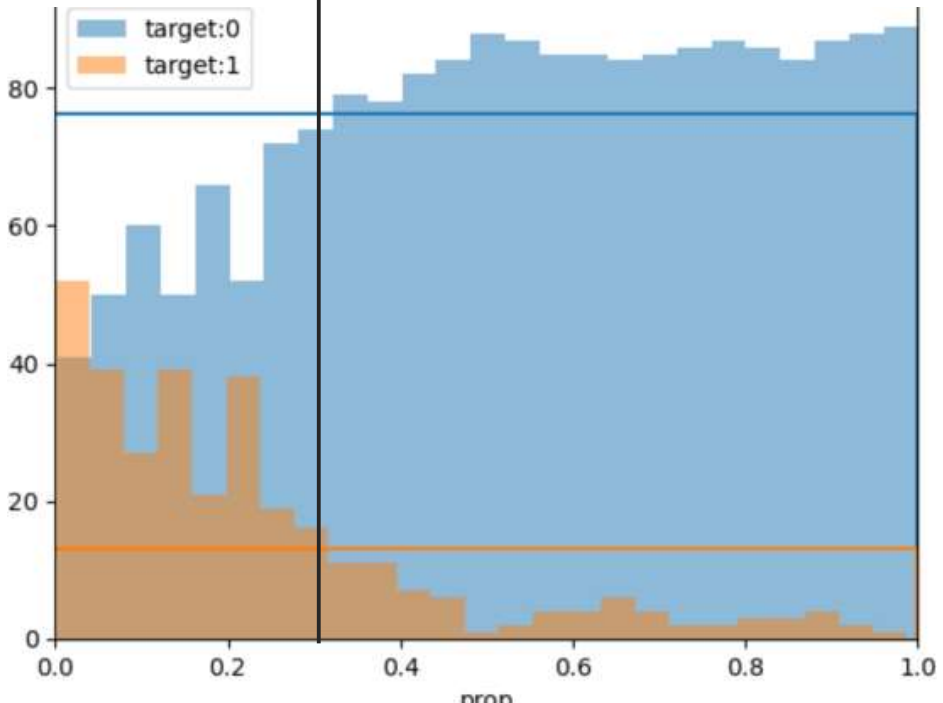


Modèle de degré 8

80/20 pour la proportion
entre taille du training set
et taille du validation set

Qu'obtenez-vous de votre côté ?
L'idéal serait d'obtenir un graphe zoomable… solution

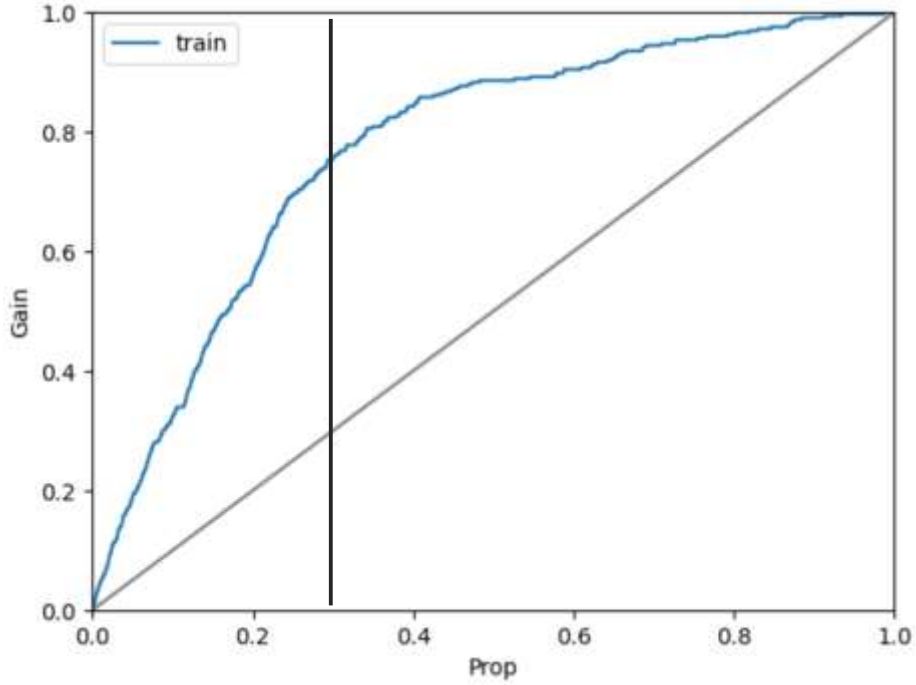


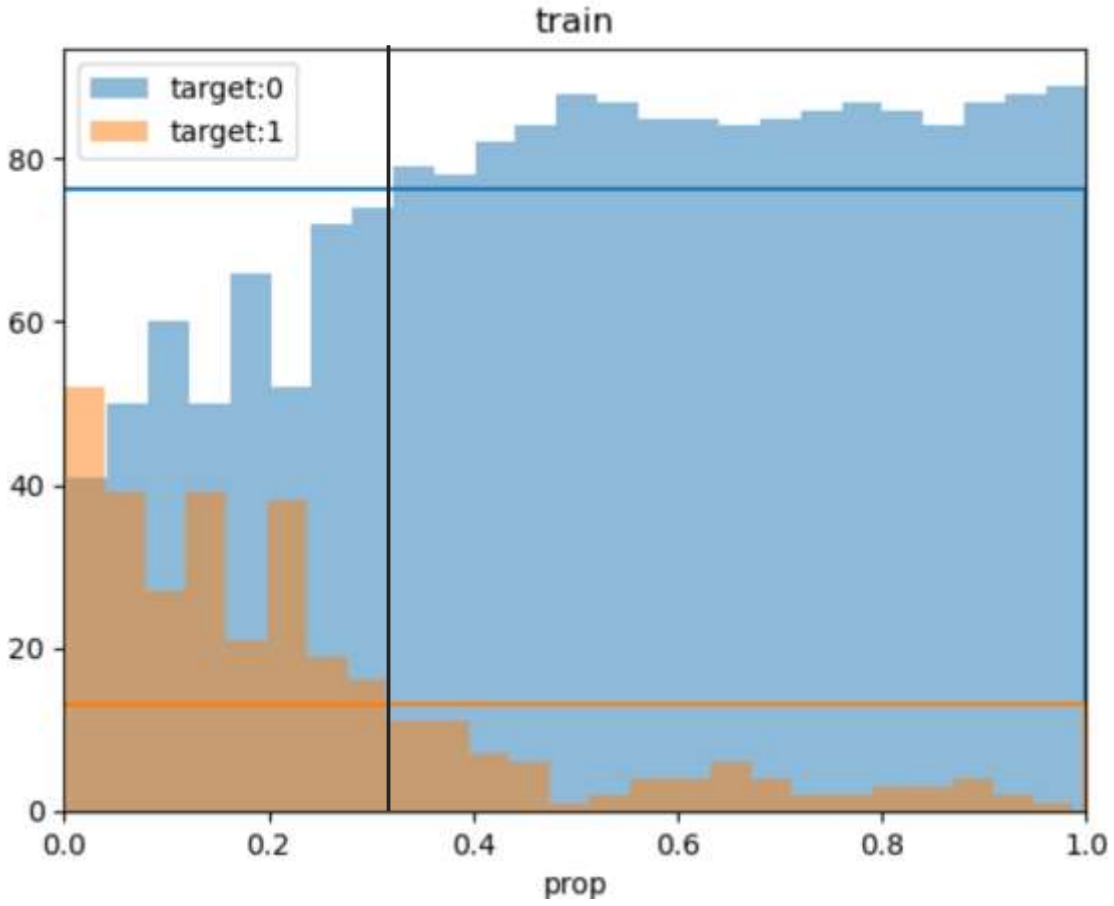


Toutes les zones à gauche représentent nécessairement des vrais positifs (car au dessus du threshold correspondant à la prop soit xxx)

Le Gain correspond à la proportion de TP classés par le modèle jusqu'à cette valeu de score (depuis le maximum soit 1)
= aire de l'histogramme jusque la vertica divisée par l'aire du rectangle orange

Les deux rectangles permettent de visua
Les résultats d'un modèle nul ☹ sans au pouvoir de concentration des positifs à g des négatifs à droite

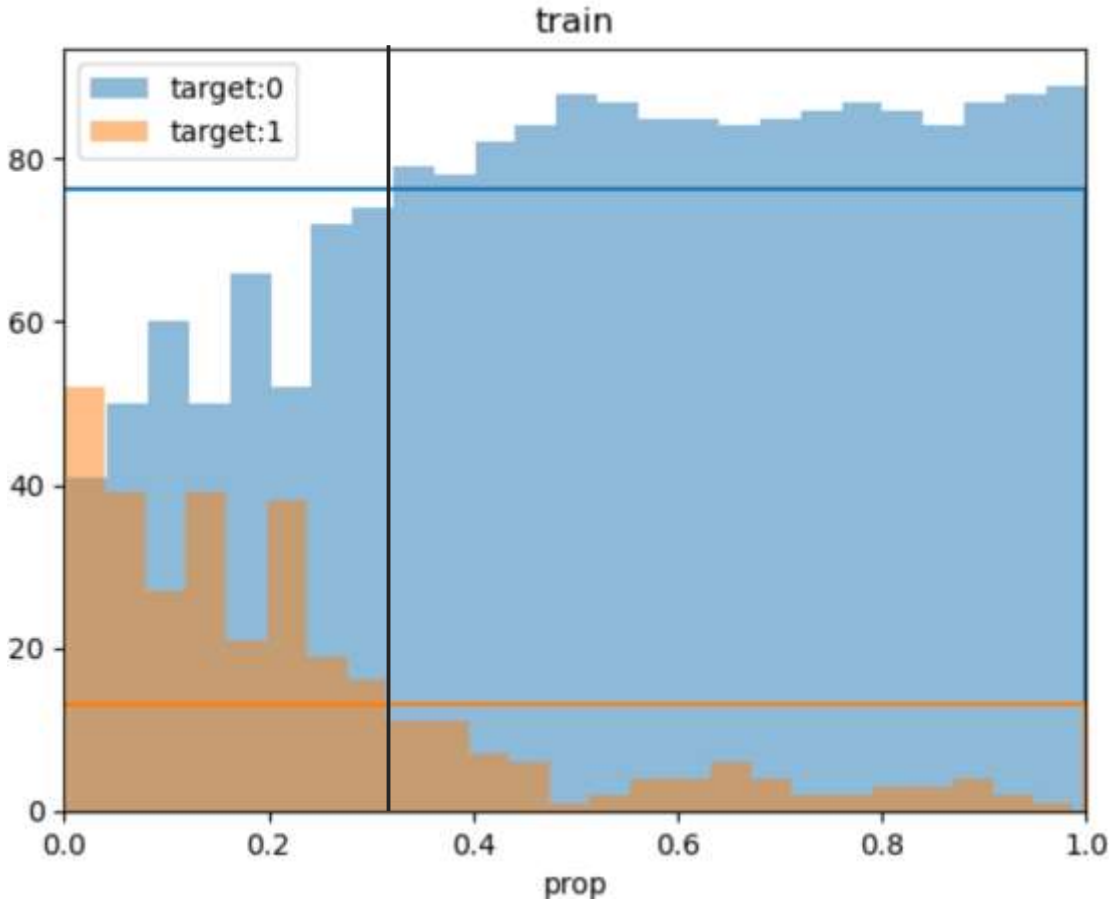




Mise en évidence de pouvoir concentrateur du moc

Il y a plus de positifs classés à gauche (dans la zor
haut score) que la normale (équipartition correspon
rectangle orange).
L'aire orange qui dépasse du rectangle orange à ga
exactement égale (même si pas la même forme) à
déficience à droite.

Le même raisonnement tient pour les négatifs, hist
bleu sauf qu'ici la concentration des négatifs se fait
valeurs basses du modèle (concentration à droite)



Le Gain s'efforcera de donner un score sur ce pouvoir de

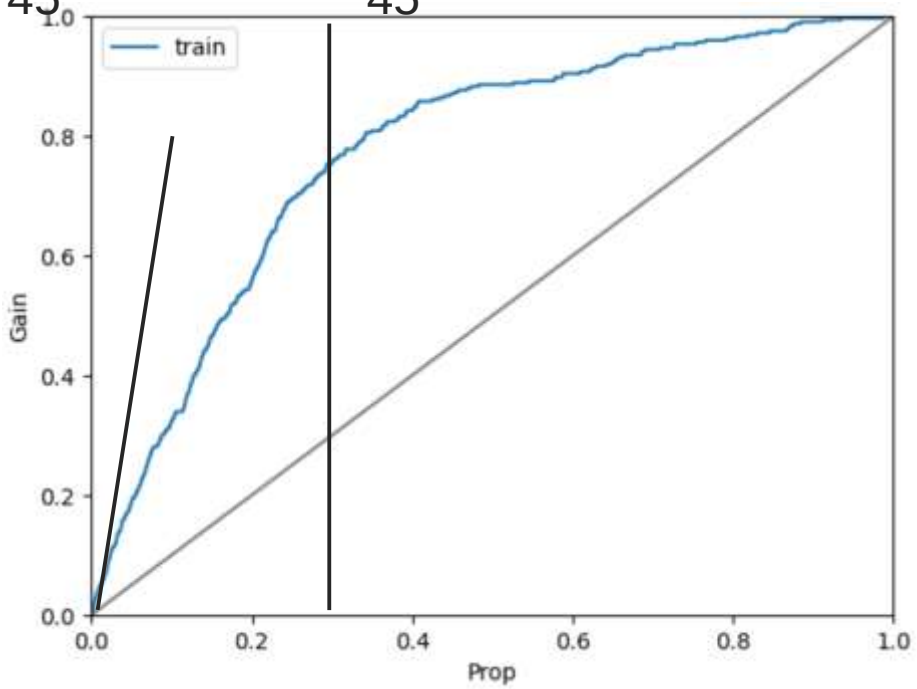
Pour une valeur de prop (ou de threshold) donnée, on ca
la proportion entre le total des vrais positifs à gauche de
(aire dans l'histogramme jusqu'à cette valeur en x) et l'ai
l'histogramme ou du rectangle orange (== nombre total c

Cette proportion ne peut évidemment qu'être dans l'inter

A gauche de la ligne verticale, cette proportion augmente
que pour un modèle null (qui donnerait une proportion ég

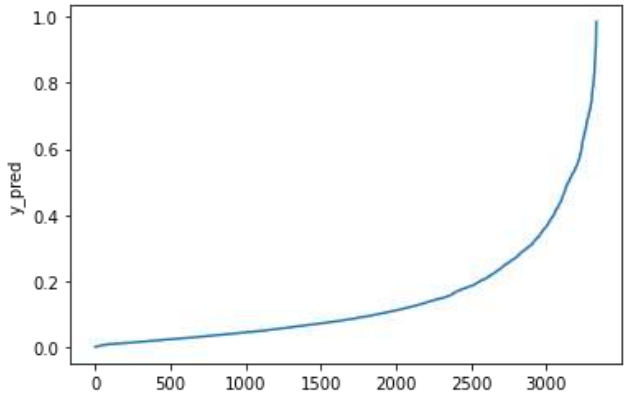
Pente locale supérieure à 45°

Pente locale inférieure à 45°

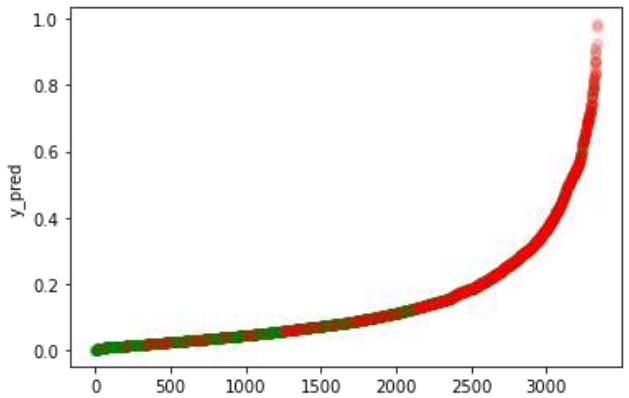


Qualification de modèle de classification binaire

Courbes de gain (1)



Courbe des prédictions (y_pred) en ordre croissant



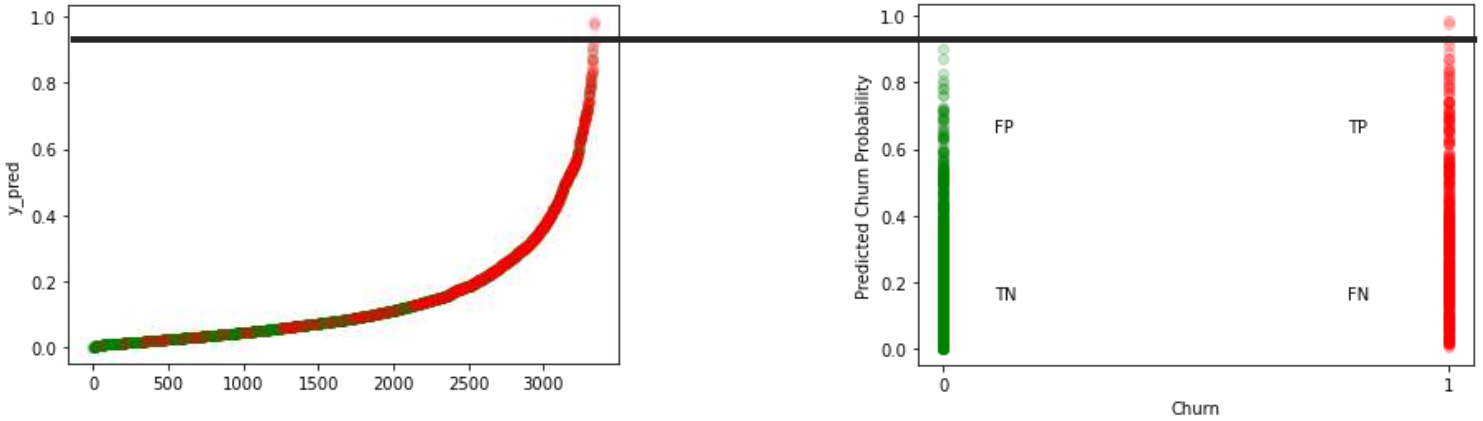
Courbe des prédictions (y_pred) en ordre croissant:

- points rouges pour les clients partant;
- points verts pour les clients restant.

Grâce à la transparence, on voit que les clients partant sont plus concentrés sur la partie haute de la courbe précédente.

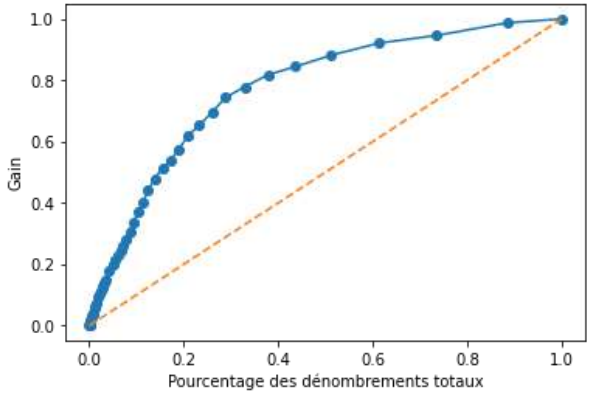
Qualification de modèle de classification binaire

Courbe de gain (2)



Ici, on s'intéressera à la proportion des
captés par notre critère y_pred>T et rap
à l'ensemble des positifs (potentiels):

$$\text{Gain} = \frac{TP}{TP+FN} = \frac{TP}{P}$$

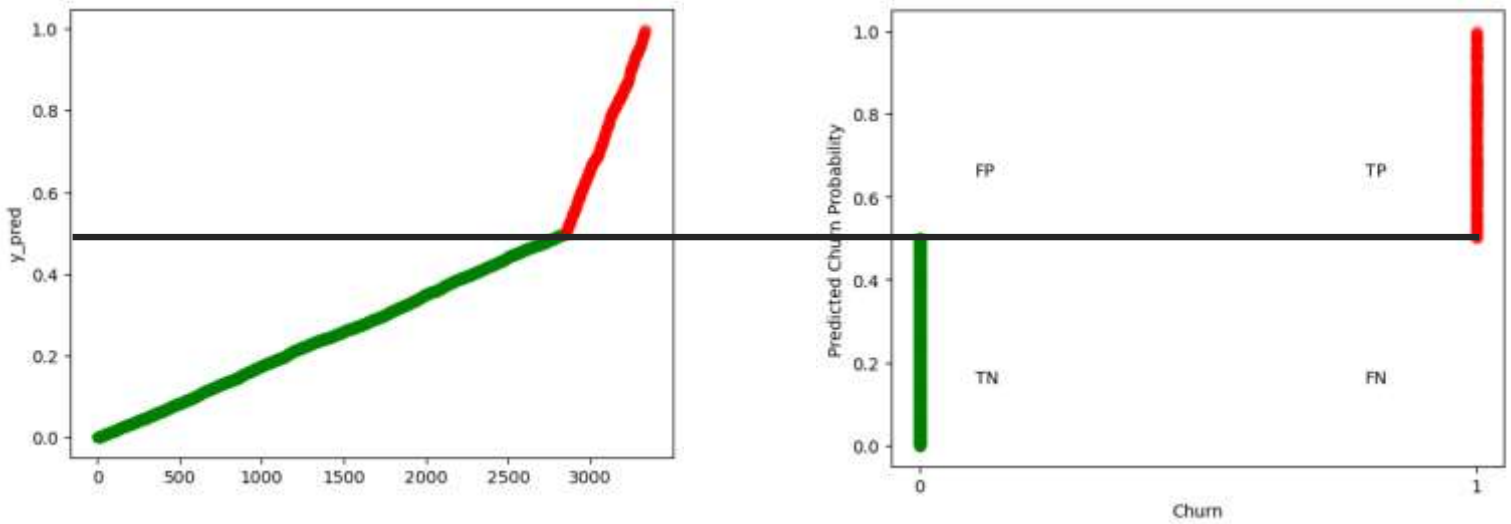


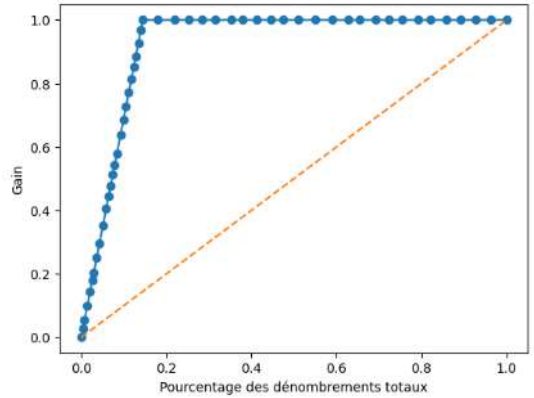
En abscisse, on reprendra la proportion des cas au des
du critère ramenée à la population totale, soit:

$$\frac{TP+FP}{TP+FN+FP+TN} = \frac{TP+FP}{Tot}$$

Qualification de modèle de classification binaire

Courbes de gain (3) – Courbe de gain dans le cas limite d'un modèle parfait





Ici, on s'intéressera à la proportion des
captés par notre critère y_pred>T et rap
à l'ensemble des positifs (potentiels):

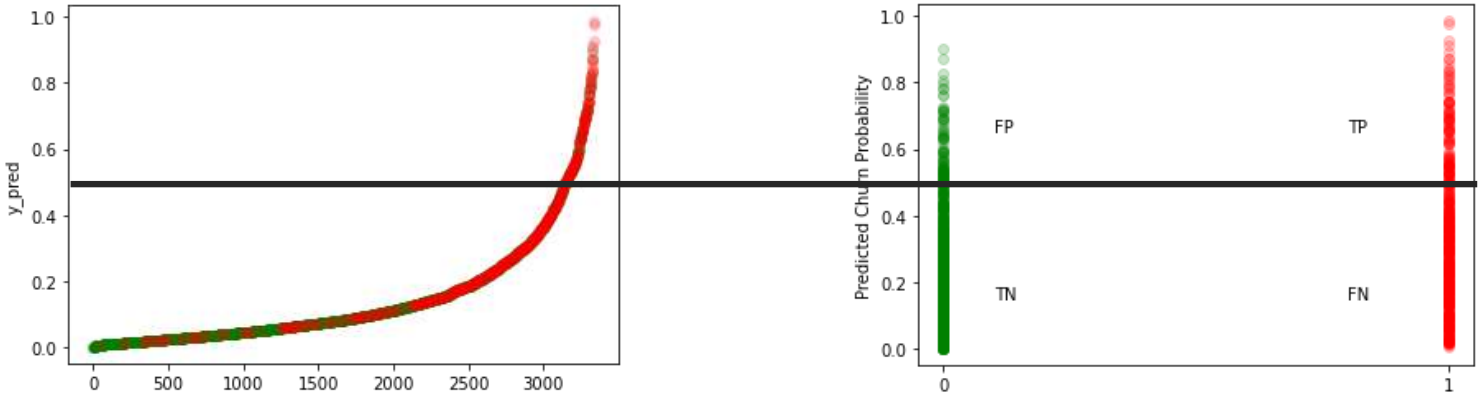
$$\text{Gain} = \frac{TP}{TP+FN}$$

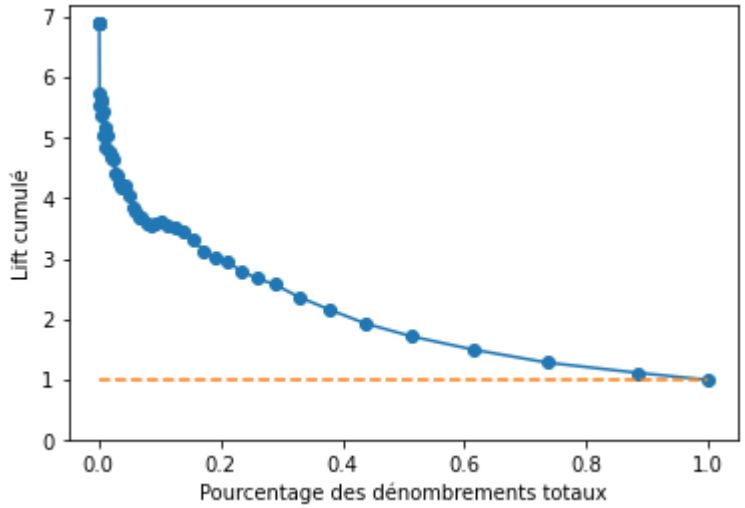
En abscisse, on reprendra la proportion des cas au des
du critère ramenée à la population totale, soit:

$$\frac{TP+FP}{TP+FN+FP+TN} = \frac{TP+FP}{N}$$

Qualification de modèle de classification binaire

Courbe de lift (1)





Ici, on comparera la proportion de vrais
dans les cas extraits (y_pred>T) à la
même proportion que donnerait un tirag
au sort quelconque sur la population to

$$\text{Lift} = \frac{\frac{TP}{TP+FP}}{\frac{TP+FP}{(TP+FN+FP+TN)==N}}$$

Comme dans le cas précédent, nous rapporterons ce n
fonction de la proportion des cas au dessus du critère r
à la population totale, soit:
:

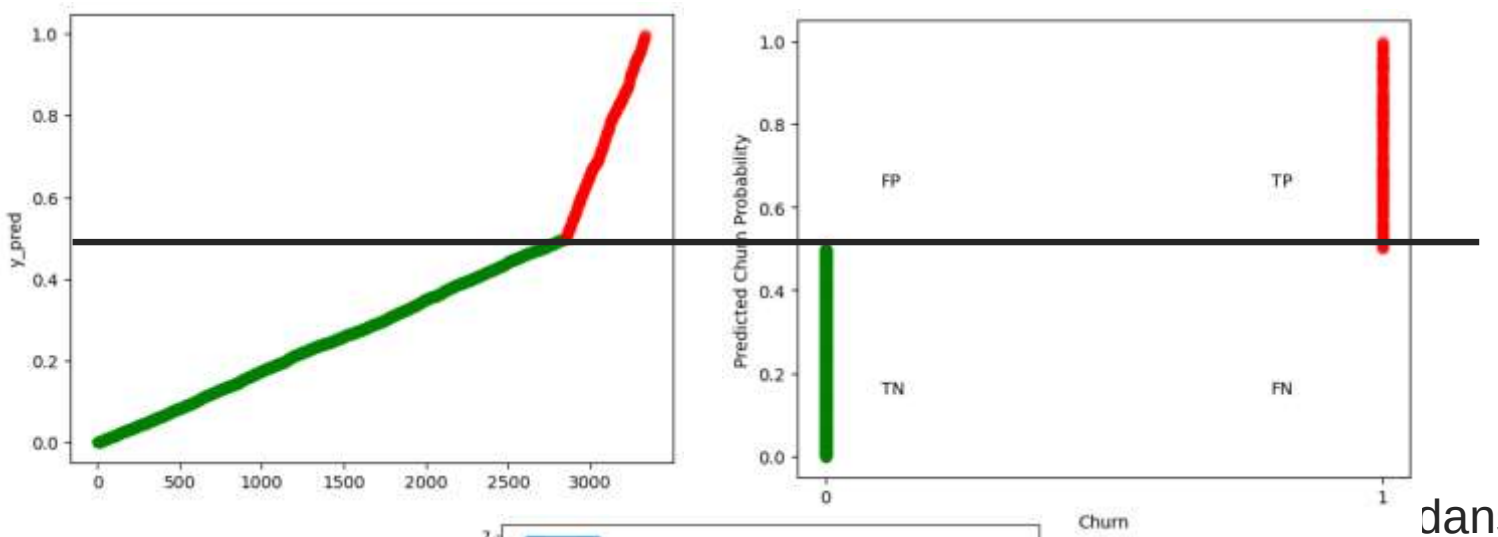
$$\frac{TP+FP}{N}$$

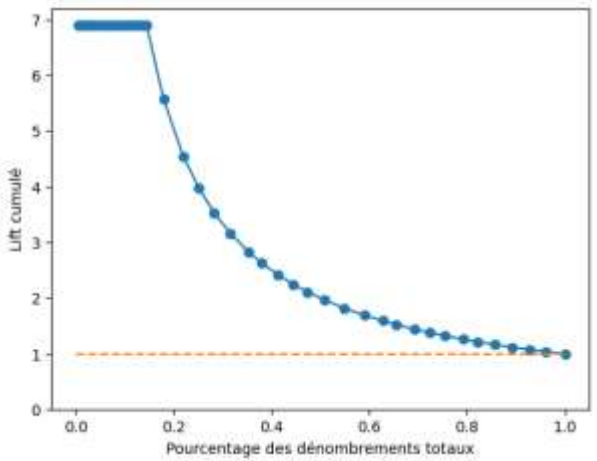
On notera que le lift maximum est indépendant du mod
simplement donné par:

$$\frac{N}{TP+FN}$$

Qualification de modèle de classification binaire

Courbes lift (2) – Courbe de lift dans le cas limite d'un modèle parfait





Ici, on comparera la proportion de vrais
dans les cas extraits (y_pred>T) à la
même proportion que donnerait un tirag
au sort quelconque sur la population to

$$\text{Lift} = \frac{\frac{TP}{TP+FP}}{\frac{TP+FN}{TP+FN+FP+TN}}$$

dans le cas précédent, nous rapporterons ce n
fonction de la proportion des cas au dessus du critère r
à la population totale, soit:
:

$$\frac{TP+FP}{TP+FN+FP+TN}$$

On notera que le lift maximum est indépendant du mod
simplement donné par:

$$\frac{TP+FN+FP+TN}{TP+FN}$$

Qualification de modèle de classification binaire

Courbes de gain **et** de lift

- Adaptable à tous les modèles donnant une valeur d'autant plus grande que le cas doit être considéré comme positif
- Essaye de qualifier l'efficacité du modèle dans le compactage des cas positifs dans le haut des valeurs issues du modèle
- L'efficacité est directement comparée à ce que le pur hasard donnerait en extrayant une sous-population de même taille